ジオメトリック・インテリジェンス

ケーススタディ補助文書 02

本編で使用された数学の解説

—機械学習エンジニアのための直感的入門—

本書は、ケーススタディ・ノベル「生存の幾何学」に登場した数学概念を、

機械学習エンジニア (微分幾何学未習) 向けに直感的に解説する文書である。

Étale Cohomology

2026 年 4 月

License: CC BY 4.0

目次

第 **1** 章 はじめに

1.1 本書の目的

1.2 想定読者と本書の方針

1.3 他の補助文書との分担

1.4 数式表記について

第 **2** 章 本書を読む前に—必要となる基礎

2.1 ベクトルと行列の復習

2.2 偏微分・勾配・ヤコビ行列・ヘシアン

2.3 確率変数・期待値・分散

2.4 グラフ理論の最小限

第 **3** 章 多様体の入門

3.1 多様体とは—「局所的に平坦」という発想

3.2 可微分多様体と接空間

3.3 計量テンソル

3.4 引き戻し計量

3.5 多様体の例—経営環境多様体

第 **4** 章 曲率

4.1 曲線の曲率 (2 次元での復習)

4.2 ガウス曲率と内在的視点

4.3 リーマン曲率テンソル

4.4 リッチテンソルとスカラー曲率

4.5 経営環境多様体での解釈

第 **5** 章 ベクトル場とリー微分

5.1 ベクトル場とは

5.2 フローと積分曲線

5.3 リー微分

5.4 リー括弧と非可換性

5.5 経営施策の数学的表現

第 **6** 章 測地線と最適制御

6.1 測地線とは
6.2 クリストッフェル記号
6.3 ハミルトン形式
6.4 ポントリャーギンの最大値原理
6.5 シンプレクティック構造

第 **7** 章 位相幾何学とその応用

7.1 位相同型と位相不変量
7.2 連結成分・ホモロジーの初歩
7.3 パーシステント・ホモロジー
7.4 層理論 (Sheaf Theory)
7.5 手術理論とコボルディズム

第 **8** 章 本ケーススタディに登場した定理

8.1 ホイットニーの拡張定理
8.2 リューヴィルの定理
8.3 ゲージ不変性の幾何学

第 **9** 章 確率・統計・機械学習の数学

9.1 ベイズ推論の最小限
9.2 MC ドロップアウトの数学的基礎
9.3 シャープレイ値と SHAP
9.4 二重機械学習 (DML) の直交化
9.5 ゼロ知識証明—ZKML の数学的基礎
9.6 形式検証の論理学的背景

付録 **A** 記号一覧

付録 **B** 推奨参考文献

第 1 章　はじめに

1.1　本書の目的

本書は、ケーススタディ・ノベル「生存の幾何学—綾鳥テキスタイル株式会社 14 ヶ月の戦争」(以下、本編) に登場した数学概念を、機械学習エンジニア向けに直感的に解説する文書である。

本編には、可微分多様体・引き戻し計量・スカラー曲率・リー微分・リー括弧・測地線・ポントリャーギンの最大値原理・シンプレクティック幾何・層理論・パーシステント・ホモロジー・ホイットニーの拡張定理など、機械学習の標準的なカリキュラムでは扱われない多数の数学概念が登場する。これらは多くがリーマン幾何学・微分幾何学・位相幾何学・最適制御理論の領域に属し、専門的な数学的訓練を受けていない読者には敷居が高い。

本書の目的は、これらの概念を「機械学習エンジニアにとって馴染みのある言語」で解説し、本編を理解する助けとすること、そしてジオメトリック・インテリジェンス理論書 (Vol.1 / Vol.2) の本格的な学習に進む前の「橋渡し」となることである。

1.2　想定読者と本書の方針

本書の想定読者は、以下のような知識・経験を持つ人物である。

- Python による機械学習の実装経験がある
- PyTorch / TensorFlow / scikit-learn などの主要ライブラリを使用したことがある
- VAE・SHAP・MC ドロップアウトといった機械学習手法に馴染みがある
- 微分積分 (大学初年級レベル) と線形代数の基礎を理解している

一方で、以下については前提としない。本書中で必要に応じて定義・解説を加える。

- 位相幾何学・微分幾何学・多様体論
- 最適化理論の高度な部分 (制約付き最適化・ポントリャーギンの最大値原理)
- リー微分・共変微分・クリストッフェル記号

本書の方針

本書では、数学的厳密さよりも「直感の獲得」を優先する。各概念について、まず日常的な比喩や機械学習の文脈での例えで概念のイメージを伝え、必要に応じて数式を提示する。厳密な定義や定理の証明は、Vol.1 / Vol.2 や標準的な教科書 (本書末尾の付録 B 参照) に譲る。

本書はあくまで「本ケーススタディに登場した数学」を扱う。本ケースに登場しない数学概念 (例えば

微分形式の一般論、リー群論の詳細、層コホモロジーの計算など) は、関連していても扱わない。これは、ハルシネーションを最小化し、読者が本編との対応関係を見失わないための方針である。

1.3 他の補助文書との分担

本ケーススタディには 5 つの文書が付属する。本書 (02) の位置づけは以下のとおりである。

文書	内容
00_story_main	本編ストーリー (綾鳥テキスタイル株式会社 14 ヶ月の戦争)
01_casestudy_GI_theory_mapping	本編の各場面と GI 理論の数学的工程との対応関係
02_mathematics(本書)	本編で使用された数学概念の解説 (定義・直感・例)
03_python_scripts	本編に登場するコード断片を整理した実装スクリプト集
04_industry_knowledge	本編に登場する繊維産業・通商規制・サイバー脅威などのドメイン知識

01 が「本編のシーンと工程の対応マッピング」を主題とするのに対し、本書 (02) は「本編に登場した数学概念そのもの」を独立して解説する。01 と本書を組み合わせて読むことで、「どの場面でこの数学が使われ、その数学とは何なのか」が両方理解できる構成となっている。

1.4 数式表記について

本書では、数式は LaTeX による正式な数学組版で表現する。例えば、計量テンソル g_{ij}、ベクトル場 V、リー括弧 $[X, Y]$ といった表記は、いずれも数学の標準的な記法に従う。

本書で頻繁に登場する記号について、以下に主なものをまとめておく (完全な一覧は付録 A を参照)。

記号	意味
M	多様体 (manifold)
z	多様体上の点 (本書では潜在空間の点を意味することが多い)
g_{ij}	計量テンソルの (i, j) 成分
$J(z)$	点 z におけるヤコビ行列
X, Y, V	ベクトル場 (vector field)
$[X, Y]$	ベクトル場 X と Y のリー括弧
$\mathcal{L}_X g$	ベクトル場 X に沿った計量 g のリー微分
R^l_{ijk}	リーマン曲率テンソル
R_{ij}	リッチテンソル
R, Scal	スカラー曲率
Γ^k_{ij}	クリストッフェル記号

添字の上下 (共変・反変) は、数学的厳密性を重視する場面では区別が重要だが、本書では直感的説明を優先するため、必要に応じて簡略化する場合がある。厳密な区別が必要な場合は、Vol.1 / Vol.2 を参照されたい。

第 2 章　本書を読む前に—必要となる基礎

本章では、本書の以降の章を読むために必要となる線形代数・微分積分・確率論・グラフ理論の基礎を、機械学習エンジニアに馴染みのある観点から復習する。すでに十分理解している読者は、本章を飛ばして第 3 章から読み始めてよい。

2.1　ベクトルと行列の復習

ベクトル

ベクトル (vector) とは、向きと大きさを持つ量である。機械学習の文脈では、しばしば多次元のデータポイントとして現れる。例えば、ある日の経営状態を「売上、コスト、在庫、為替レート、サプライチェーン健全度」の 5 つの数値で表すなら、それは 5 次元ベクトル $v = (v_1, v_2, v_3, v_4, v_5)$ として表現できる。

本書で頻出する操作:

- ベクトルの和—$v + w$(同じ次元のベクトル同士の足し算)
- スカラー倍—$c \cdot v$(ベクトルを定数倍する)
- 内積—$v \cdot w$ または $\langle v, w \rangle$(2 つのベクトルの「近さ」を測る量)
- ノルム—$\|v\|$(ベクトルの「長さ」$\|v\| = \sqrt{v \cdot v}$)

行列

行列 (matrix) とは、ベクトルを別のベクトルに変換する線形写像を、数値の表として表現したものである。$n \times m$ 行列 A は、m 次元のベクトル v を n 次元のベクトル Av に変換する。

本書で重要となる概念:

- 固有値・固有ベクトル—$Av = \lambda v$ を満たす λ(固有値) と v(固有ベクトル)。行列の「性格」を要約する
- 特異値分解 (SVD) —$A = U\Sigma V^T$。任意の行列を「回転 → スケール → 回転」に分解する
- ランク—行列の独立な行 (または列) の数。フルランクとは、最大限に独立な行・列を持つ状態
- 正定値性—すべての固有値が正である行列。計量テンソルとして使える条件

特に重要—ヤコビ行列

本書では多変数の関数 $f\colon \mathbb{R}^m \to \mathbb{R}^n$ が頻繁に登場する。例えば、VAE のデコーダは潜在空間の点 (m 次元) をデータ空間の点 (n 次元) に写す関数である。

ヤコビ行列 $J(z)$ は、点 z における関数 f の局所的な線形近似を与える行列である。f が $\mathbb{R}^m$ から $\mathbb{R}^n$ への写像であるとき、ヤコビ行列は $n \times m$ 行列であり、その (i, j) 成分は f の i 番目の出力成分の、j 番目の入力変数による偏微分 $\partial f_i / \partial z_j$ である。

$$J(z)_{ij} = \frac{\partial f_i(z)}{\partial z_j}$$

ヤコビ行列の幾何学的意味は、「点 z の近傍で、入力空間の小さな変化がどのように出力空間の変化に変換されるか」を線形近似で表現することである。これは多様体論で計量テンソルを構築するための基本道具となる。

2.2 偏微分・勾配・ヤコビ行列・ヘシアン

偏微分

多変数関数 $f(x_1, x_2, \ldots, x_n)$ について、変数 x_i だけを変化させ、他の変数を固定したときの変化率を、x_i に関する偏微分と呼び、$\partial f / \partial x_i$ と書く。

例えば、$f(x, y) = x^2 + 3xy + y^3$ について、$\partial f / \partial x = 2x + 3y$、$\partial f / \partial y = 3x + 3y^2$ である。

勾配

スカラー値関数 $f \colon \mathbb{R}^n \to \mathbb{R}$ の勾配 ∇f は、すべての偏微分を成分とするベクトルである。

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_n} \right)$$

勾配は、関数 f の値が最も急速に増加する方向を指す。機械学習では、損失関数を最小化するために勾配の逆方向に進む (勾配降下法) が基本である。

ヘシアン

ヘシアン (Hessian) は、関数 f の 2 階偏微分を並べた $n \times n$ 対称行列である。

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

ヘシアンは、関数の局所的な「曲がり方」を表す。ヘシアンが正定値なら局所的に下に凸 (極小値の候補)、負定値なら上に凸 (極大値の候補)、混合した固有値を持つなら鞍点である。

本書で扱うリーマン幾何学の曲率テンソルは、ヘシアンの多様体上での一般化と見ることができる。

2.3 確率変数・期待値・分散

本書では、第 9 章で MC ドロップアウト・SHAP・DML・ZKML を扱うため、確率論の基礎が必要となる。

確率変数

確率変数 (random variable) とは、確率的な事象に値を割り当てる関数である。機械学習の文脈では、予測モデルの出力 y_{pred}、観測されたデータ x、ノイズ ε などが確率変数として扱われる。

期待値と分散

確率変数 X の期待値 $\mathbb{E}[X]$(平均値) は、その値の重み付き平均である。離散の場合は $\mathbb{E}[X] = \sum_i x_i P(X = x_i)$、連続の場合は $\mathbb{E}[X] = \int x\, p(x)\, dx$。

分散 $\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$ は、確率変数の値が平均値からどれだけ広がっているかを表す。標準偏差 $\sigma = \sqrt{\mathrm{Var}(X)}$ は、分散の平方根で、データと同じ単位で広がりを表現する。

条件付き確率と独立性

事象 B が起きたという条件のもとで事象 A が起きる確率を、条件付き確率 $P(A|B)$ と書く。$P(A|B) = P(A \cap B)/P(B)$。

ベイズの定理は、条件付き確率の関係を表す基本式である:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

ベイズの定理は、第 9 章のベイズ推論および MC ドロップアウトの数学的基礎で重要な役割を果たす。

2.4 グラフ理論の最小限

本書では、第 7 章で層理論やパーシステント・ホモロジーを扱う際、グラフ構造が登場する。

グラフの定義

グラフ (graph)$G = (V, E)$ は、頂点 (ノード) の集合 V と、頂点ペアを接続する辺 (エッジ) の集合 E から構成される構造である。

本ケーススタディの文脈では、サプライチェーンが典型的なグラフである。各ノードは工場・倉庫・小売店・顧客などの拠点であり、各エッジは拠点間の取引・配送関係を表す。

有向グラフと無向グラフ

辺に方向があるグラフを有向グラフ (directed graph)、方向がないグラフを無向グラフ (undirected graph) と呼ぶ。サプライチェーンでは「A から B への配送」のように方向があるため、有向グラフでモデル化されることが多い。

隣接行列とラプラシアン

グラフを行列で表現する標準的な方法が隣接行列 (adjacency matrix) である。n 個のノードを持つグラフの隣接行列 A は $n \times n$ 行列で、(i, j) 成分は、i から j への辺が存在すれば 1、なければ 0 である。

次数行列 D は対角行列で、(i, i) 成分はノード i から出る辺の本数 (次数) である。グラフラプラシアン L は $L = D - A$ で定義される対称行列で、ノード間の値の不整合を測定する道具として使われる。

L の固有値分解は、グラフのスペクトル特性を明らかにする。最小固有値は常に 0(対応する固有ベクトルは定数ベクトル) であり、第 2 固有値の大きさはグラフの「結合の強さ」を反映する。第 7 章で扱う層ラプラシアン (sheaf Laplacian) は、このグラフラプラシアンを多次元の層構造に一般化したものである。

次章からは、いよいよ多様体の本論に入る。

第 3 章　多様体の入門

本章では、ジオメトリック・インテリジェンス理論の中核概念である多様体 (manifold) を、機械学習エンジニアにとって馴染みのある観点から導入する。多様体は本ケーススタディの全体を通じて中心的な役割を果たすため、本書で最も重要な章の一つである。

3.1　多様体とは—「局所的に平坦」という発想

多様体とは、各点の周辺で局所的にユークリッド空間と同一視できる滑らかな空間のことである。これは抽象的に聞こえるかもしれないが、日常的な例で考えると非常に身近な概念である。

地球の表面の例

地球の表面は球面 (2 次元曲面) であり、これは典型的な 2 次元多様体である。地球表面のあらゆる点に立つと、その点の周辺は近似的に「平らな平面」のように見える。地球規模では曲がっているが、自分の半径数 km の周辺だけ見れば、平面と同じ幾何学が成立する。

これがまさに多様体の本質である。「局所的にはユークリッド空間と同じ」という性質を持ちながら、「大域的には曲がっている可能性がある」空間。多様体の理論は、この局所と大域の関係を統一的に扱う数学的枠組みである。

機械学習における多様体仮説

機械学習エンジニアは、すでに「多様体仮説 (manifold hypothesis)」という形でこの概念に触れている可能性が高い。多様体仮説とは、「現実世界の高次元データは、見かけ上は高次元空間に存在するが、実際には低次元の多様体の周辺に集中している」という主張である。

例えば、224×224 ピクセルのカラー画像は $224 \times 224 \times 3 = 150{,}528$ 次元のベクトル空間に属するが、現実の自然画像はこの広大な空間のごく一部—おそらく数百次元程度の多様体—の近傍に集中している。VAE や GAN といった生成モデルは、この多様体構造を暗に活用している。

ジオメトリック・インテリジェンス理論は、この発想を経営環境データに拡張する。多数の経営指標 (本ケースでは 100 指標) があっても、それらは独立に変動するのではなく、低次元多様体 (本ケースでは 8 次元) の上を動いている、という仮説に基づく。

3.2　可微分多様体と接空間

可微分多様体

多様体の中でも、各点の周辺で「滑らかさ」を持つもの—すなわち微分・積分が可能なもの—を可微分多様体 (differentiable manifold) と呼ぶ。本ケーススタディで扱われる多様体はすべて可微分多様体である。

可微分性は、後の曲率計算やリー微分・最適制御の計算で必要となる。離散的な点の集まりや、折れ目のある曲面では、これらの計算が破綻する。

接空間

多様体 M 上の点 p における接空間 (tangent space)T_pM とは、点 p で M に「接する」線形空間のことである。直感的には、地球の表面のある地点で「水平な接平面」を考えるのと同じ発想である。

接空間は、多様体の各点で定義される。多様体が n 次元なら、各点の接空間も n 次元である。重要なのは、多様体自体は曲がっていても、各点の接空間は通常のユークリッド空間として扱える、という点である。これにより、曲がった空間の中の局所的な解析を、通常の線形代数の道具で実行できる。

本書で頻出する「ベクトル場」(第 5 章) は、多様体の各点に「その点の接空間内のベクトル」を割り当てる場のことである。

3.3 計量テンソル

可微分多様体の上で「距離」を測るためには、計量テンソル (metric tensor) が必要である。計量テンソルとは、多様体の各点で「微小な変位がどれだけの距離に対応するか」を定義する数学的対象である。

計量テンソルの形式

n 次元多様体の各点 p における計量テンソル $g_{ij}(p)$ は、$n \times n$ の対称正定値行列である。すなわち、以下の性質を持つ。

- 対称性—$g_{ij} = g_{ji}$(添え字 i と j を入れ替えても同じ値)
- 正定値性—任意の非ゼロベクトル v に対して、$\sum_{ij} g_{ij} v^i v^j > 0$

計量テンソルがあれば、点 p における 2 つの接ベクトル v, w の内積は

$$\langle v, w \rangle = \sum_{ij} g_{ij} v^i w^j$$

で計算でき、ベクトルの長さは $\|v\| = \sqrt{\langle v, v \rangle}$ となる。

リーマン多様体

計量テンソルが定義された可微分多様体を、リーマン多様体 (Riemannian manifold) と呼ぶ。本ケーススタディの「経営環境多様体」は、リーマン多様体である。

3.4 引き戻し計量

本ケーススタディで採用される引き戻し計量 (pullback metric) は、計量テンソルを構成する一つの特殊な方法である。VAE デコーダによる構成法を持ち、機械学習との接続が直接的である点が特徴である。

引き戻しの一般的な意味

数学において「引き戻し (pullback)」とは、ある空間の構造を、写像を通じて別の空間に「持ち戻す」操作の総称である。

具体例で考えよう。地図上の二点間の距離を考えるとき、地図 (平面) と現実の地表面 (球面) は別の空間である。地図を見ながら距離を計算するためには、地表面の真の距離 (球面上の距離) を、地図上にどう表現するかを定義する必要がある。これが、地表面の計量を地図に「引き戻す」という操作である。

VAE デコーダによる引き戻し計量

VAE のデコーダ f は、潜在空間の点 z をデータ空間の点 $f(z)$ に写す関数である。ここで、データ空間には自然なユークリッド距離が定義されている (各データ点を高次元ベクトルとして見る場合)。

引き戻し計量とは、データ空間のユークリッド計量を、デコーダ f を通じて潜在空間に引き戻したものである。具体的には、点 z における引き戻し計量 $g(z)$ は、デコーダのヤコビ行列 $J(z)$ を使って次のように構成される。

$$\boxed{g(z) = J(z)^T J(z)}$$

この行列の (i, j) 成分は、

$$g_{ij}(z) = \sum_k \frac{\partial f_k}{\partial z_i} \frac{\partial f_k}{\partial z_j}$$

である。

引き戻し計量の性質

$g(z) = J^T J$ は、以下の重要な性質を持つ。

- 対称行列—$(J^T J)^T = J^T (J^T)^T = J^T J$、すなわち $g_{ij} = g_{ji}$
- 半正定値—任意のベクトル v に対して $v^T g v = v^T J^T J v = \|Jv\|^2 \geq 0$
- J がフルランクなら正定値—つまり、本ケーススタディの命題 1.1 条件 3「ヤコビアンの非退化性」が満たされていれば、g は正定値計量テンソルとなる

これが、本ケーススタディで命題 1.1 条件 3 が要求される数学的理由である。条件 3 が破綻すれば、g は単に半正定値となり、計量テンソルとして使えない領域が生じる。

幾何学的解釈

$v^T g(z) v = \|J(z)v\|^2$ という関係式の意味を考えよう。左辺は、潜在空間で点 z から微小方向 v に動いたときの「距離の二乗」を表す。右辺は、デコーダ出力—つまりデータ空間—で対応する変位 $J(z)v$ の長さの二乗である。

つまり、引き戻し計量で測った潜在空間の距離は、「対応するデータ空間での見かけ上の距離」を表現している。潜在空間で「同じ距離」だけ動いても、データ空間で大きく変化する場所と、ほとんど変化しない場所がある。引き戻し計量は、この非一様性を定量化する。

3.5 多様体の例—経営環境多様体

ここまでの抽象的な議論を、本ケーススタディの「経営環境多様体」に当てはめてまとめる。

項目	経営環境多様体での具体的内容
多様体 M	VAE が学習した 8 次元の潜在空間
点 $z \in M$	ある時点での経営状態 (8 次元ベクトル)
接空間 $T_z M$	点 z から取りうる微小変化の方向の空間
計量テンソル $g_{ij}(z)$	引き戻し計量 $J(z)^T J(z)$。$J(z)$ は VAE デコーダのヤコビアン
ベクトル場 X	経営施策 (例: ベトナム工場停止 X_{cyber}、エンティティ・リスト施行 X_{trade})

本ケーススタディの第 1〜2 月の作業は、この経営環境多様体を実データから構築する過程であった。命題 1.1 の三条件は、構築された潜在空間が「真に多様体として機能するか」を検証する基準である (具体的な失敗と克服の過程は、01_casestudy_GI_theory_mapping の第 3 章を参照)。

次章では、この多様体の上で「曲がり方」を測る道具—曲率—を扱う。

第 4 章　曲率

本章では、リーマン多様体の曲がり方を測る道具—曲率—を扱う。本ケーススタディでは、スカラー曲率が「経営環境のどこが安定でどこが不安定か」を一目で示す指標として使われた。曲率の概念は階層的に構成されており、最も詳細なリーマン曲率テンソルから順に縮約してリッチテンソル、スカラー曲率と段階的に情報を圧縮する。

4.1　曲線の曲率—2 次元での復習

曲率の概念を、まず 2 次元平面の曲線で復習する。これは多くの読者がすでに親しんでいる内容である。

円の曲率

半径 r の円の各点における曲率は、$\kappa = 1/r$ で定義される。半径が小さい円は強く曲がっており (大きな曲率)、半径が大きい円は緩く曲がっている (小さな曲率)。直線は「半径無限大の円」とみなせ、曲率はゼロである。

一般の曲線の曲率

曲線 $y = f(x)$ の各点における曲率は、その点で曲線に最もよく当てはまる円 (接触円) を考え、その円の曲率として定義される。具体的には、

$$\kappa = \frac{|f''(x)|}{(1 + (f'(x))^2)^{3/2}}$$

つまり、関数の二階微分が大きいほど曲率も大きくなる。これは第 2 章で復習したヘシアンと密接に関連する概念である。

4.2　ガウス曲率と内在的視点

曲線から曲面に話を進めよう。2 次元曲面の曲がり方を測るには、ガウス曲率 (Gaussian curvature) が用いられる。

外在的視点 vs 内在的視点

曲面の曲がり方を測るには、二つのアプローチがある。

- 外在的視点—曲面を 3 次元空間に埋め込んで、外から見て「どう曲がっているか」を測る

- 内在的視点—曲面の中だけを使って、外部の空間に頼らずに曲がり方を測る

ガウスの「驚異の定理 (Theorema Egregium)」は、ガウス曲率が内在的に定義可能であることを示した、19 世紀の重要な発見である。すなわち、曲面の中の住人 (2 次元生物) が、自分の周辺で三角形を測って内角の和を計算するだけで、曲率が判定できる。

- 内角の和 $= 180^\circ \to$ 平坦 (ガウス曲率 0)
- 内角の和 $> 180^\circ \to$ 球状 (ガウス曲率正)
- 内角の和 $< 180^\circ \to$ 鞍状 (ガウス曲率負)

この内在的視点が、リーマン幾何学の根本にある発想である。経営環境多様体は外部の高次元空間に埋め込まれているとは考えず、多様体の中の構造 (計量テンソル) だけから曲率を計算する。

4.3 リーマン曲率テンソル

n 次元のリーマン多様体に対して、その曲がり方を最も詳細に記述するのがリーマン曲率テンソル R^l_{ijk} である。これは 4 つの添え字を持つテンソルであり、n^4 個の成分から構成される。

クリストッフェル記号からの構成

リーマン曲率テンソルは、計量テンソル g_{ij} から計算されるクリストッフェル記号 Γ^k_{ij} を介して構成される。クリストッフェル記号は、計量テンソルとその一階偏微分を組み合わせて定義される量である。

$$\Gamma^k_{ij} = \frac{1}{2} g^{kl} \left(\partial_i g_{lj} + \partial_j g_{li} - \partial_l g_{ij} \right)$$

ここで g^{kl} は計量テンソルの逆行列、∂_i は i 番目の座標変数による偏微分を表す。クリストッフェル記号の役割は第 6 章でさらに詳しく扱う。

リーマン曲率テンソルは、クリストッフェル記号とその一階偏微分の組み合わせで定義される。

$$R^l_{ijk} = \partial_i \Gamma^l_{jk} - \partial_j \Gamma^l_{ik} + \Gamma^l_{im} \Gamma^m_{jk} - \Gamma^l_{jm} \Gamma^m_{ik}$$

この式は複雑に見えるが、本書の方針として「直感優先」のため、各成分を覚える必要はない。重要なのは、リーマン曲率テンソルが計量テンソルから機械的・代数的な手続きで計算可能である、という事実である。

リーマン曲率テンソルの幾何学的意味

リーマン曲率テンソルの直感的な意味は、「ベクトルを多様体上で平行移動させたとき、出発点と到着点でどれだけずれるか」を測ることにある。曲がっていない空間 (ユークリッド空間) では、ベクトルを閉じた経路で平行移動させると、出発点で完全に元のベクトルに戻る。曲がった空間では、わずかにずれる。このずれの量を定量化するのがリーマン曲率テンソルである。

4.4 リッチテンソルとスカラー曲率

リーマン曲率テンソルは詳細な情報を持つが、n^4 個の成分は実用的には扱いにくい。そこで、添え字を一つ縮約してリッチテンソル R_{ij}(n^2 個の成分) を、さらに縮約してスカラー曲率 R(1 個のスカラー) を得る。

リッチテンソル

リッチテンソルは、リーマン曲率テンソルの第 1 と第 3 の添え字を縮約した結果である。

$$R_{ij} = R^k_{ikj}$$

ここで k についての和を取る (アインシュタインの規約: 上下に同じ添え字が現れたら和を取る)。リッチテンソルは $n \times n$ 対称行列で、リーマン曲率テンソルから計量テンソルと同じ形式の量を取り出したものである。

スカラー曲率

スカラー曲率 R は、リッチテンソルをさらに縮約したものである。

$$R = g^{ij} R_{ij}$$

スカラー曲率は多様体の各点で定義されるスカラー値で、その点の周辺における曲がり方を一つの数値に要約した量である。本ケーススタディの第 3 章「地形図」(2026 年 10 月) では、このスカラー曲率が綾鳥多様体上で計算され、危険な領域 (負の曲率が大きい点) が特定された。

スカラー曲率の符号と意味

スカラー曲率 $R(z)$ の符号と大きさの意味は、以下のように解釈される。

- $R > 0$ —局所的に「球状」。その点付近で軌道は収束する傾向がある。安定構造

- $R = 0$ ―局所的に「平坦」。その点付近では収束も発散もしない。中立
- $R < 0$ ―局所的に「鞍型」。その点付近で軌道は発散する傾向がある。不安定構造

経営環境多様体において、スカラー曲率が大きく負の値を取る点は、わずかな摂動が増幅される領域である。すなわち、小さな衝撃が連鎖的に大きな影響を生む経営状態であり、危機の前兆を検出する強力な指標となる。

4.5 経営環境多様体での解釈

本ケーススタディで報告されたスカラー曲率の値の例を、ここで再掲する (詳細は 01_casestudy_GI_theory_mapp
の第 4 章参照)。

時点	スカラー曲率	背景
2020-03-15	−47.31	COVID グローバル・ロックダウン
2022-02-28	−38.92	ウクライナ戦争勃発
2026-08-26	−22.17	ケーススタディの「現在地」

重要なのは、スカラー曲率という単一の数値が、経営環境の構造的脆弱性を表現できるという点である。100 個の経営指標すべてを個別に追跡するのではなく、これらが構成する多様体上の各点のスカラー曲率を計算することで、「現在地が危険か安全か」を一目で判断できる。これが、ジオメトリック・インテリジェンス理論が提供する「次元削減」の真の意味の一つである。

次章では、多様体の上のベクトル場―すなわち経営施策のモデル化―と、それに関連するリー微分・リー括弧を扱う。

第 5 章　ベクトル場とリー微分

本章では、多様体上の「ベクトル場」と、ベクトル場どうしの相互作用を測る道具—リー微分とリー括弧—を扱う。本ケーススタディでは、複数の経営施策・脅威がベクトル場としてモデル化され、それらの相互作用効果 (創発現象) が定量化される過程で中心的な役割を果たした。

5.1　ベクトル場とは

ベクトル場 (vector field)X とは、多様体 M の各点 p に「その点の接空間内のベクトル $X(p) \in T_pM$」を割り当てる場のことである。直感的には、多様体上のすべての点に矢印を一本ずつ描いたものと考えてよい。

日常的な例

ベクトル場の身近な例として、地球の表面上の風速ベクトル場が挙げられる。地球表面のあらゆる地点に、その地点での風の向きと強さがベクトル (矢印) として定義されている。これは 2 次元多様体 (地球表面) 上のベクトル場である。

別の例として、磁場や電場、流体の流速場なども、3 次元空間 (あるいはその部分多様体) 上のベクトル場である。

経営の文脈でのベクトル場

本ケーススタディでは、各種の経営施策・外部ショックが経営環境多様体上のベクトル場としてモデル化される。

本編第 4 章で定義されたベクトル場 X_{cyber}(ベトナム工場のサイバー攻撃) を例として再掲する。

$$X_{\text{cyber}}(z) = (0, 0, 0, -0.8, 0, -0.6, 0, +0.4)$$

これは 8 次元の経営環境多様体の各点に対して、上記の 8 次元ベクトルを割り当てるベクトル場である。具体的には、潜在次元 3(生産能力) に -0.8、次元 5(サプライチェーン信頼性) に -0.6、次元 7(コスト構造) に $+0.4$ という値である。すなわち、サイバー攻撃を受けた経営状態は、生産能力とサプライチェーン信頼性が下がり、コストが上がる方向に「動かされる」ことをこのベクトル場が表現する。

5.2　フローと積分曲線

ベクトル場 X が与えられたとき、その流れに沿って動く軌道を考えることができる。これが積分曲線 (integral curve)、またはフロー (flow) である。

積分曲線の数学的定義

ベクトル場 X の積分曲線とは、各時刻 t において、その点でのベクトル $X(c(t))$ と曲線の接線方向 $c'(t)$ が一致するような曲線 $c(t)$ のことである。

$$\frac{dc}{dt}(t) = X(c(t))$$

これは常微分方程式である。初期条件 $c(0) = z_0$ が与えられれば、ベクトル場 X が滑らかなら、唯一の解 $c(t)$ が (少なくとも局所的に) 存在する。

経営の文脈での解釈

経営環境多様体上で、「サイバー攻撃ベクトル場 X_{cyber} に沿って流される」という意味は、「サイバー攻撃を受け続けた場合、経営状態がどのように時間発展するか」という軌道に対応する。

Neural ODE(本ケーススタディで使われた手法) は、まさにこの積分曲線をニューラルネットワークでパラメトリゼーションする手法である。微分方程式 $dz/dt = f(z, t)$ における右辺関数 f を、観測データから学習することで、未知のダイナミクスを連続時間で表現する。

5.3 リー微分

ベクトル場が与えられたとき、その流れに沿って多様体上の他の量 (関数、テンソル場など) がどう変化するかを記述する微分演算が、リー微分 (Lie derivative) である。

関数のリー微分

まず、最も単純な場合として、多様体上のスカラー値関数 f のリー微分を考える。ベクトル場 X に沿った関数 f のリー微分 $\mathcal{L}_X f$ は、X の流れに沿って f がどれだけ変化するかを表す。

$$\mathcal{L}_X f = X(f) = \sum_i X^i \frac{\partial f}{\partial z^i}$$

これは方向微分 (directional derivative) と等しい。X 方向への f の傾きである。

計量テンソルのリー微分

本ケーススタディで重要なのは、計量テンソル g のリー微分 $\mathcal{L}_X g$ である。これは、ベクトル場 X の流れに沿って計量テンソル—すなわち多様体の「形」そのもの—がどう変化するかを表す対称行列である。

$\mathcal{L}_X g$ の幾何学的解釈は次のとおりである。

- $\mathcal{L}_X g = 0$ のとき—X はキリングベクトル場と呼ばれ、X の流れに沿って動いても多様体の幾何構造が保たれる。「穏やかな」流れである
- $\mathcal{L}_X g \neq 0$ のとき—X の流れは多様体の幾何構造そのものを変形させる。「構造変革型」の流れである。$\mathcal{L}_X g$ の固有値スペクトルが、変形の方向と大きさを示す

本ケースでの計算結果

本編第 4 章で報告された $\mathcal{L}_{X_{\text{cyber}}} g$ の固有値分析結果を再掲する。

- 最大固有値—3.7142(コスト方向に約 3.7 倍の膨張)
- 最小固有値—−2.1893(生産能力方向に約 2.2 倍の収縮)
- トレース—4.2831(全体として経営環境の体積が膨張、すなわち不確実性の増大)

これは、サイバー攻撃が経営環境多様体の幾何構造そのものを—単に状態を移動させるだけでなく—変形させることを定量的に示している。

5.4 リー括弧と非可換性

二つのベクトル場 X, Y のリー括弧 $[X, Y]$ は、本ケーススタディの最も鋭い洞察を支える数学的道具である。

リー括弧の定義

ベクトル場 X, Y のリー括弧 $[X, Y]$ は、新しいベクトル場として定義される。座標系での具体的な表現は次のとおりである。

$$[X, Y]^k = \sum_i \left(X^i \frac{\partial Y^k}{\partial z^i} - Y^i \frac{\partial X^k}{\partial z^i} \right)$$

つまり、Y を X の方向に微分した結果から、X を Y の方向に微分した結果を引いたものである。

幾何学的意味—経路の非可換性

リー括弧の直感的な意味を、以下のような状況で考えよう。多様体上の点 z から出発し、二つの異なる経路で動くことを考える。

- 経路 A —まず X に沿って微小ステップ ε 進み、次に Y に沿って微小ステップ ε 進む

- 経路 B —まず Y に沿って微小ステップ ε 進み、次に X に沿って微小ステップ ε 進む

ユークリッド空間 (平坦な空間) では、経路 A と B の終点は完全に一致する。X と Y の順序を入れ替えても結果は同じ—「可換」である。

しかし、一般のベクトル場では、経路 A と B の終点は微妙にずれる。このずれの大きさと方向を、ε^2 のオーダーで測定するのがリー括弧 $[X, Y]$ である。すなわち、リー括弧は「順序によって結果がどれだけずれるか」を定量化する。

$[X, Y] = 0$ のとき、X と Y は可換であり、流れの順序を入れ替えても結果は同じである。$[X, Y] \neq 0$ のとき、非可換であり、X と Y を組み合わせる順序で結果が変わる。さらに重要な点として、$[X, Y]$ は X 単独でも Y 単独でも生み出せない第三の効果—すなわち X と Y の相互作用に固有の効果—を表現する。

経営の文脈での創発効果

経営施策の文脈に翻訳すると、リー括弧は「二つの施策・脅威の組み合わせから生じる、どちらか単独では生じない第三の効果」を捉える。

本編第 4 章で計算された $[X_{\text{cyber}}, X_{\text{trade_policy}}]$ の結果を再掲する。

- 大きさ—2.8934(強い創発効果)
- 方向—主に潜在次元 4(ブランド評判) と次元 6(投資家信頼) の負の方向

サイバー攻撃 X_{cyber} 単独では生産にダメージを与え、エンティティ・リスト施行 $X_{\text{trade_policy}}$ 単独では調達を制限する。しかし両者の組み合わせは、どちらか単独では生じない第三の効果—ブランド評判の壊滅的崩壊—を生む。リー括弧 $[X_{\text{cyber}}, X_{\text{trade_policy}}]$ が、この創発効果の数学的検出を可能にする。

5.5 経営施策の数学的表現

本章のまとめとして、経営施策のベクトル場としてのモデル化と、その数学的扱いを整理する。

数学的概念	経営の文脈での意味
X	ある経営施策・外部ショック (サイバー攻撃、規制施行など)
X の積分曲線	施策・ショックが継続した場合の経営状態の時間発展軌道
$\mathcal{L}_X g$	施策・ショックが経営環境の構造そのものをどう変形させるか
$[X, Y]$	二つの施策・ショックの相互作用から生じる創発効果
$[X, Y] = 0$	二施策は可換、独立に評価して足し合わせてよい
$[X, Y] \neq 0$	非可換、線形分析では捉えられない創発効果が存在する

リー括弧分析が威力を発揮するのは、複数の脅威・施策が同時に作用している状況である。本ケーススタディでは、第 5 月以降、X_{cyber}、X_{trade}、X_{dpp}(EU DPP 規制)、X_{takeover}(敵対的買収) という 4 つのベクトル場が同時に作用し、それらの高次のリー括弧—$[[[X_{\text{cyber}}, X_{\text{trade}}], X_{\text{dpp}}], X_{\text{takeover}}]$ のような入れ子構造—が計算された。これは脅威の規模に応じてスケーラブルに高次に拡張可能な、線形分析にはない強力な道具である。

第 6 章　測地線と最適制御

本章では、リーマン多様体上の「最短経路」である測地線 (geodesic)、その計算に必要なクリストッフェル記号、そしてこれらを拡張した最適制御の枠組み—ハミルトン形式とポントリャーギンの最大値原理—を扱う。本ケーススタディでは、危機対応プランの導出と長期軌道シミュレーションが、これらの数学的道具に基づいていた。

6.1　測地線とは

測地線とは、リーマン多様体上の二点を結ぶ最短経路、より厳密には「局所的に最短である経路」のことである。

ユークリッド空間での復習

平らなユークリッド空間において、二点を結ぶ最短経路は直線である。これは中学校以来の常識である。直線の特徴は、各点での進行方向が変化しない、すなわち接ベクトルが一定であることである。

曲がった空間での測地線

曲がった多様体上では、状況が複雑になる。例えば、地球表面上の二点を結ぶ最短経路は、平面地図上では直線に見えないが、球面上では大円 (地球の中心を通る平面と球面の交線) である。これが球面上の測地線である。

一般のリーマン多様体上の測地線は、「進行方向が局所的に変化しない経路」として定義される。ただし、ここで「変化しない」とは、多様体の曲がり方を考慮した「共変微分」での意味である。

測地線方程式

測地線 $c(t)$ は、以下の常微分方程式を満たす曲線である。

$$\frac{d^2c^k}{dt^2} + \sum_{ij} \Gamma^k_{ij} \frac{dc^i}{dt}\frac{dc^j}{dt} = 0$$

ここで Γ^k_{ij} はクリストッフェル記号である。第 1 項は通常の二階微分 (直線の場合の方程式) であり、第 2 項が「曲がった空間での補正」を担っている。

6.2 クリストッフェル記号

クリストッフェル記号 (Christoffel symbols)Γ^k_{ij} は、第 4 章で定義したリーマン曲率テンソルの計算でも登場した量である。本節では、その役割をより詳しく解説する。

計量テンソルからの計算

クリストッフェル記号は、計量テンソル g_{ij} とその逆行列 g^{kl} から、以下の式で計算される。

$$\Gamma^k_{ij} = \frac{1}{2} g^{kl} \left(\partial_i g_{lj} + \partial_j g_{li} - \partial_l g_{ij} \right)$$

n 次元多様体では、クリストッフェル記号は n^3 個の成分を持つ。ただし、添え字 i と j について対称 ($\Gamma^k_{ij} = \Gamma^k_{ji}$) なので、独立な成分は $n^2(n+1)/2$ 個である。

幾何学的役割—平行移動と共変微分

クリストッフェル記号の幾何学的役割は、「曲がった空間でベクトルを平行移動するための補正項」を与えることである。

ユークリッド空間では、ベクトルを別の点に移動させるとき、座標を変えないだけでよい。これが「平行移動」である。しかし曲がった空間では、座標を変えないだけではベクトルが「歪んで」しまう。これを補正するために必要な情報が、クリストッフェル記号である。

本ケーススタディの第 8 章で言及された「クリストッフェル補正」は、まさにこの役割を果たしている。最適制御の計算で多様体の曲率を考慮しないと、「空間が平坦であるかのように」最適経路が計算されてしまい、実際の経営環境の構造に逆らう不自然な処方となる。

6.3 ハミルトン形式

本節では、最適制御理論の数学的基盤となるハミルトン形式 (Hamiltonian formulation) を導入する。

ニュートン形式とハミルトン形式

古典力学には、二つの主要な定式化がある。

- ニュートン形式—$F = ma$(力 = 質量 × 加速度)。位置 q とその二階微分 (加速度) を扱う
- ハミルトン形式—位置 q と運動量 p を独立した変数として扱い、ハミルトニアン $H(q, p)$ を導入する

ハミルトン形式の利点は、位置と運動量を対称的に扱える点、そして数値積分の安定性を保証するシンプレクティック構造 (後述) を持つ点である。本ケーススタディの長期シミュレーションでは、ハミルトン形式が必須である。

ハミルトンの正準方程式

ハミルトニアン $H(q,p)$ が与えられたとき、系の時間発展は以下の正準方程式に従う。

$$\frac{dq}{dt} = \frac{\partial H}{\partial p}, \qquad \frac{dp}{dt} = -\frac{\partial H}{\partial q}$$

二つの方程式は対称的な構造を持ち、これがシンプレクティック構造の基本である。

6.4 ポントリャーギンの最大値原理

ポントリャーギンの最大値原理 (Pontryagin's Maximum Principle, PMP) は、1956 年にレフ・ポントリャーギンらによって定式化された、最適制御理論の中核となる定理である。本ケーススタディでは、危機対応プランの最適化に直接適用された。

解く問題

最大値原理が解く問題は、以下のような最適制御問題である。

1. 初期状態 $z(0)$ と目標状態 $z(T)$ が与えられている
2. 使える制御入力 $u(t)$ の集合 (本ケースでは経営施策の組み合わせ) が指定されている
3. 制御 $u(t)$ が決まると、状態の進化は微分方程式 $dz/dt = f(z,u,t)$ で決まる
4. 各時点でのコスト関数 $L(z,u,t)$ と終端ペナルティ $\Phi(z(T))$ が与えられている
5. 総コスト $J = \int_0^T L\,dt + \Phi(z(T))$ を最小化する制御 $u^*(t)$ と最適経路 $z^*(t)$ を求めよ

最大値原理の貢献

最大値原理が偉大なのは、この最適化問題を「ハミルトニアン $H(z,p,u)$ を時間ごとに最大化する u を選ぶ」という、より単純な問題に帰着させた点にある。具体的には、ハミルトニアンは以下のように定義される。

$$H(z,p,u,t) = -L(z,u,t) + p^T f(z,u,t)$$

ここで $p(t)$ は随伴変数 (co-state、または共役変数) と呼ばれ、各状態次元の「影の価格」に相当する量である。$p(t)$ は以下の随伴方程式で時間発展する。

$$\frac{dp}{dt} = -\frac{\partial H}{\partial z}$$

そして最適制御 $u^*(t)$ は、各時刻でハミルトニアン $H(z, p, u, t)$ を最大化するように選ばれる。

$$u^*(t) = \arg\max_u H(z(t), p(t), u, t)$$

Neural ODE の adjoint 法との関係

現代の機械学習における重要な発見として、Neural ODE(Chen et al., 2018) で使われる随伴法 (adjoint method) が、ポントリャーギンの最大値原理の随伴方程式と数学的に同型である、という事実がある。

これにより、伝統的に困難だった最適制御問題を、現代の機械学習フレームワーク (PyTorch の autograd と torchdiffeq) で効率的に解けるようになった。本ケーススタディの危機対応プラン計算は、この技術的進歩を活用している。

曲がった多様体での最大値原理

ジオメトリック・インテリジェンス理論で最大値原理を適用する際、経営環境が多様体であることを考慮した補正が必要である。具体的には、ダイナミクス dz/dt にクリストッフェル記号による補正項が加わる。

この補正がない場合、最適経路は「空間が平坦である」と仮定して計算され、実際には実行不可能、あるいは経営環境の自然な曲率に逆らう不自然な処方となる。本ケーススタディで「ベトナム工場危機への 90 日プラン」が直感に反するスケジュール—ブランド防衛が先、生産復旧が後—を提示したのは、まさにこのクリストッフェル補正による多様体上の真の測地線が、平坦空間での最短経路と異なることを反映している。

6.5 シンプレクティック構造

本ケーススタディの第 9 章で言及された「シンプレクティック幾何」は、長期シミュレーションの数値的安定性を保証するための数学的枠組みである。

シンプレクティック形式

シンプレクティック形式 ω は、位相空間 (状態 q と運動量 p の組み合わせ空間) に定義される反対称双線形形式である。標準的な形式は、以下のように書ける。

$$\omega = \sum_i dp_i \wedge dq_i$$

ここで $\wedge$(ウェッジ積) は、外積形式の積である。シンプレクティック形式の物理的解釈は、「位相空間の体積要素」を測る道具である。

リューヴィルの定理

リューヴィルの定理 (Liouville's theorem) は、ハミルトン系の時間発展がシンプレクティック形式 ω を厳密に保存することを述べる定理である。すなわち、位相空間の体積はハミルトン的な時間発展の下で不変である。

経営の文脈に翻訳すると、企業価値とその変化率の組み合わせ空間に内在する「保存量」を、シンプレクティック構造が表現している。リューヴィルの定理は、長期シミュレーションがこの保存量を破壊しないことを要求する。

シンプレクティック積分器

標準的な数値積分法 (オイラー法、ルンゲ・クッタ法など) は、各ステップで小さな数値誤差を生む。これらは時間経過とともに蓄積し、長期シミュレーションでは「エネルギーのドリフト」として現れる。経営の言葉では、シミュレーションが進むにつれて企業価値が物理的根拠なく勝手に増減してしまう、という現象である。

シンプレクティック積分器 (symplectic integrator) は、シンプレクティック形式を厳密に保存する数値積分手法である。最も基本的なものはシンプレクティック・オイラー法であり、より精度の高いものとしてシュテルマー = ヴェルレ法 (Störmer-Verlet method) がある。本ケーススタディの 5 年軌道シミュレーションでは、後者が採用された (詳細は 01_casestudy_GI_theory_mapping の第 8 章および第 9 章を参照)。

シュテルマー = ヴェルレ法の構造

シュテルマー = ヴェルレ法は、各ステップで以下の三段階の対称的な構造を持つ。

1. 運動量 p を半ステップ進める (クリストッフェル補正付き)
2. 位置 q を 1 ステップ進める

3. 運動量 p を残りの半ステップ進める

この対称的構造により、シンプレクティック形式が機械精度で保存される。本編で報告された「60 ヶ月のシミュレーション後でも企業価値が 10^{-8} オーダーの精度で保存」という結果は、シュテルマー = ヴェルレ法のこの性質に基づく。

次章では、別の幾何学的視点—位相幾何学 (トポロジー) とその応用—を扱う。

第 7 章　位相幾何学とその応用

本章では、位相幾何学 (トポロジー) の入門と、本ケーススタディで活用された応用—パーシステント・ホモロジー、層理論、手術理論—を扱う。これらは前章までの微分幾何学とは異なる視点で多様体やデータの構造を捉える道具であり、本ケーススタディで「微分幾何学的アプローチでは見えない構造」を抽出するために重要な役割を果たした。

7.1　位相同型と位相不変量

位相幾何学 (topology) は、図形の「形」を、連続的な変形 (伸縮、曲げ) では変わらないが、切ったり貼ったりすると変わる性質として捉える数学である。

コーヒーカップとドーナツの例

位相幾何学の有名な例えとして、「コーヒーカップとドーナツは同じ形」というものがある。両者とも穴が一つあり、粘土細工のように連続的に変形すれば、互いに移すことができる。これらは位相同型 (homeomorphic) であり、位相幾何学の観点では同じ図形である。

一方、ドーナツと球は位相的に異なる。球には穴がなく、ドーナツには一つの穴がある。連続的な変形では穴の数を変えられないため、両者は位相同型ではない。

位相不変量

位相不変量 (topological invariant) とは、連続的な変形では変わらない量である。本書で扱う重要な位相不変量は以下である。

- 連結成分の数—その図形は何個に分かれているか
- 穴の数 (一次元) —その図形にはいくつの「穴」(ループ) があるか
- 空洞の数 (二次元) —その図形には球の内部のような「空洞」がいくつあるか

これらは数学的には「ホモロジー群」(homology group) の階数 (rank) として厳密に定義される。

7.2　連結成分・ホモロジーの初歩

ホモロジー群

ホモロジー群は、図形の位相的構造を代数的 (群論的) に記述する道具である。本書では厳密な定義は避け、各次元のホモロジー群が捉える情報のみを述べる。

- 0 次ホモロジー H_0 —連結成分の数 (その図形がいくつのピースに分かれているか)
- 1 次ホモロジー H_1 ——次元の独立した「穴」の数 (ループの数)
- 2 次ホモロジー H_2 —二次元の独立した「空洞」の数
- 一般に k 次ホモロジー H_k —k 次元の独立した位相的特徴の数

球面 S^2 のホモロジー群は $H_0 = 1$(連結成分 1 個)、$H_1 = 0$(穴なし)、$H_2 = 1$(空洞 1 個) である。トーラス (ドーナツ表面) では $H_0 = 1$、$H_1 = 2$(2 つの独立したループ)、$H_2 = 1$ となる。

コホモロジー

ホモロジーと密接に関連する概念として、コホモロジー (cohomology) がある。本書では詳細には立ち入らないが、本ケーススタディの第 6 章「規制の津波」で言及された「非自明な第一コホモロジー類」という表現は、ある種の位相的障害の存在を示す代数的な量に対応する。詳細は専門書 (付録 B 参照) に譲る。

7.3 パーシステント・ホモロジー

パーシステント・ホモロジー (persistent homology) は、近年急速に発展している位相的データ解析 (Topological Data Analysis, TDA) の中核技術である。本ケーススタディでは、第 7 章でメゾン・オロールによる隠れた所有構造の検出に活用された。

基本的な発想

離散的な点群データに対して、そのままではホモロジーは自明である (各点が独立した連結成分になり、穴も空洞もない)。これを意味のある形で扱うのがパーシステント・ホモロジーである。

アイデアは次のとおりである。各データ点を中心とする半径 ε の球を考え、ε を 0 から大きくしていく。

1. ε が小さいうちは、球同士が交わらず、各点が独立した連結成分
2. ε が大きくなると、球同士が交わり、点が結ばれてグラフ構造ができる (連結成分の数が減る)
3. さらに大きくなると、ループや空洞が現れたり消えたりする

パーシステント・ホモロジーは、各位相的特徴が「どの ε で生まれて、どの ε で消えるか」を記録する。長く存続する (persistent な) 特徴は、データの本質的な位相構造を反映していると判断される。短命な特徴は、ノイズと判定される。

バーコード表示

パーシステント・ホモロジーの結果は、しばしばバーコード (barcode) または永続化図 (persistence diagram) として可視化される。各位相的特徴を「生まれた ε」と「消えた ε」の区間として表示し、長い区間は本質的な特徴、短い区間はノイズとして区別する。

本ケースでの応用

本ケーススタディの第 7 章で、リンが綾鳥株式の持株蓄積パターン (日次の購入量、デリバティブポジション、ブローカーの身元を組み合わせた高次元時系列) に TDA を適用した。

ripser ライブラリを使ったパーシステント・ホモロジー計算の結果は、以下の特徴を示した (詳細は 01_casestudy_GI_theory_mapping の第 9 章参照)。

- H_0(連結成分) —4 個の購入活動クラスター
- H_1(ループ) —1 個の持続的なループ

解釈: 4 個の連結成分が一つのループでつながった構造は、多層シェル会社 (実質的支配者を隠蔽するための循環的所有構造) の典型的な位相的シグネチャである。これは単純な統計分析 (平均、相関係数など) では検出不可能な特徴であり、データの「形 (位相)」を見ることで初めて見えてくる構造である。

7.4 層理論 (Sheaf Theory)

層理論 (sheaf theory) は、空間の各局所領域に「データ」を割り当て、それらの局所データが大域的に整合しているかを判定する数学である。本ケーススタディの第 5 章 (偽造品検知) と第 8 章 (内部脅威検知) で活用された。

層の直感的概念

「層」という用語は、農業の「束」や「層」のイメージから来ている。空間 X(本ケースではサプライチェーンのグラフなど) の各点・各部分集合に、「その局所での束のようなデータ」を割り当てる仕組みである。

層には二つの重要な操作が組み込まれている。

- 制限 (restriction) —大きい部分集合のデータから、小さい部分集合のデータへ整合的に絞り込む
- 貼り合わせ (gluing) —局所的に整合するデータが、大域的なデータとして一意に組み合わさる

「整合性チェック」とは、与えられたデータが本当にこの層の構造を満たすか、すなわち局所同士の貼り合わせで矛盾が生じないか、を検査することである。

セル層と層ラプラシアン

本ケースで用いられたのは、グラフ構造の上に定義される「セル層 (cellular sheaf)」と、その整合性を測定する「層ラプラシアン (sheaf Laplacian)」である。

本書の想定読者向けの直感的な理解として、第 2 章で復習したグラフラプラシアン $L = D - A$ を一般化したものとして、層ラプラシアンを捉えることができる。

グラフラプラシアンは「ノード間でスカラー値の不整合がどれだけあるか」を測定する。具体的には、x がノード上のスカラー値ベクトルなら、$x^T Lx$ は隣接ノード間での値の差の二乗和に対応する。

層ラプラシアンは、これを多次元データに拡張する。各ノードがスカラー値ではなくベクトル空間 (層に割り当てられたデータ) を持ち、各辺に「制限写像」が定義される。層ラプラシアンは、これら制限写像を通じた不整合を測定する対称行列である。

整合性スコアの計算

計算手順は単純である。

1. 対象データを層構造に組み込む
2. 層ラプラシアン L を計算する
3. $L \cdot x$ を計算する (x はデータベクトル)
4. $\|L \cdot x\|$(または $x^T Lx$) が小さければ整合的、大きければ不整合

本ケースでの応用例

本ケーススタディでは、層理論が二つの異なる場面で活用された (詳細は 01_casestudy_GI_theory_mapping の第 9 章参照)。

- 偽造品検知—サプライチェーンを層構造として表現し、製造記録・出荷マニフェスト・小売在庫・顧客レビューの整合性を検査
- 内部脅威検知—バッジアクセスログ、ファイルアクセスログ、時間パターン、ネットワーク位置の四つのデータソースを層として束ね、複数ソース間の整合性を検査

層理論の力は、各データソース単独では正常に見える行動でも、複数ソース間の整合性を見ることで異常を検出できる点にある。これは点ごとのチェックでは見逃される全体的な不整合を捉える数学的道具である。

7.5　手術理論とコボルディズム

手術理論 (surgery theory) は、多様体の位相を制御された方法で変化させる数学的フレームワークである。M&A や事業再編といった、企業の構造そのものを変える施策のモデル化に応用される。本ケーススタディでは第 6 章「規制の津波」で活用された。

通常の幾何学的変形との違い

前章までで扱った微分幾何学的な変形—計量テンソルの変化、リー微分による変形—は、多様体の位相は保ったまま「形を変える」操作であった。これらは多様体の連続的変形であり、穴の数や連結成分の数は変わらない。

手術理論は、これとは異なる種類の変形を扱う。「切除」と「接着」によって、多様体の位相そのものを意図的に変える操作である。これは経営の文脈では、「現在のサプライチェーン構造のままでは解けない問題を、構造そのものを変えることで解く」という発想に対応する。

手術の二段階

手術は、以下の二段階で進行する。

1. 切除 (excision) —問題のある領域を多様体から取り除く
2. 接着 (gluing) —切除した領域の代わりに、より良い位相を持つ領域を接着する

本ケーススタディの第 6 章では、新疆に隣接する仲介業者を経由するサプライチェーンパス (新疆関連の問題ある領域) を切除し、エジプト・インド・米国の透明な代替調達網 (より良い位相を持つ領域) を接着する、という具体的な手術が実行された。

コボルディズム条件

手術理論で重要なのは、切除と接着が「コボルディズム条件」を満たすことである。

コボルディズム (cobordism) とは、二つの多様体が同じ境界を持つ高次元多様体で繋がれる関係のことを言う。手術における「切除した領域の境界条件と、接着する領域の境界条件が、適切に一致していなければならない」という制約が、このコボルディズム条件である。

ビジネスの言葉に翻訳すると、代替サプライヤーは取り除かれた仲介業者と同じ素材仕様 (繊維長、引張強度、染色堅牢度など) を提供しなければならない、という制約条件となる。本編では、エジプト綿 (29mm)、インド綿 (30mm)、米国ピマ綿 (34mm) が、取り除かれた仲介業者の供給する繊維 (28-32mm) と十分一致することが、コボルディズム条件の検証として確認された。

位相的障害の解消

手術が成功すると、変更後の多様体は元の多様体とは位相的に異なる。本ケースでは、「DPP 規制 (透明性) とエンティティ・リスト (可視性のリスク) が両立しない」という構造的矛盾 (非自明な第一コホモロジー類) が、手術後には解消される。これにより、標準的な測地線制御で航行可能な構造へと変わる。

次章では、本ケーススタディに登場した個別の重要定理—ホイットニーの拡張定理、リューヴィルの定理、ゲージ不変性—を扱う。

第 8 章　本ケーススタディに登場した定理

本章では、本ケーススタディの個別の重要定理を扱う。これらは、これまでの章で扱った概念を背景としながら、特定の数学的主張として独立に重要な役割を果たす定理群である。

8.1　ホイットニーの拡張定理

ホイットニーの拡張定理 (Whitney 1934) は、本ケーススタディの第 2 章「壁」(2026 年 9 月後半) で、Neural ODE による失われたデータの補間を理論的に正当化する根拠として活用された。

定理のステートメント

本書の方針として、厳密な数学的ステートメントは脚注扱いとし、直感的な意味を中心に説明する。

ホイットニーの拡張定理の基本的な主張は、おおよそ以下のとおりである。$\mathbb{R}^n$ の閉部分集合 A 上に、関数値 $f(x)$ と各階の偏微分の値が与えられているとする。これらの値が「ホイットニー条件」と呼ばれる整合性条件—A の各点周りでテイラー展開した値が、隣接する点での値と高次の項まで矛盾なく繋がること—を満たすならば、$\mathbb{R}^n$ 全体に C^k 級 (k 階まで連続微分可能) の関数 F が存在し、A 上では F の各階偏微分が与えられた値と一致する。

k を ∞ と取れば C^∞ 級 (無限回微分可能) の拡張が、有限値で取れば C^k 級の拡張が得られる。本ケーススタディで必要とされるのは $k \geq 3$ 程度であり、これは曲率テンソル計算で必要となる計量の二階微分が連続であることを保証するためである。

通常の補間問題との違い

機械学習エンジニアにとって馴染みのある補間問題と比較しておく。

- 線形補間—二点を直線で繋ぐ。C^0 級 (連続だが微分不連続な可能性あり)
- スプライン補間—三次スプラインなどで C^2 級の繋がりを保証
- ガウス過程回帰—滑らかなカーネルを選べば C^∞ 級の補間を確率的に推定

ホイットニーの拡張定理が他の補間と異なる特徴は、以下である。

1. 関数値だけでなく微分値も指定できる (あるいは指定する必要がある)
2. 整合性条件を満たせば C^∞ 級の拡張が「構成的に」存在することが保証される
3. 拡張する領域は閉集合 A の周辺だけでなく、$\mathbb{R}^n$ 全体まで広げられる

Neural ODE との接続

本ケーススタディでは、データに欠損がある (2020 年 3 月など、COVID 期の遷移期間データが極めて少ない) 状況で、Neural ODE による軌道補間が行われた。これが「データの捏造」ではなく「失われた滑らかな軌道の復元」と位置づけられる根拠が、ホイットニーの拡張定理にある。

ただし、定理の適用には「データがホイットニー条件を近似的に満たす」という仮定が必要である。現実の経営データで以下のような状況では、この仮定が満たされない。

- 不連続なレジームシフト—規制発効による瞬間的な需要変化、戦争勃発による急変など、関数値そのものがジャンプする場合
- 微分不能だが連続な変化—需要曲線の屈折点、価格戦略の方針転換など、関数は連続だが微分が不連続な場合

本ケースでは、各遷移期の境界点が完全な不連続ではなく「急速だが連続的」であると仮定し、Neural ODE による補間を行い、補間後の VAE が命題 1.1 の三条件を満たすかで仮定を事後的に検証する、という現実的なアプローチが採用された。

8.2 リューヴィルの定理

リューヴィルの定理 (Liouville's theorem) は、ハミルトン力学系の時間発展がシンプレクティック構造を厳密に保存することを述べる定理である。第 6 章で導入した内容を、本節で改めて定理として位置づける。

定理の内容

リューヴィルの定理: ハミルトニアン $H(q, p, t)$ によって支配される系の時間発展は、位相空間における体積要素を保存する。

数学的には、シンプレクティック形式 $\omega = \sum_i dp_i \wedge dq_i$ が、ハミルトン的時間発展の下で不変であるという主張である。

経営の文脈での解釈

経営環境多様体において、状態 z と運動量 (変化率)p の組み合わせ空間に内在する「保存量」を、シンプレクティック形式が表現している。リューヴィルの定理は、この保存量が長期にわたって維持されることを保証する。

本ケーススタディの 5 年軌道シミュレーション (60 ヶ月) では、シンプレクティック積分器 (シュテルマー = ヴェルレ法) を使うことで、リューヴィルの定理が数値計算上も (ほぼ) 厳密に保たれる。これに

より、シミュレーション結果が真の物理 (経営力学) から大きく逸脱しないことが保証される。

通常の数値積分法での問題

通常のオイラー法やルンゲ・クッタ法は、リューヴィルの定理を保存しない。これらの手法では、各ステップで小さな数値誤差が生じ、累積するとシンプレクティック形式が破壊される。経営の言葉では、「企業価値が物理的根拠なくモデル内で勝手に増減する」という現象が起きる。

60 ヶ月の月次ステップで標準的な手法を使うと、累積誤差により予測値が真の値から大きく逸脱する。シンプレクティック積分器を使うことで、この問題が原理的に解決される。本編で報告された $\Delta H/H = 3.21 \times 10^{-8}$ という保存性能は、シュテルマー = ヴェルレ法によりリューヴィルの定理がほぼ機械精度で実現されていることを示す。

8.3 ゲージ不変性の幾何学

ゲージ不変性 (gauge invariance) は、物理学 (特に電磁気学・素粒子物理学) で重要な概念だが、本ケーススタディでは異なる文脈で活用された。第 8 章「内なる敵」(2027 年 4 月) で、データ漏洩への対策として「敵対者の盗んだデータを無効化する」道具として用いられた。

ゲージ変換の基本概念

ゲージ変換とは、座標系の取り方を変える変換であり、物理的に意味のある量 (曲率、距離など) はこの変換で不変であることが要求される。これがゲージ不変性である。

リーマン幾何学の枠組みでは、座標系の選び方を変えても、曲率テンソルやリッチテンソル、スカラー曲率といった「内在的な量」は不変である。これは曲率が多様体の本質的な幾何構造を反映している以上、座標系の選び方に依存してはならないからである。

正則直交変換による不変性

本ケースで活用されたのは、特に正則直交変換 (orthogonal transformation) による不変性である。

n 次元ユークリッド空間において、$n \times n$ 直交行列 $R(R^T R = I$ を満たす行列) による変換 $z \mapsto Rz$ は、ベクトルの長さや角度を保つ変換である。リーマン幾何学では、計量テンソルが正定値対称行列であることから、適切な座標変換により対角化 (直交変換による単純化) が可能である。

重要なのは、計量テンソル・曲率テンソル・リー微分・リー括弧といった、本ケーススタディで使われるすべての幾何学的量が、この種の変換で不変である (あるいは、変換に応じて適切に共変的に変換される) という事実である。

本ケースでの応用—防御的ゲージ変換

本編第 8 章で、メリディアン社のシステムが APT 攻撃を受け、綾鳥多様体の非機密ビジュアライゼーション草案が漏洩した。地形の大まかな形—山と谷の位相、特異点の概略位置—が敵対者に渡った状況である。

対策として採用されたのが、ゲージ変換による多様体の「再ランダム化」である。具体的な実装は以下のとおりである (詳細は 01_casestudy_GI_theory_mapping の第 9 章参照)。

1. ランダムな 8×8 直交行列 R を生成
2. VAE エンコーダの出力 z を、$z' = Rz$ に変換
3. VAE デコーダの入力 z' に対しては、R^T で逆回転してから元のデコーダに渡す

これにより、外部に見える潜在空間表現は完全に変わるが、内部のすべての幾何学的計算—計量、曲率、リー微分、最適制御—は不変に保たれる。これは、リーマン幾何の根本性質「正則直交変換のもとで全テンソル量が不変」に基づく。

運用ルールとして、リームのチームは「48 時間ごとに座標系を回転させる」方式を採用した。敵対者が漏洩データから多様体構造を再構築しようとしても、48 時間以内に座標系が変わるため、再構築が完了する前に情報価値が失われる。

次章では、本ケーススタディの最終分野—確率・統計・機械学習に関する数学 (MC ドロップアウト、SHAP、DML、ZKML、形式検証) —を扱う。

第 9 章　確率・統計・機械学習の数学

本章では、本ケーススタディで使われた確率論・統計学・機械学習関連の数学概念を扱う。これらは前章までの幾何学とは性格が異なり、機械学習エンジニアにはより馴染みのある領域である。本書では、特に「信頼性の 5 本の柱」(MC ドロップアウト、SHAP、DML、ZKML、形式検証) の数学的基礎を順に解説する。

9.1　ベイズ推論の最小限

本ケーススタディの第 6 章で MC ドロップアウト、第 9 章で ZKML が扱われるが、これらの数学的基礎にあるのがベイズ推論である。本節で、その最小限を整理する。

ベイズの定理 (再掲)

第 2 章で復習したとおり、ベイズの定理は条件付き確率の関係を表す基本式である。

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

ベイズ推論の文脈では、A をモデルパラメータ θ、B を観測データ D と読み替える。

$$P(\theta|D) = \frac{P(D|\theta) \cdot P(\theta)}{P(D)}$$

この式の各項には固有の名前が付いている。

- $P(\theta)$ —事前分布 (prior)。データを見る前のパラメータについての信念
- $P(D|\theta)$ —尤度 (likelihood)。パラメータが θ の場合、データ D が観測される確率
- $P(\theta|D)$ —事後分布 (posterior)。データを見た後のパラメータについての信念
- $P(D)$ —エビデンス (evidence)。正規化定数の役割

ベイズニューラルネットワーク

通常のニューラルネットワークは、各重みに単一の値 (点推定) を学習する。これに対し、ベイズニューラルネットワーク (BNN) は、各重みに確率分布を学習する。これにより、予測値だけでなく、その予測の不確実性も同時に得られる。

しかし、BNN の事後分布 $P(\theta|D)$ を厳密に計算することは、現実のニューラルネットワーク (数百万〜数十億のパラメータ) では計算量的に不可能である。実用には何らかの近似が必要となる。

9.2 MC ドロップアウトの数学的基礎

MC ドロップアウト (Monte Carlo Dropout) は、Gal & Ghahramani(2016) によって提案された、ベイズニューラルネットワークの近似実装である。

通常のドロップアウト

本書の想定読者にとって、ドロップアウトは過学習を防ぐ正則化手法として馴染みがある。訓練時にニューロンの一部をランダムに無効化し、ネットワークが特定の入力パターンに過度に依存するのを防ぐ手法である。

通常の運用では、ドロップアウトは訓練時のみ有効化し、推論時には全ニューロンを有効にして決定論的な予測を行う。

MC ドロップアウトの発想

MC ドロップアウトは、推論時にもドロップアウトを有効化するという、シンプルだが強力な発想である。同じ入力に対して T 回 (典型的には $T = 100$〜200) 推論を行うと、ドロップアウトのランダムマスクが毎回異なるため、T 個の異なる出力が得られる。

この T 個の出力から、以下の量が計算できる。

- 出力の平均—最良予測値 (点推定)
- 出力の標準偏差—不確実性の指標
- 出力の分位点—信頼区間

理論的正当化

Gal & Ghahramani の論文の主要貢献は、このランダムマスク集合がベイズニューラルネットワークの変分近似事後分布に対応し、推論時のドロップアウト付きサンプリングがモンテカルロ変分推論に相当することを示した点である。

厳密な数学的証明は本書のスコープを超えるが、要点は次のとおりである。ドロップアウトを適用したニューラルネットワークは、各重みに「ベルヌーイ分布のスケール」を持つ確率モデルとみなせる。この確率モデルの事後分布を、KL ダイバージェンスを最小化する変分近似で求めると、それが推論時ドロップアウトのサンプリングと一致する。

キャリブレーション

MC ドロップアウトの実用上重要な性質が、キャリブレーション (calibration) である。「過去に 95% 信頼区間を付して行った予測のうち、実際に真の値が信頼区間内に入っていた割合」を測定する指標である。

理想的には、95% 信頼区間で約 95% のキャリブレーションが得られるべきである。本ケーススタディで報告された 93.2% という値は、目標の許容範囲内であり、提示される信頼区間が単なる名目上のものではなく、実際に予測の不確実性を正しく表現していることを示している (詳細は 01_casestudy_GI_theory_mapping の第 6 章参照)。

9.3 シャープレイ値と SHAP

SHAP(SHapley Additive exPlanations、Lundberg & Lee 2017) は、機械学習モデルの個別予測について「各特徴量がその予測値にどれだけ寄与したか」を、シャープレイ値に基づいて算出する手法である。本ケーススタディでは、第 5 章で偽造品危機におけるブランド低下の要因分解に活用された。

シャープレイ値の起源

シャープレイ値 (Shapley value) は、Lloyd Shapley が 1953 年に提案した、協力ゲーム理論における中核概念である。「複数のプレイヤーが協力して得た成果を、各プレイヤーの貢献度に応じて公平に分配する方法」を、数学的に一意に定める。

n 人のプレイヤーが集団 S を構成して得る成果を $v(S)$ と書く。プレイヤー i のシャープレイ値 φ_i は、以下のように定義される。

$$\varphi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! \cdot (n - |S| - 1)!}{n!} \left[v(S \cup \{i\}) - v(S) \right]$$

ここで和は i を含まないすべての部分集合 S にわたる。直感的には、「プレイヤー i がいる場合といない場合の成果の差 (限界貢献)」を、すべての可能な参加順序について平均したものである。

SHAP への応用

SHAP は、シャープレイ値を機械学習に応用したものである。各特徴量を「プレイヤー」、予測値を「ゲームの賞金」と見立てることで、各特徴量の予測への寄与度を一意に決定する。

SHAP 値が満たす重要な性質は以下である。

- 加算性—すべての特徴量の SHAP 値の和が、ベースライン予測からの差と等しい

- 公平性—同じ役割を果たす特徴量は同じ SHAP 値を持つ
- 局所的正確性—モデルの個別予測について、SHAP 値が正確に予測値を分解する

計算量

厳密なシャープレイ値の計算は、n 個の特徴量に対して 2^n 個の部分集合を考える必要があり、計算量的に厳しい。実用には、各種の近似アルゴリズムが使われる。例えば、TreeSHAP(決定木モデル向けの効率的アルゴリズム)、KernelSHAP(モデル非依存の近似アルゴリズム) などである。

解釈の限界

SHAP は強力な説明可能性ツールだが、その解釈には注意が必要である。SHAP は「現在の予測値の中で、どの特徴量が貢献しているか」を答える。これは相関ベースの説明であり、「ある特徴量を介入で変化させたら、予測値がどう変わるか」という因果関係を答えるものではない。

因果関係を扱うには、別の枠組み—二重機械学習 (DML) など—が必要となる。これが次節の主題である。

9.4 二重機械学習 (DML) の直交化

二重機械学習 (Double Machine Learning, DML、Chernozhukov et al. 2018) は、観察データから因果効果を推定するための統計的手法である。本ケーススタディでは、SHAP と組み合わせて、偽造品の株価への因果効果の推定に活用された。

解く問題

DML が解く問題は、以下のような因果推論問題である。

観測データ $\{(Y_i, D_i, X_i)\}$ があるとする。Y は結果変数 (株価)、D は処置変数 (偽造品頻度)、X は交絡因子の候補となる多数の共変量 (規制環境、市場センチメントなど) である。「D が Y に与える因果効果」を推定したい。

ナイーブな線形回帰 $Y \sim D + X$ では、X に含まれない交絡因子があると、推定値にバイアスが生じる可能性がある。DML は、機械学習を用いて X による影響を精緻に統制することで、このバイアスを除去する手法である。

直交化の発想

DML の中核は「直交化 (orthogonalization)」と呼ばれるテクニックである。基本的なアイデアは以下のとおりである。

1. X から Y を予測する機械学習モデル $m(X)$ を訓練する
2. X から D を予測する機械学習モデル $\ell(X)$ を訓練する
3. 「残差」$Y - m(X)$ と $D - \ell(X)$ を計算する
4. 残差同士で線形回帰を行い、その係数を因果効果として推定する

この手順により、X による「説明できる」部分が両方の変数から除去され、残った部分での関係が因果効果として現れる。直交化が効果を発揮するためには、機械学習モデル m, ℓ が十分柔軟で、X と Y/D の関係を非線形まで含めて捉える必要がある。

交差適合 (Cross-Fitting)

もう一つの DML の中核技術が、交差適合 (cross-fitting) である。データを K 個のフォールドに分割し、各フォールドの予測値を別のフォールドで訓練したモデルから得る、というクロスバリデーション風の手順である。

これは、機械学習モデルの過学習による偏りを除去するための工夫である。同じデータでモデルを訓練し予測すると、過学習により残差が小さくなりすぎ、因果効果の推定にバイアスが生じる可能性がある。交差適合により、この問題が回避される。

SHAP との組み合わせ

本ケーススタディの第 5 章で、SHAP と DML が組み合わせて活用された。SHAP は「現在の予測値の中で偽造品が支配的な相関要因」を示し、DML は「偽造品の減少が株価回復の因果要因である」ことを示した。両者が一致したことで、「偽造品対策を最優先せよ」という提言に強い確信が持てた (詳細は 01_casestudy_GI_theory_mapping の第 7 章参照)。

SHAP と DML が乖離する場合は、相関ベースの説明と因果関係に乖離があることを示し、施策決定の判断に追加的な検討が必要であることを示唆する。両者の組み合わせが、施策提言の質を高める。

9.5 ゼロ知識証明—ZKML の数学的基礎

ZKML(Zero-Knowledge Machine Learning) は、ゼロ知識証明 (Zero-Knowledge Proof, ZKP) を機械学習に適用する技術である。本ケーススタディの第 10 章で、14 体エージェントの計算過程の暗号学的保証として活用された。

ゼロ知識証明とは

ゼロ知識証明は、Goldwasser, Micali, Rackoff(1985) が導入した、暗号学・計算量理論の基本概念である。証明者 (prover) が検証者 (verifier) に対し、ある主張が正しいことを納得させるが、その主張の内容以外の情報は一切伝えない、という相互作用プロトコルである。

ゼロ知識証明には、以下の三つの性質が要求される。

- 完全性 (completeness) ―主張が正しいなら、検証者は必ず納得できる
- 健全性 (soundness) ―主張が誤りなら、検証者はほぼ確実に検出できる
- 零知識性 (zero-knowledge) ―検証者は、主張の真偽以外の情報を一切得られない

古典的な例―洞窟のパラドックス

ゼロ知識証明の直感的な例として、Quisquater らによる「洞窟のパラドックス」がある。

ある洞窟は、円形の通路で構成されており、途中に扉がある。扉は秘密の合言葉でしか開かない。証明者 P は、検証者 V に「合言葉を知っている」ことを、合言葉そのものを教えずに証明したい。

プロトコル: V は外で待ち、P が左右どちらかの通路を選んで奥へ進む。V が後から入ってきて「左から戻ってこい」あるいは「右から戻ってこい」と指示する。P は合言葉を知っているなら、V の指示通りに戻ってこれる。これを n 回繰り返すと、P が合言葉を知らないのに毎回正解する確率は $(1/2)^n$ となり、十分小さくなる。

重要なのは、V が観察できるのは「P が指示通りに戻ってくる」という事実だけであり、合言葉そのものは一切知ることができない点である。

ZKML への応用

ZKML は、ゼロ知識証明を「機械学習モデルの推論実行」に応用する。証明したい主張は、「指定された AI モデル M に入力 x を与えると、出力 y が得られる」というものである。証明者は、モデル M とその実行過程を完全には開示せずに、この主張の正しさを暗号学的に証明する。

本ケーススタディでは、ezkl というライブラリ (本編コードで言及) を使った実装が想定されている。一般的な手順は以下である。

1. デコーダを ONNX(Open Neural Network Exchange) 形式にエクスポート
2. ezkl により算術回路に変換
3. 証明を生成 (計算過程を暗号学的に証拠化)

4. クライアントが証明を検証—モデル内部の重みやデータを見ることなく、計算の正しさだけを確認できる

ZKML の限界

ZKML が保証するのは「計算過程に嘘がない」ことのみである。以下は保証しない。

1. パラメータが正当な訓練プロセスで得られたものか
2. 入力データが本物か (改竄された偽データではないか)
3. モデル選択の妥当性—モデルアーキテクチャがそもそも適切か

これらの保証には、別の防御層 (訓練ログのコミットメント、第三者監査など) が必要である。詳細は Vol.1 第 9 章を参照されたい。

9.6 形式検証の論理学的背景

形式検証 (formal verification) は、定理証明支援系や SMT ソルバーを用いて、ソフトウェアやアルゴリズムが特定の性質を満たすことを数学的に証明する技術である。本ケーススタディでは、第 10 章で 14 体 AI エージェントの本番稼働に先立ち、安全性性質の形式検証が実施された。

テストと形式検証の違い

「テスト」が「特定の入力に対して期待通りの出力が得られるか」を確認するのに対し、「形式検証」は「すべての可能な入力に対して、特定の性質が常に成立するか」を数学的に証明する。テストは確率的な品質保証だが、形式検証は決定的な品質保証である。

AI エージェントが自律的に意思決定を行う環境では、テストだけでは網羅的な検証が原理的に不可能である。本ケーススタディの 14 体エージェントは多様体上で同時に動作し、互いに通信し、複数の経営アクションを推奨する。これらの組み合わせから生じる予期せぬ挙動を、テストだけで検証することはできない。

論理学的基礎

形式検証の論理学的基礎は、命題論理・一階述語論理を超えた、より表現力の高い論理体系である。具体的には以下のような体系が使われる。

- 依存型理論 (dependent type theory) —Coq、Agda、Lean 4 などの定理証明支援系の基礎。型が値に依存できる、表現力の高い論理

- ホーア論理 (Hoare logic) —プログラム変数の事前条件・事後条件を扱う論理。プログラム検証の古典的枠組み
- モデル検査 (model checking) —有限状態系のすべての状態を網羅的に探索する手法
- SMT(Satisfiability Modulo Theories) —命題論理に算術・配列などの理論を組み込んだ論理。Z3 などのソルバーが使われる

使用されるツール

本ケーススタディで言及された形式検証ツールは以下である。

- Coq —依存型理論に基づく定理証明支援系。歴史的に最も広く使われた依存型システムの一つ
- Agda —同じく依存型理論ベース。Coq よりも数学的な表記に近い
- Z3 —Microsoft Research による SMT ソルバー。決定可能な範囲の論理式について自動で充足可能性を判定

証明されうる性質の例

本編で報告された、14 体エージェントについて形式的に検証された性質は以下である (本書の方針として、具体的な証明手順には踏み込まず、検証された主張の概要のみを記す)。

1. 単一の推奨が月あたりの企業価値を 5% 超低下させることはない
2. エージェント推奨の組み合わせが多様体の滑らかさを保存する
3. 機密データの区画がエージェント境界を越えてリークすることはない
4. ゲージ変換のローテーションスケジュールが暗号論的に健全である

これらは、テストでは網羅的に検証することが原理的に不可能な性質である。「いかなる入力の組み合わせでも」「いかなる多様体上の点でも」「いかなる時刻でも」これらの性質が成立することを、形式検証は数学的に保証する。

形式検証の数学的内容 (具体的な証明、Coq の戦術、Z3 のエンコーディングなど) は本書のスコープを超える。これらは Vol.1 第 9 章および専門書 (付録 B 参照) を参照されたい。

本書の本文は、ここで終わる。次に、本書で使った記号の一覧と、推奨参考文献を付録として掲載する。

付録 A　記号一覧

本書で使用した主要な記号を一覧する。本書では LaTeX による正式な数学組版で表現する方針をとっているため、添字の上下 (共変・反変) も適切に区別されているが、文脈によっては簡略化する場合がある。厳密な区別が必要な場合は、Vol.1 / Vol.2 を参照されたい。

A.1　基本的な数学記号

記号	意味
$\mathbb{R}^n$	n 次元ユークリッド空間
$\partial f/\partial x$	関数 f の x に関する偏微分
∇f	関数 f の勾配ベクトル
$v \cdot w$ または$\langle v, w \rangle$	ベクトル v と w の内積
$\lVert v \rVert$	ベクトル v のノルム (長さ)
A^T	行列 A の転置
A^{-1}	行列 A の逆行列
$\sum$	和の記号
$\int$	積分記号

A.2 多様体・幾何学的記号

記号	意味
M	多様体 (manifold)
z またはp	多様体上の点
T_pM	多様体 M の点 p における接空間
g_{ij}	計量テンソルの (i,j) 成分
$g(z) = J(z)^T J(z)$	引き戻し計量 (VAE デコーダによる構成)
$J(z)$	点 z における関数のヤコビ行列
Γ_{ij}^k	クリストッフェル記号
R_{ijk}^l	リーマン曲率テンソル
R_{ij}	リッチテンソル
R またはScal	スカラー曲率

A.3 ベクトル場とリー微分

記号	意味
X, Y, V	多様体上のベクトル場
$X(p)$ または$X(z)$	ベクトル場 X の点 p (または z) における値
$\mathcal{L}_X f$	関数 f のベクトル場 X に沿ったリー微分
$\mathcal{L}_X g$	計量テンソル g のベクトル場 X に沿ったリー微分
$[X, Y]$	ベクトル場 X と Y のリー括弧
$c(t)$	多様体上の曲線 (時間 t をパラメータとする)
$c'(t)$ またはdc/dt	曲線 c の接ベクトル

A.4 最適制御・力学系

記号	意味
$z(t)$ または$q(t)$	時刻 t における系の状態
$u(t)$	時刻 t における制御入力
$p(t)$	随伴変数 (co-state)、または運動量
$H(z, p, u, t)$	ハミルトニアン
$L(z, u, t)$	コスト関数
$\Phi(z(T))$	終端ペナルティ
ω	シンプレクティック形式

A.5 確率・統計

記号	意味
$\mathbb{E}[X]$	確率変数 X の期待値
$\mathrm{Var}(X)$	確率変数 X の分散
σ	標準偏差
$P(A\|B)$	B が起きた条件の下での A の条件付き確率
$P(\theta\|D)$	データ D を観測した後のパラメータ θ の事後分布
$P(D\|\theta)$	パラメータ θ の下でのデータ D の尤度
φ_i	プレイヤー i のシャープレイ値

付録 B　推奨参考文献

本書は本ケーススタディに登場した数学概念の入門的な解説に専念した。各概念の厳密な定義・定理の証明・より詳細な議論については、以下の参考文献を推奨する。

本書の方針として、私 (著者) が確実に内容を把握している標準的な参考文献のみを挙げる。各分野には他にも優れた教科書が多数存在するため、以下のリストは網羅的なものではなく、初学者に適した「入口」となる文献を厳選している。

B.1　微分幾何学・リーマン幾何学

本書の第 3 章〜第 6 章で扱った多様体・計量・曲率・測地線などの内容を、より厳密に学ぶための参考文献。

- M. P. do Carmo, *Riemannian Geometry*, Birkhäuser, 1992. リーマン幾何学の標準的な教科書。学部上級〜大学院初年級レベル
- J. M. Lee, *Introduction to Smooth Manifolds*, Springer, 2nd ed., 2013. 可微分多様体の入門として広く使われる教科書
- J. M. Lee, *Riemannian Manifolds: An Introduction to Curvature*, Springer, 1997. リーマン幾何学の入門書、上記の続編

B.2　最適制御・ハミルトン力学

第 6 章のポントリャーギンの最大値原理、ハミルトン形式、シンプレクティック構造に関する参考文献。

- D. Liberzon, *Calculus of Variations and Optimal Control Theory: A Concise Introduction*, Princeton University Press, 2012. ポントリャーギンの最大値原理を含む最適制御理論の簡潔な入門書
- V. I. Arnold, *Mathematical Methods of Classical Mechanics*, Springer, 2nd ed., 1989. 古典力学のシンプレクティック幾何による定式化の名著

B.3　位相幾何学

第 7 章の位相同型・ホモロジー・パーシステント・ホモロジーに関する参考文献。

- A. Hatcher, *Algebraic Topology*, Cambridge University Press, 2001. 代数的位相幾何学の標準教科書、著者ウェブサイトで無料公開

- H. Edelsbrunner, J. Harer, *Computational Topology: An Introduction*, AMS, 2010. パーシステント・ホモロジーを含む位相的データ解析の入門書

B.4 機械学習・統計学

第 9 章の確率論・MC ドロップアウト・SHAP・DML などの参考文献。

- C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006. ベイズ推論を含む機械学習の総合的な教科書
- Y. Gal, Z. Ghahramani, "Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning", ICML 2016. MC ドロップアウトの原論文
- S. M. Lundberg, S.-I. Lee, "A Unified Approach to Interpreting Model Predictions", NeurIPS 2017. SHAP の原論文
- V. Chernozhukov et al., "Double/debiased machine learning for treatment and structural parameters", *The Econometrics Journal*, 2018. DML の原論文

B.5 暗号学・形式検証

第 9 章後半のゼロ知識証明・形式検証に関する参考文献。

- S. Goldwasser, S. Micali, C. Rackoff, "The Knowledge Complexity of Interactive Proof Systems", *SIAM J. Comput.*, 1989. ゼロ知識証明の基礎論文 (原論文は 1985 年 STOC)
- A. Chlipala, *Certified Programming with Dependent Types*, MIT Press, 2013. Coq による依存型を使った検証付きプログラミングの教科書

B.6 ジオメトリック・インテリジェンス理論書

本書はあくまで本ケーススタディの読解を助けるための入門書である。ジオメトリック・インテリジェンス理論そのものを体系的に学ぶには、以下の理論書を参照されたい。

- Étale Cohomology, ジオメトリック・インテリジェンス理論 Vol.1(本ケーススタディの理論的基盤)
- Étale Cohomology, ジオメトリック・インテリジェンス理論 Vol.2(幾何学的拡張・エージェント設計)
- Étale Cohomology, ジオメトリック・インテリジェンス Companion Vol.1 / Vol.2(理論書の補助文書)

また、本ケーススタディのその他の補助文書も併せて参照されたい。

- 01_casestudy_GI_theory_mapping ―本編の各場面と GI 理論の数学的工程との対応関係
- 03_python_scripts ―本編に登場するコード断片を整理した実装スクリプト集
- 04_industry_knowledge ―本編に登場する繊維産業・通商規制・サイバー脅威などのドメイン知識

――本書終――