GI 理論 実践教材（詳細版）

データから微分可能多様体をつくる

―― 産業固有のデータの制約と、品質チェックリストに合格するまでの試行錯誤 ――

Étale Cohomology　2026 年 11 月

本教材の範囲と注意

本教材は、各ケーススタディ（物語）の原稿に記載されている範囲で、産業や組織に固有のデータセットの特徴と制約、そして、その制約を克服して微分可能多様体の品質チェックリスト（命題 1.1 の 3 条件）に合格するまでの試行錯誤を整理したものである。既存の教材「多様体の品質チェックリスト合格までの試行錯誤」の詳細版にあたる。

- 各ケーススタディは、チェックリストのすべての項目について、すべての試行の数値を書いているわけではない。書かれていない数値は推測で補わず、「本文に記載なし」とした。
- 原稿の数値は物語の中の数値であり、実際のデータで計算した結果ではない。一方、使われている手法は実在する。
- 「Eight Eyes の多様体」の 3 回の試行の詳細は、Eight Eyes の多様体の原稿ではなく、続く作品「敵の多様体」（公開準備中）の中で、カイトが Eight Eyes 多様体の構築の過程として説明している。本教材では、その記載を出典として明記して用いる。
- 中国の「天網」の試行錯誤も、「敵の多様体」（公開準備中）の記載にもとづく。公開版で記載が変わる可能性がある。
- チェックリストの閾値は作品によって異なる（作品 1 〜 5： MSE < 0.01、KNN 保存率 ≧ 0.90、最小特異値 ≧ 0.001。Eight Eyes と天網： MSE < 0.025、KNN 保存率 ≧ 0.90、最小特異値 ≧ 0.025）。本教材では、各作品の設定をそのまま示す。

第１章　品質チェックリストと、データの制約の型

1.1　品質チェックリスト（命題 1.1 の３条件）

条件	内容	データの制約との関係
条件１　再構成忠実度（MSE）	VAE のデコーダが元のデータを十分に低い誤差で再構成できる	単位や尺度がばらばらなデータ、粒度の混在、欠損の扱いの誤りで悪化する
条件２　潜在空間の滑らかさ（KNN 保存率）	データ空間で近い点が潜在空間でも近い	レジームや組織、プロジェクトでデータが「島」に分かれると悪化する。逆に、検閲で均質化されたデータでは見かけ上よくなることがある
条件３　ヤコビアンの非退化性（最小特異値）	デコーダのヤコビ行列がフルランク（どの方向にも潰れない）	島と島の間の細い橋、データの実質的な情報量（独立な変動の数）の不足、検閲で動きを失った指標で悪化する

1.2　産業と組織に固有のデータの制約の型

制約の型	典型的な例	登場する作品
レジームの断絶（１回限り）	COVID、Brexit などで、前後のデータが別の世界になる	繊維、英国
周期的な構造変化	シリコンサイクルのように、構造が周期的に変わる	半導体、日本（マクロ経済サイクル）
データの単位の離散性・システムの分断	プロジェクトごとの別管理、本社と海外 JV の基幹システムの別、案件ごとに異なるプラットフォーム	建設
粒度の極端な違い	秒単位の IoT・装置データと月次の経営データ。年次の公開統計とリアルタイムの SIGINT	建設、半導体、Eight Eyes
顧客ごとの機密の壁	顧客 A のデータを顧客 B に知られてはならない	半導体（繊維の手法を応用）
機密区分と情報源の保護	SC クリアランスのある機密の脅威データ、HUMINT の情報源	繊維、日本、英国、Eight Eyes
生データを入れられない	集計した指標になって初めてパイプラインに入れられる	日本、英国、Eight Eyes
組織のサイロ	省庁や機関ごとにデータが閉じている	日本
国境・共有の制約	データを国の外に出せない。共有できる指標の範囲が国によって違う	Eight Eyes
データの極端な不足	事故の記録が７件しかない	白夜
正しいデータだがバイアスのあるデータ選択によるデータ解釈結果の認知誘導(旧ソ連の反射理論)	外から、正しい数字だけを偏って選んだ資料が流し込まれる。数字そのものは改ざんされていない	白夜
不都合なデータの削除（検閲）	社会不安、隠れ債務、環境汚染などが入力から外される	中国（天網）

第２章　生存の幾何学（繊維業界）

2.1　産業固有のデータセットの特徴

データ源	内容	期間・規模	特徴・問題点
経営実績データ（SAP など）	売上、コスト、在庫など。５地域（日本、EU、米国、東南アジア、中東）	2018 年４月～2026 年８月の月次、100 指標・８カテゴリ、約 50,500 データポイント	2021 年に売却したインドネシア子会社のデータ、ベトナム事業の最初の２年間のデータが欠ける（財務データだけで 300 以上の欠損点）
ベトナム工場のコストデータ	染料コストなど	2024 年３月～8 月	６か月分がまるごとデジタルの記録に存在しない。現地の CFO の交代で報告基準が維持されず、紙の請求書としてのみ存在
サイバー脅威データ	攻撃の頻度、脆弱性など	18 か月分のみ	期間が短い
機密の脅威データ	GCHQ、日本の国家サイバー統括室（NCO）の評価	—	SC クリアランス保有者のみが扱える。情報源を守る必要がある
SNS のデータ	Twitter/X、Weibo、Instagram、業界フォーラム	３年分、約 280 万件の投稿	非構造化データ

2.2　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
欠損 412 セル（約 0.74%）	放置すれば再構成（条件１）と滑らかさが損なわれる	時間的な近傍と地域間の相関を使った k=5 の KNN 補完。ただしレジームシフトの期間は補完しない
COVID、スエズ運河、ウクライナ侵攻のレジームシフト	補間で埋めると、本物の不連続を滑らかにしてしまい、急変の可能性を過小評価する	３期間にレジームシフトの印を付けて保存（補完後も 23 セルを意図的に欠損のまま残す）。外れ値 147 件は真正の極端な出来事として保持
レジームの境界の遷移データの不足	第１回の試行で、３つのクラスターと細い橋。条件２（0.84）・条件３（0.0002）が不合格	遷移の３期間の日次データの抽出、SNS の日次センチメント、制約付き Neural ODE による補間（2.4）
機密データと非機密データの分離	機密の情報を多様体に反映しつつ、情報源を守る必要	ロンドンのサーバーの専用区画に隔離（保存時・通信時の暗号化、SC 保有者のみアクセス可能）。機密の脅威指標を、情報源を明かさずに、情報量を保った数値の特徴量に変換して多様体に融合（作中の「準同型埋め込み」）

2.3　試行ごとの結果

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回	0.0073 合格	0.84 不合格	0.0002 不合格	不合格（２条件）

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第２回	0.0051 合格	0.937 合格	0.0089 合格	すべて合格

2.4　制約を克服して合格するために行ったこと

ステップ１　原因の特定

８次元の潜在空間を t-SNE で２次元に映し、データが COVID 前・COVID の撹乱期・COVID 後の３つのクラスターに分かれ、間が細い橋でつながっているだけであることを確認した。倉田教授は、データに３つの連結成分があり、VAE がそれを無理に１つの多様体に押し込もうとしている、と診断した。前処理でレジームシフトに印を付けたことは正しかったが、月次の疎なデータの境界点からは、VAE は滑らかな遷移を学べなかった。

ステップ２　５日間の集中的なデータの補強

- 第１日：綾鳥に、３つの遷移期間（2019 年 12 月～2020 年 7 月、2021 年 9 月～2022 年 2 月、2024 年 11 月～2025 年 3 月）の日次の売上（製品ライン別）、工場の稼働率（施設別）、在庫（倉庫別）を依頼。SAP は日次の取引を記録していたが、分析用にその粒度で抽出したことはなかった。
- 第２日：約 287,000 件の生の取引記録が届き、カイトが 18 時間かけてクレンジングと整合を行い、1,247 日分の日次の遷移データ（35 列）にまとめた。
- 第３日：NLP のパイプラインで、３年分・約 280 万件の SNS の投稿を再処理し、遷移期間の日次センチメントを抽出。
- 第４日：制約付き Neural ODE で、売上の連続性、稼働率は 0～100%、総資産の保存という経営の「物理法則」を守る遷移の経路を合成。捏造ではなく、既知の始点と終点の間の制約付きの補間（ホイットニーの拡張定理による正当化）。
- 第５日：VAE を再訓練し、命題 1.1 を再検証。３条件すべてに合格。

考え方

リームは、補間した後も条件２が不合格なら、経営の動きそのものが滑らかでないことが分かり、それ自体が重要な情報になる、と述べた。合成は、条件を「通すため」ではなく、仮説を「確かめるため」に使う。

第３章　弧月の測地線（建設業界）

3.1　産業固有のデータセットの特徴

データ源	内容	期間・規模	特徴・問題点
SAP S/4HANA（本社 ERP）	国内プロジェクトの財務、人事	2015 年 4 月〜（10 年分）。国内は高品質	海外 JV のデータは JV パートナーのシステムとの二重管理で、SAP には月次の集約値しか入っていない
Aconex（海外プロジェクト管理）	中東・東南アジア・アフリカの進捗、設計変更、品質検査	2018 年〜（7 年分）	プロジェクトによって記録の粒度が大きく異なる。サウジの NEOM は Aconex ではなく、NEOM 指定の独自のプラットフォーム
IoT プラットフォーム	クレーン荷重、コンクリート養生温度、振動、GPS 測量、気象	2021 年〜（4 年分）、8 か国・約 30,000 基	秒単位のデータ。センサー故障率が年 5%で欠損が多い。現場ごとにセンサーの種類と設定が異なる
Refinitiv／Bloomberg	為替、金利、鉄鋼・セメント・銅の価格	2010 年〜（15 年分）	高品質
独自の地政学リスク DB	国別リスク、制裁リスト、規制変更	2019 年〜（6 年分）	構造化されていない（Excel ベース、手動更新）
SIEM ログ	ネットワーク、IDS/IPS、OT の異常	2022 年〜（3 年分）	期間が短い

事業の基本単位がプロジェクトで、同時に 47 のプロジェクトが進行し、工期は 6 か月の国内の改修から 12 年のサウジのプラントまで幅がある。プロジェクトごとに期間も規模も違い、データは別々のシステムで管理され、プロジェクト間のつながりがデータの上で断絶している。

3.2　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
プロジェクト単位の離散的なデータ	第 1 回の試行で無数の小さな島。条件 2（0.72）・条件 3（0.00007）が不合格	分析の単位を企業レベルの月次 KPI に変え、プロジェクト間の共変動を主成分分析で保存（ファイバー束の考え方）
秒単位の IoT データと月次の経営データの粒度の違い	月次に集約すると IoT の情報のほとんどが失われる	IoT は月次に集約せず、2 層アーキテクチャにする。上層は月次の経営環境多様体（約 120 指標→12 次元）、下層は現場のデジタルツイン。下層の異常は、上層の特定の次元への「摂動」として伝播させる
国内・中東・新興国の地理的レジーム	第 2 回の試行で 3 つの塊が残り、条件 2（0.86）が不合格	人材の流動を遷移データとして追加し、制約付き Neural ODE で補間（3.4）
システムの分断（本社 ERP と JV、案件ごとのプラットフォーム）	集約値しか取れないデータ、粒度の違うデータが混在	企業レベルの月次の状態ベクトルにそろえることで、システムの違いを吸収（120 か月×120 次元の企業状態行列）

3.3　試行ごとの結果

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回	0.0068 合格	0.72 不合格	0.00007 不合格	不合格（２条件）
第２回	0.0054 合格	0.86 不合格	0.0018 合格	不合格（条件２）
第３回	0.0047 合格	0.924 合格	0.0031 合格	すべて合格

3.4　制約を克服して合格するために行ったこと

ステップ１　固有次元の推定と潜在次元の選択

Levina-Bickel の最尤推定で固有次元 11.7（綾鳥の 8.3 より高い）を得て、潜在次元を 12 とし、11 と 13 でも確認した。VAE は 2,500 エポック、18 時間で訓練した。

ステップ２　プロジェクトから企業へ（第１回→第２回）

新人の河野遥が、VAE に入れるべきは「プロジェクトごとのデータ」ではなく、「プロジェクトの集合が毎月生み出す企業レベルの経営指標」だと提案した。さらに、単純な集約ではなく、主成分分析でプロジェクト間の共変動のパターンを抽出して月次の指標に加え、相互作用の情報を失わないようにした。リンは、これがリルル先生のファイバー束の考え方（底空間＝月次の企業 KPI、ファイバー＝その月のプロジェクト群の詳細）と同じだと指摘した。結果、企業状態行列は 120 か月×120 次元（月次 KPI 28＋共変動 5 ＋その他 87）になった。

ステップ３　人材の流動を橋に（第２回→第３回）

三浦沙織が、国内・中東・新興国の 3 つの塊は「別世界」ではなく、人材の流動でつながっていると指摘した。サウジのプロジェクトが中断すると技術者が国内に戻り、国内の受注が増えると中東に回す技術者が足りなくなる。SAP の人事モジュールから技術者の異動履歴 3,247 件（国内→中東 1,089 件、中東→国内 876 件、国内→東南アジア 534 件、東南アジア→アフリカ 412 件）を取り出し、遷移の信号とした。さらに、技術者の総数の保存、各地域の最低人員、資金移動は資金調達能力の範囲内、という制約を課した Neural ODE で、地理的レジームの間の遷移を補間した。

第４章　光稜精機の物語（半導体製造装置業界）

4.1　産業固有のデータセットの特徴

原稿は、半導体製造装置メーカーのデータの困難を、次の５つにまとめている。

困難	内容
１　シリコンサイクル（周期性）	好況期には受注が殺到し、不況期には半減する。過去 12 年に３回のサイクル。VAE が学ぶべきは「定常的な環境」ではなく「周期的に構造が変わる環境」
２　顧客集中と機密性の壁	顧客は世界に 10 社程度（TSMC、Samsung、Intel、SK hynix、Micron など）。顧客 A の歩留まりデータを顧客 B が知ることは絶対に許されず、同じ社内でも厳密にファイアウォールで分けられている
３　物理データの超高次元性	エッチング装置のプロセスデータは、１ステップに 300 以上のパラメータ、１ウェハーに 50 ステップで 15,000 パラメータ。装置１台が１日に数十 GB のデータを生む
４　技術世代の断絶	２～３年ごとに新しいプロセスノードに移行し、装置の仕様がまったく異なる。５年前のデータが現在の装置に適用できない場合がある
５　地政学データの直接的な影響	米国 BIS の一枚の文書が、事業を直接左右する

経営データは約 130 指標で、綾鳥の 100、弧月の 120 より多い。

4.2　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
顧客ごとの機密の壁	顧客ごとのデータを、そのままでは１つの VAE で学習できない	綾鳥の案件で使った手法を応用。顧客ごとのデータは暗号化されたまま多様体の構築に寄与するが、個別の顧客データは復元できないようにする（作中の「準同型埋め込み」）
物理データの超高次元性	装置のデータを月次の経営データと同じ多様体に載せると、スケールが違いすぎる	２層アーキテクチャ。上層は月次の経営環境多様体（約 130 指標→13〜16 次元）、下層は装置のデジタルツイン群（装置１台あたり数千パラメータ×数百台、リアルタイム）。身体化エージェントが装置の異常を検知し、上層に伝播
シリコンサイクル	第１回の試行で３フェーズのクラスター。条件２（0.63）・条件３（0.00003）が不合格	ヒルベルト変換による瞬時位相（4.4）
技術世代の断絶	第２回の試行で 14nm と 3nm の島が残り、条件２（0.87）が不合格	レシピの設定値から物理量への変換（4.4）

4.3　試行ごとの結果

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回	0.0082 合格	0.63 不合格	0.00003 不合格	不合格（２条件）

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第２回	0.0058 合格	0.87 不合格	0.0024 合格	不合格（条件２）
第３回	0.0049 合格	0.931 合格	0.0038 合格	すべて合格

4.4　制約を克服して合格するために行ったこと

ステップ１　固有次元の推定

推定固有次元 14.2（綾鳥の 8.3、弧月の 11.7 を上回る）。潜在次元 14 で、3,000 エポック、22 時間かけて訓練した。

ステップ２　周期を「位相」で表す（第１回→第２回）

リルル先生は、時計の文字盤のように、2019 年の不況底と 2023 年の不況底は、カレンダーの上では４年離れていても、サイクルの上では同じ位置だと説明し、サイクルの位相角を指標として加えることを提案した。瀬川凛太郎（プラズマ物理の出身）が、周期は 3.5〜4.5 年で揺らぐので単純な三角関数では表せないと指摘し、３次のバタワースのバンドパスフィルタ（周期 42〜54 か月）でサイクルの成分を取り出し、ヒルベルト変換で瞬時位相を推定した。−π と π の境目の不連続を避けるため、cos と sin の２指標として加えた（推定された現在の位相角 268.3°、不況底からの回復初期）。あわせて、弧月で成功した方法を応用し、R&D の投資額の推移と特許出願の技術分類の変遷を、技術世代の間の遷移データとして加えた。

ステップ３　レシピから物理量へ（第２回→第３回）

伊藤翔太（元クリーンルームのプロセスマネージャー）が、技術世代が変わってもプラズマの物理法則は変わらず、変わるのは人間が決めるレシピの設定値（ガスの種類、圧力、RF 電力）だと指摘した。レシピのパラメータを、プラズマの物理量（電子密度、イオンエネルギー、エッチングレート、均一性）に変換すると、レシピ空間では断絶に見えた世代間のデータが、物理量空間では連続として現れた。

第５章　国家の曲率（日本の経済安全保障）

5.1　組織固有のデータセットの特徴

国家のデータは、７つのインテリジェンス関係機関と 11 の省庁に分かれて存在し、それぞれが法律、同盟国との約束、情報源の保護のために、データを外に出せない理由を持っていた。

機関	データを出せなかった理由と、突破の方法
警察庁警備局（最も困難な壁）	個別の事案や情報源が特定されることへの懸念。サイバー班が３週間かけて、集約の手順と VAE のアーキテクチャとソースコードを精査し、３つの検証（入力の監査、デコーダからの復元攻撃、メンバーシップ推論攻撃）に合格したことで、データの提供を許可
公安調査庁	警備局が出すなら出す。ただし国家情報局経由で
防衛省情報本部	SIGINT データは GSOMIA の制約がある。米国側への正式な要請と同意の取得に６週間
外務省	HUMINT の情報源は絶対に出せない。リルル先生が「ベクトル場への翻訳」方式を３回のセミナーで説明し、外務省の担当者が自ら「方向と強さ」のパラメータを設定する方式で合意
防衛装備庁	米国 FMS 経由の装備データには米国国務省の承認が必要。政府間の手続きに８週間
経産省、農水省、資源エネ庁、厚労省、総務省、金融庁	政治の力で個別に突破。農水省が最も抵抗した

5.2　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
生データを入れられない	個別の記録を入れずに、多様体を学習しなければならない	国家情報局の中で月次の集計指標にまとめ、件数の少ない区分は秘匿し、統計的なノイズ（差分プライバシー）を加えてから入力する「国家情報局経由モデル」
情報源（HUMINT）を出せない	重要な情報が入力から欠ける	情報源の中身ではなく、「方向と強さ」のパラメータとして、ベクトル場に翻訳して入力
定義・単位・更新頻度の不統一	再構成の誤差、滑らかさが損なわれる	遠藤真紀が３週間をかけて「経済安全保障データ辞書」を作り、156 指標の定義・単位・更新頻度を統一
時点の数の不足	月次だけでは 15 年分でも約 180 時点で、156 指標・20 次元の学習には足りない	週次・日次で取れる指標（通関、海運、金融市場、サイバーの観測）を軸に約 3,000 時点を組み、月次の指標は補間して加える
省庁ごとのデータのサイロ	第１回の試行で 11 分野が個別の島。条件２（0.71）・条件３（0.00009）が不合格	産業連関表で分野間の依存関係を指標化、マクロ経済サイクルの位相角を追加（5.4）

5.3　試行ごとの結果

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回	本文に記載なし	0.71 不合格	0.00009 不合格	不合格（２条件）
第２回	本文に記載なし	本文に記載なし	本文に記載なし	本文に記載なし
第３回	0.0052 合格	0.918 合格	0.0027 合格	すべて合格

5.4　制約を克服して合格するために行ったこと

推定固有次元19.3から潜在次元を20とした。第１回の試行で11分野が島に分かれたことについて、リルル先生は、弧月の地理的レジーム、光稜のシリコンサイクルと同じパターンで、国家の場合は省庁ごとの「データの島」だと指摘した。遠藤真紀が、11分野の間の物理的な依存関係（半導体がなければ医療機器は動かない、レアアースがなければEVは作れない）を産業連関表から定量化して指標に加えることを提案し、さらにリルル先生の提案で、光稜の案件で成功したヒルベルト変換による位相角を、マクロ経済のサイクルに適用して加えた。第３回の試行で３条件すべてに合格した。

遠藤は、データがそろった日に、「この３か月で手に入れたのはデータだけではない。７つのインテリジェンス関係機関と11の省庁の人間関係を構築し、『国家情報局経由モデル』というデータ統合の制度的な枠組みを作った。これは多様体と同じくらい重要だ」と述べた。

第６章　国王陛下の多様体（英国の国家レジリエンス）

6.1　組織固有のデータセットの特徴

・GCHQ の SIGINT データは、第１層（メタデータ：誰が誰に、いつ、どこから通信したか）、第２層（通信の内容）、第３層（分析結果：脅威評価）に分かれている。多様体に載せられるのは第３層だけ。

・Brexit 後、英国は EU の法執行データベース（シェンゲン情報システム SIS II）や、加盟国どうしの行政データの交換の仕組みへのアクセスを失い、データ基盤そのものに穴が開いている。

・約 170 指標、10 カテゴリ（エネルギー：DESNZ、金融：HM Treasury・イングランド銀行・FCA、防衛：MOD・MI6、サイバー：GCHQ・NCSC、マクロ経済：HM Treasury・ONS・BoE など）。推定固有次元 22〜25 でシリーズ最大規模。

6.2　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
生データ（第１層・第２層）を入れられない	入力は分析結果に限られる	第３層の分析結果だけを入力。VAE に必要なのは「脅威の方向と大きさ」で、個別の通信内容ではない（カイト）。倉田教授の助言で、生データは月次の集計指標にまとめ、件数の少ない区分は伏せ、差分プライバシーを付加。集約の規則と少ない区分の扱いを GCHQ の側で文書にして監査し、復元の攻撃も GCHQ のチームが試す
時点の数の不足	月次だけでは約 180 時点で、約 170 指標・23 次元には少なすぎる	週次・日次の指標を軸に約 4,000 時点を組み、月次の指標は補間であることの印を付けて加える
Brexit による構造の断層	第１回の試行で「２つの英国」が分離し、条件２（0.68）が不合格	「EU 離脱度」の連続変数と Neural ODE による補間（6.4）
Brexit 後のデータの穴	EU の仕組みへのアクセスを失った指標	Eurostat などの公開統計は引き続き使えるが、加盟国としてのデータの交換は失われた（原稿の記載）。それ以上の補い方は本文に記載なし

6.3　試行ごとの結果

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回	本文に記載なし	0.68 不合格	本文に記載なし	不合格（条件２）
第２回	本文に記載なし	本文に記載なし	本文に記載なし	本文に記載なし
第３回	0.0048 合格	0.927 合格	0.0032 合格	すべて合格

6.4　制約を克服して合格するために行ったこと

リルル先生は、Brexit は周期的な現象ではなく１回限りの構造変化なので、光稜の位相角ではなく、離脱の度合いを表す連続的な指標を加え、Neural ODE で変化の前後をなめらかにつなぐのが適していると判断した。オリヴィア（オックスフォード数学科卒）が、移行期（2016〜2020 年）のデータを精密に分析し、EU 規制の適用率、EU 市場へのアクセスの度合い、EU との情報共有の接続

度を、0（完全なEU加盟）から1（完全な離脱）の尺度で計量化した「EU離脱度」をVAEの指標に加えた。Brexitの前後のデータが、同じ多様体の上の連続した道のりとして学習できるようになり、第3回の試行で3条件すべてに合格した（23次元）。

第７章　Eight Eyes の多様体（８か国のインテリジェンス統合）

7.1　組織固有のデータセットの特徴

・７カテゴリ、約 280 指標、15 年分。入力は生のデータではなく、各国の分析の層を通った後の、集計された指標だけ（MALLARD、PRISM、XKeyscore などの収集・保存・検索の層の上に、多様体を重ねる）。

・時間の粒度が根本的に異なる：公開統計（GDP、軍事費白書など）は年次・四半期、経済指標（為替、株価、貿易統計）は日次・月次、SIGINT・ELINT は秒〜分単位のリアルタイム。

・同じ概念でも定義が違う：たとえば軍事費は、SIPRI の定義（研究費を含む）と NATO の定義（年金を含む）で異なる。

・SIGINT 由来のデータには、情報源の保護のために意図的に欠損が作られる場合がある。

・単位がばらばら：軍事費（兆ドル単位）とジニ係数（0〜1）やメディア自由度指数（0〜100）が同じ空間に入る。

・共有の範囲が国によって違い（Tier A：Five Eyes、Tier B：日本・フランス・ドイツ）、各国の指標は国の外に出せない。

7.2　前処理の４つの作業（「敵の多様体」での説明）

作業	内容
1　時系列の粒度の統一	年次・四半期・月次・日次・リアルタイムのデータを、共通の粒度にそろえる
2　名寄せ	同じ概念の定義を統一する（例：軍事費は SIPRI の定義に統一）
3　欠損値の処理	情報源の保護のための意図的な欠損は、単純な補間ではなく、MCMC にもとづく多重代入法で扱う
4　統計的な標準化	各指標をドメイン別に z-score 標準化する

7.3　試行ごとの結果（「敵の多様体」でのカイトの説明。閾値：MSE < 0.025、KNN 保存率 ≧ 0.90、最小特異値 ≧ 0.025）

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回	0.041 不合格	0.87 不合格	0.029 合格	不合格（２条件）
第２回	0.019 合格	0.83 不合格	0.031 合格	不合格（条件２）
第３回	0.019 合格	0.923 合格	0.034 合格	すべて合格

7.4　制約を克服して合格するために行ったこと

第１回→第２回：尺度の違い（条件１）

再構成の誤差が大きい原因を調べると、軍事データ（兆ドル単位）とメディア自由度指数（0〜100）が異なる尺度のまま投入されていた。VAE が尺度の大きいデータに引きずられ、尺度の小さいデータの再構成精度が落ちていた。ドメイン別の z-score 標準化を適用した。リルル先生は、こ

れを「ショートブレッドの教訓」（材料が少ないからこそ、材料の品質がすべてを決める）と呼んだ。

第２回→第３回：外交データの粒度の不統一（条件２）

KNN 保存率が低い原因を調べると、外交データの時系列の粒度が不統一だった（条約は年次、投票は会期ごと、制裁は随時）。四半期への統一が不完全で、外交データの近傍構造が歪んでいた。条約は発効の四半期に、投票は会期の属する四半期に集約し、制裁は発動・解除の四半期に配置して、すべてを四半期に統一した。

設計で満たす：滑らかさ

活性化関数に Tanh（C^∞級）を使い、曲率の計算に必要な滑らかさを設計で保証した。

共有の制約のもとでの多様体（Eight Eyes の多様体の原稿）

- VAE の座標にはすべての入力の指標が混ざるので、座標の単位では共有の範囲を分けられない。入力の指標の側で範囲を分け、Tier B には、共有できる指標群だけで命題 1.1 を満たす最小の次元数（約 22 次元）の多様体を提供した。
- 各国の指標を国の外に出せないので、各国が自国の施設の中で座標を計算し、集計とノイズを加えた結果と更新の情報だけを持ち寄る連合学習で、共同の多様体を学習させた。

第８章　白夜の臨界（ロシアの反射統制と向き合ったメリディアン側の多様体）

8.1　産業固有のデータセットの特徴

- 北極海の LNG 事故の記録は、世界中を探しても７件しかない（極端なデータの不足）。
- 船齢、Arc 等級、積荷の種類が互いに強く相関する（古い船は Arc 等級が低く、積荷も異なる傾向）。
- 氷海での衝突確率、LNG の物理的特性、気象統計は、IMO、AMSA、ERA5 再解析データから実在する数値として入手できる。
- 保険市場に流れ込む分析レポートには、ロシアの AI「БЕЛЫЙ-7」による正しいデータだがバイアスのあるデータ選択によるデータ解釈結果の認知誘導(旧ソ連の反射理論)の資料（実在しない機関の名義のものを含む）が混じる。

「正しいデータなら、改ざんではないのでは？」―― 何が問題なのか

この手口では、資料に書かれた数字は、１つ１つはすべて正しい。数字そのものは改ざんされていない。それでも問題になるのは、どの数字を示し、どの数字を示さないかという「選び方」に偏りがあるためである。

- たとえば、過去３年の北極海の航行の記録から、事故のなかった期間のデータだけを集中的に引用すれば、事故のあった期間の記録が１件も書き換えられていなくても、「リスクは下がっている」という結論に読み手を導ける。
- 読み手は、示された正しい数字から、自分の頭で考えて結論を出したと思う。しかし、その判断の根拠は、最初から送り手が選んで渡したものである。これが、旧ソ連で体系化された反射理論（反射統制）の考え方である。
- 嘘を含まないため、事実確認（ファクトチェック）では見抜けない。見抜くには、「何が示されなかったか」を確かめる統計学の検定（シンプソンのパラドックス、スキャン検定、並べ替え検定など）が必要になる。

本教材では、この手口を「正しいデータだがバイアスのあるデータ選択によるデータ解釈結果の認知誘導(旧ソ連の反射理論)」と呼ぶ。

8.2　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
実データが７件だけ	Fisher 情報行列が退化し、計量の正定値性（条件③）が崩れる	物理シミュレーションで 5,000 件のシナリオを生成（Sim-to-Real）し、Fisher 行列に λI（λ = 0.001）を加えるチホノフ正則化
変数間の多重共線性	「同じ方向を２回数える」ことになり、曲率が歪む（局所線形性、条件①）	主成分分析で互いに直交する軸に変換
損害額の分布の裾	微分できる滑らかな分布が必要（可微分性、条件②）	一般化パレート分布でモデル化し、深層学習でそのパラメータを推定
正しいデータだがバイアスのあるデータ選択によるデータ解釈結果の認知	多様体の条件は満たしても、入力が偏っていれば結果も偏る	統計学の検定（シンプソンのパラドックス、スキャン検定、並べ替え検定、レイリー検定）、層の整合性の半径による引用ネ

データの制約	チェックリストへの影響	克服のために行ったこと
誘導(旧ソ連の反射理論)		ットワークの検証で、入力の偏りを見抜く
シミュレーションへの依存	答えが、シミュレーションを作った人間の仮定に引きずられる	本物の７件を、シミュレーションが現実からずれていないかを確かめる物差しとして使い続ける

8.3　教訓

本作は、チェックリストに合格すること（多様体の品質）と、入力されるデータが誠実であること（データの品質）が、別の問題であることを示している。多様体が数学的に正しくても、入力が正しいデータだがバイアスのあるデータ選択によるデータ解釈結果の認知誘導(旧ソ連の反射理論)を受けていれば、正しい計算で歪んだ姿が描かれる。

第９章　中国の「天網」（敵の多様体：公開準備中）

9.1　組織固有のデータセットの特徴

天網は、Eight Eyes と同じく約 280 指標・35 次元の多様体として設計された。しかし、入力からは、中国国家安全部の技術局による「国家安全審査」の名目で、統治にとって不都合なデータ ―― 社会不安、地方政府の隠れ債務、環境汚染の実態、幹部の汚職や蓄財など ―― が外されている。

9.2　試行ごとの結果（「敵の多様体」でカイトが再構成したもの。閾値：MSE < 0.025、KNN 保存率 ≧ 0.90、最小特異値 ≧ 0.025）

試行	条件１ MSE	条件２ KNN 保存率	条件３ 最小特異値	判定
第１回（35 次元）	0.033 不合格	0.94 合格	0.012 不合格	不合格（２条件）
第２回（35 次元）	0.016 合格	0.947 合格	0.014 不合格	不合格（条件３）
第３回（26 次元）	0.016 合格	0.947 合格	0.031 合格	「合格」（次元を下げて）

9.3　データの制約とチェックリストへの影響

データの制約	チェックリストへの影響	克服のために行ったこと
不都合なデータの削除（検閲）	データの実質的な情報量（独立な変動の数）が 35 次元を支えるには足りず、条件３が閾値を割り続ける	陳偉明は前処理を改善しても条件３を満たせず、潜在次元を 35 から 26 に下げて「合格」させた
検閲による均質化	KNN 保存率が 0.94 と、Eight Eyes の 0.923 より高い。現実の近傍構造ではなく、データが均質化されて単純になったことの兆候	（教訓：KNN 保存率が高いことは、良い兆候とは限らない）

9.4　別の道として提案されたこと

陳偉明は、不都合なデータを暗号化したまま学習させる道 ―― 準同型暗号による秘密計算や、個々の記録を特定できないよう統計的なノイズを加える差分プライバシー ―― を提案した。技術的には可能だが、国家安全部の林雪華は、それらのデータは国家安全審査の対象で天網に入力することは認められていないと退けた。誰が何を知ってよいかの線を引くのは、技術ではなく政治である。

9.5　教訓

- 35 次元を 26 次元に下げたことは、多様体が捉えられる現実の複雑さが約 74%に減ったことを意味する。失われた９次元は、検閲で除外されたデータが本来持っていた情報の次元である。リルル先生の言葉では、「次元の低さそのものが、検閲の署名」である。
- チェックリストを「通す」ために次元を下げることは、数学的には合格でも、現実の一部を見ないことを選ぶことである。合格の数値だけでなく、合格させるために何を捨てたかを記録することが重要である。

第 10 章　横断比較 —— データの制約と、克服の型

データの制約の型	影響した条件	克服の型（作品）
レジームの断絶（1 回限り）	条件 2 ・ 3	遷移期間の細かい粒度のデータ＋制約付き Neural ODE（繊維）。変化の度合いの連続変数＋補間（英国）
周期的な構造変化	条件 2 ・ 3	ヒルベルト変換による瞬時位相を cos・sin で追加（半導体、日本）
データ単位の離散性・システムの分断	条件 2 ・ 3	企業レベルの月次 KPI への変換と、主成分分析による共変動の保存（建設）
粒度の極端な違い	条件 1 ・ 2	2 層アーキテクチャ（建設、半導体）。共通の粒度への統一（Eight Eyes の四半期化）
人間が決めた設定値の断絶	条件 2	自然法則が決める物理量で記述し直す（半導体）
地理・組織の分断	条件 2 ・ 3	分断をつなぐ実際の流れや依存関係の指標化（建設の人材の流動、日本の産業連関表）
尺度・定義の不統一	条件 1	データ辞書による統一（日本）、名寄せとドメイン別の z-score 標準化（Eight Eyes）
顧客・機密区分の壁	—（学習の前提）	隔離した区画での処理と、情報源を明かさない特徴量への変換（繊維、半導体）
生データを入れられない	—（学習の前提）	集計指標＋件数の少ない区分の秘匿＋差分プライバシー、攻撃の試験（日本、英国）
国境・共有の制約	—（学習の前提）	入力の指標の側での範囲の分割と最小次元、連合学習（Eight Eyes）
時点の数の不足	条件 1 〜 3	週次・日次の指標を軸に時点を増やし、補間の印を付ける（日本、英国）
データの極端な不足	条件③	Sim-to-Real＋チホノフ正則化（白夜）
正しいデータだがバイアスのあるデータ選択によるデータ解釈結果の認知誘導(旧ソ連の反射理論)	（条件の外側）	統計学の検定と層の整合性による入力の検証（白夜）
不都合なデータの削除	条件 3	正直なデータでなければ解決しない。次元を下げた「合格」は、現実を見ないことの選択（天網）

実務への教訓

- データの制約は、産業と組織の構造そのものを映している。チェックリストの不合格は、その構造を知らせる信号である。
- 制約を克服する鍵は、統計の操作よりも、現場の実務家の知恵（河野遥、三浦沙織、瀬川凛太郎、伊藤翔太、遠藤真紀、オリヴィア）から見つかることが多い。
- 機密や国境の制約は、データを「入れない」ことで守り、そのうえで「入れられる形」（集計、特徴量、連合学習）に変える制度と技術を作ることで乗り越える。

・合格の数値だけでなく、合格させるために何を補い、何を捨てたかを記録する。補ったもの（補間、合成）は本物のデータで照らし合わせ続け、捨てたもの（次元、データ）は、見えなくなった現実として明示する。