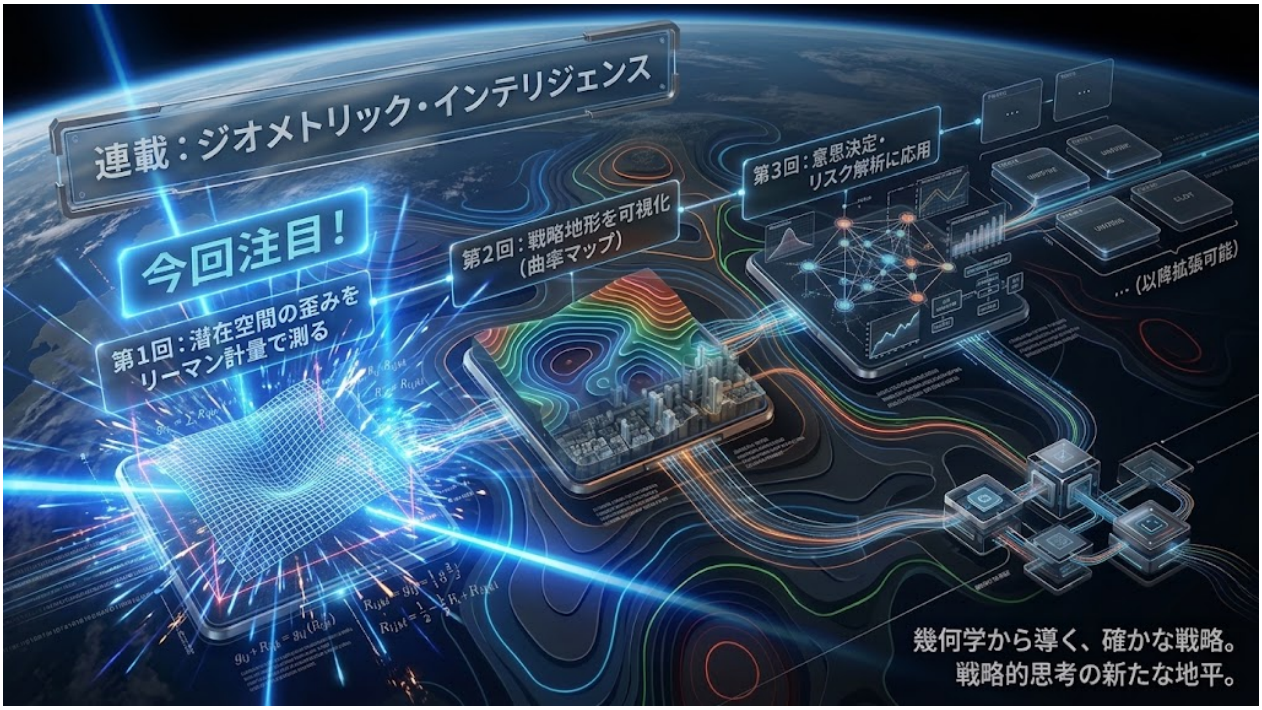
VAEの潜在空間を「社会経済分析の地図」に変えるには？ —— リーマン計量を導入するための3つの条件（Geometric Intelligence論への招待）



この記事の想定読者



- 企業や官庁で働く、Python機械学習エンジニア
- 経営コンサルタント
- 政策コンサルタント
- 機械学習（AI）とAIエージェントに明るい、国会議員の政策スタッフ・秘書

この記事を読んで得られるもの



- VAEの潜在空間が、画像の生成では優れた力を発揮する一方で、社会経済分析の「地図」としては、そのままでは使えない理由
- 潜在空間に「定規」（リーマン計量）を当ててよいかを確かめる、3つの条件。地図のたとえで、数式なしに理解できます
- エンジニア向けの、条件の判定の目安
- 業界や政策領域ごとに、データにどんな制約がありそうか。そして、その制約を越えて条

件を満たすための試行錯誤の型（架空の舞台で考えたもの）
- 条件を満たした地図の上で、地形の起伏や最も無理のない道筋を計算する世界への入口（連載第2回以降で詳しく扱います）

① VAEとは何か —— 「実在しない顔」を描けるAI

Python機械学習エンジニアの皆様は、VAE（変分オートエンコーダ、Variational Autoencoder）と聞くと、どんなイメージをお持ちでしょうか。

画像生成AIを支える、王道のアルゴリズムの1つ。
そんなイメージではないでしょうか？

実際、VAEに実在する人物の顔の画像を大量に学習させると、架空の人物の顔画像を生成できます。学習した顔の瞳や鼻・口、頬・顎（あご）・耳の形、顔全体のバランスを、わずかに変えるのです。

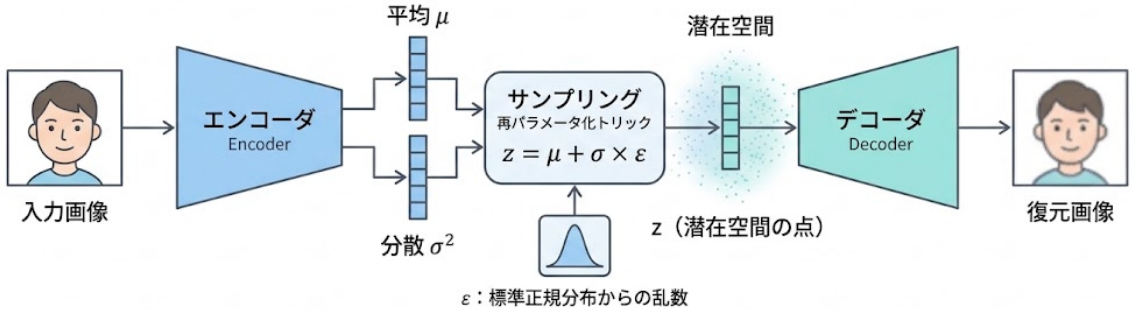
実際には存在しない。けれど、見るからに現実に存在しそうな顔です。

これは、**VAE** の 「**V**」、つまり **Variational（変分）の部分** が力を発揮しているからです。

VAEは、2013年にKingmaとWellingが発表した **論文**「**Auto-Encoding Variational Bayes**」で提案された **生成モデル** です。

その仕組みは、次の **3つの部品** でできています。

- **エンコーダ**：入力された顔画像を、「潜在空間」の上の位置に変換します。潜在空間は、少ない数の座標（たとえば数十次元）からなる空間です。
  このとき、**普通のオートエンコーダのように1つの点を出力するのではありません。**
  「平均」と「分散」の組、つまり**確率分布**として出力します。
- **サンプリング**：その分布から、点を1つ取り出します。ここでは「再パラメータ化トリック」という工夫を使います。これにより、確率的な操作を含んだままでも、誤差逆伝播で学習できます。
- **デコーダ**：取り出した点から、元の顔画像を復元します。



なぜ、1つの点ではなく、「平均」と「分散」の組（確率分布）として出力するのでしょうか。

もし１つの点として出力すると、それぞれの顔は、潜在空間の上の「点」にしか対応しません。

点と点の間のすき間は、学習の中で一度も使われない場所になります。

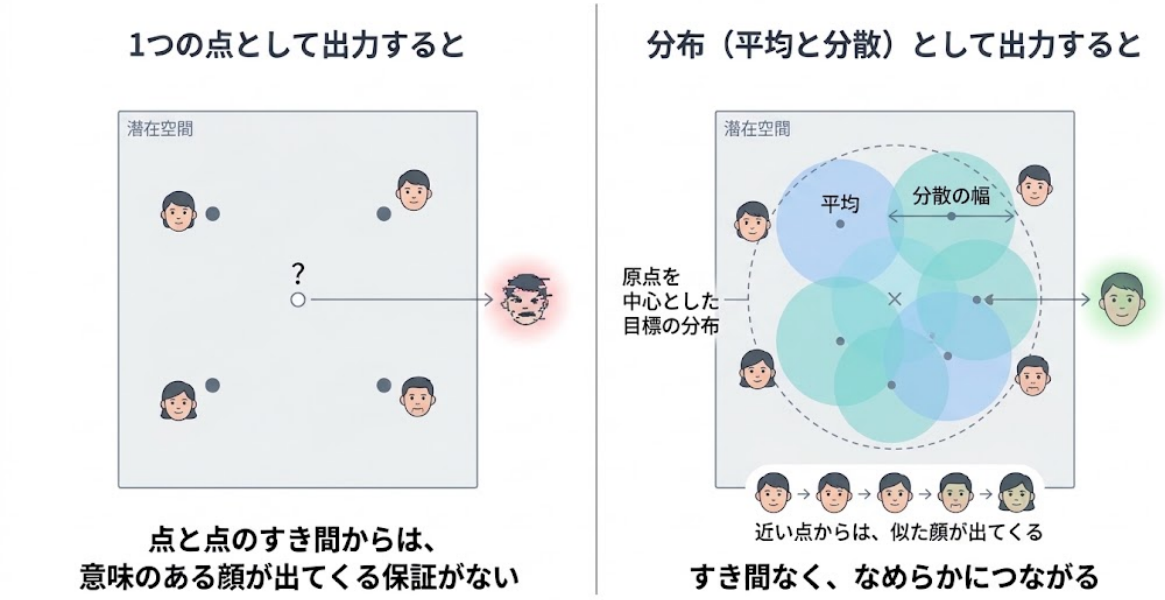
そのすき間の点をデコーダに通しても、意味のある顔が出てくる保証はありません。

一方、**分布として出力すると、それぞれの顔は、「平均」を中心に、「分散」の幅をもった小さな「範囲」に対応します。**

学習では、**その範囲の中のどの点からでも、元の顔に近い顔が復元できるように訓練** されます。
すると、**近い点からは似た顔が出てくるようになり、潜在空間がすき間なく、なめらかにつながります。**

これが、潜在空間の中の新しい点から「実在しないが、実在しそうな顔」を作り出せる仕組みの土台 です。

ここで1つ、注意しておきたいことがあります。
VAE には、**「中心」と「広がり」が、2つの段階で** 出てきます。



1. **入力ごとの分布（エンコーダが出力するもの）**
   エンコーダは、入力された **顔画像1枚ごとに** 、**別々の「平均** μ **」と「分散** σ^2 **」** を出力します。
   （平均 μ は潜在空間の中の位置を、分散 σ^2 はその位置のまわりの広がりの幅を表します）
   顔Aには顔Aの平均と分散が、顔Bには顔Bの平均と分散があります。
   ですから、潜在空間の中には、顔の数だけ、小さな範囲（中心と広がり）があります。
   上で説明した「それぞれの顔は、『平均』を中心に、『分散』の幅をもった小さな『範囲』に対応する」は、こちらの話です。
2. **全体の目標の分布（あらかじめ決めた標準正規分布）**
   こちらは、潜在空間に1つだけある、原点を中心とした分布です（平均0、分散1）。
   このあと説明する学習の2つ目の項（KL情報量）が、1の小さな範囲たちを、この原点の周りの大きな円の中に集めるように働きます。
   「潜在空間の中央に中心が1つだけあり、その円の中に収まるように制御する」というイメージは、こちらの話です。

つまり、潜在空間の中央には、原点を中心とした大きな円が1つあります。
その中に、顔ごとの小さな範囲がたくさん集められ、互いに重なり合って並びます。
重なり合うので、すき間がなくなるのです。

学習では、次の2つの量の和を小さくします。

1. **再構成の誤差**：復元した画像が、元の画像にどれだけ近いか
2. **KL情報量（KLダイバージェンス）**：エンコーダが出力する分布が、あらかじめ決めた標

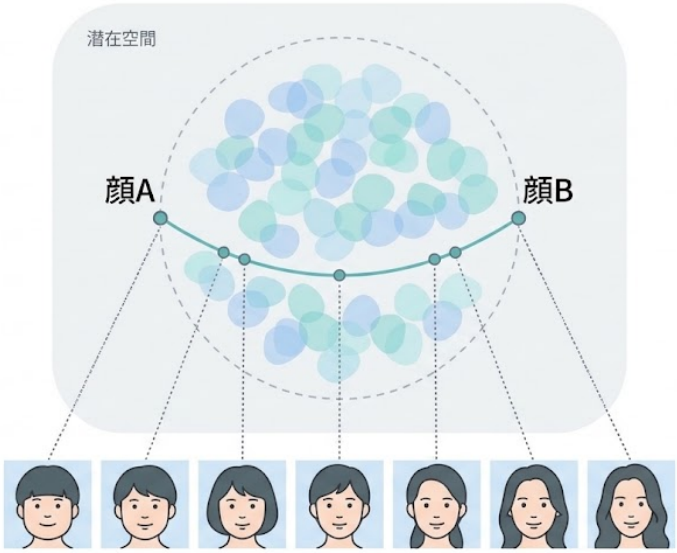
準正規分布にどれだけ近いか

これは、**変分推論** という統計学の方法で、**「証拠下界（ELBO）」と呼ばれる量を最大化すること** にあたります。
「変分（Variational）」という名前 は、**ここから来ています。**

2つ目の項のおかげで、顔ごとの小さな範囲は、潜在空間の原点を中心とした大きな円の中に集められ、互いに重なり合います。
そのため、学習していない点を選んでデコーダに通しても、「それらしい顔」が出てきます。

2人の顔の座標の間をなめらかにたどれば、顔が少しずつ移り変わっていく画像も作ることができます。

これが、「実在しないが、実在しそうな顔」を描ける理由です。

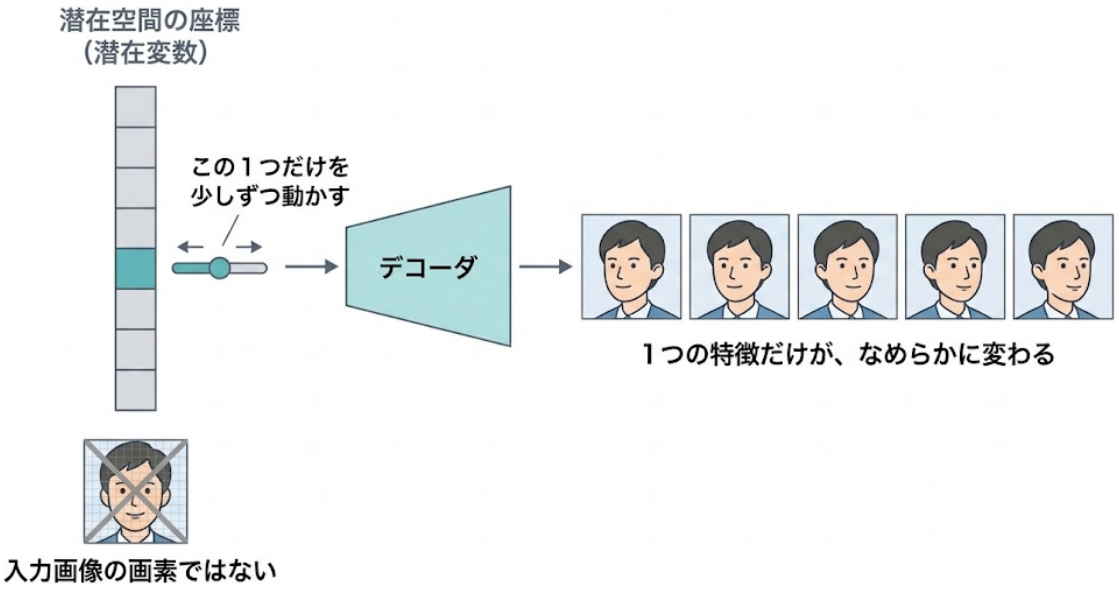


途中の点からも、実在しないが、実在しそうな顔が生まれる

VAEを少し改良した「β-VAE（ベータVAE）」という手法 も提案され、話題になりました。

潜在空間の座標のうち1つだけを、少しずつ動かしてみます。
すると、生成される顔の特徴の一部だけが、なめらかに変化していく様子が示されたのです。

このとき動かすのは、入力画像ではなく、「潜在空間の次元（潜在変数）」です。



β-VAE は、**潜在空間の各次元がそれぞれ別々の特徴（たとえば笑顔の度合いや顔の向きなど）を独立して表すように促す手法** として、大きな注目を集めました。
このような性質を、「**ディスエンタングルメント（ disentanglement ）**」 と呼びます。

disentanglement は、「もつれさせる、からませる」という意味の entangle に、反対の意味を表す接頭辞 dis- が付いた言葉です。
もつれ合い、からまり合った複数の特徴をときほぐし、1つずつ取り出して動かせるようにする、という意味です。

では、β-VAE以前の普通のVAEでは、潜在空間の各次元は、独立した特徴を表していないのでしょうか。

答えは、「そうなるとは限らない」です。

普通のVAE でも、学習の目標とする分布（標準正規分布）は、各次元が互いに独立した形をしています。

けれど、**学習の目的は、あくまで「元の顔をうまく復元すること」と「目標の分布に近づけること」** です。
「1つの次元に、1つの特徴だけを担わせる」ことは、目的に入っていません。

そのため、**普通のVAE** では、**1つの次元を動かすと、顔の向きと明るさと髪型が一緒に変わる、ということがよく起こります。**
複数の特徴が、複数の次元にからまり合って記録されてしまう のです。

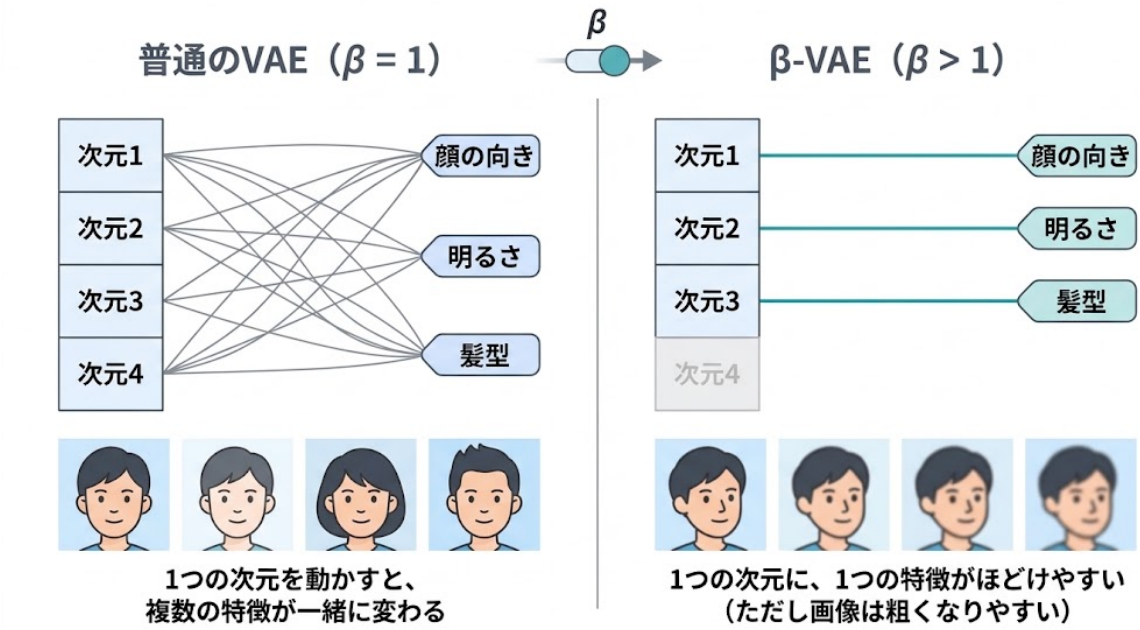
β-VAE の「β **（ベータ）** 」は、**学習の2つ目の項（KL情報量）にかける重み** です。

$\beta = 1$ **のとき** は、**元のVAEと同じ** になります。

β **を1より大きくする** と、顔ごとの小さな範囲を、原点を中心とした標準正規分布に **近づける力が強く** なります。
その分、潜在空間に詰め込める情報の量が絞られ、各次元が、互いに独立した特徴を表しやすく なります。
こうして、**β-VAEは、からまりをほどく方向に学習を後押し** します。

ただし、そのぶん、復元される画像は粗くなりやすい、という代償を払うことになる傾向があります。

また、**β-VAEでも、いつも必ずきれいにほどけるわけではありません。**
どの特徴がどの次元に分かれて現れるかは、**データや学習の設定によって変わります。**



論文の著者たちは、**データを生み出している「独立した要因」** を、**人間に教えられることなく学び取ること** を、人間のように学び、推論できるAIに向けた大切な一歩と位置づけていました。

この考え方は、その後、カメラやセンサーを持つロボットや、仮想環境の中で行動するAIエージェントが、自分の周りの世界の成り立ちを、データから自律的に学び取る研究につながっています。

たとえば、同じ研究グループは、β-VAEで学んだ表現を強化学習のエージェントの「見る力」として使うと、学習したときとは見え方の違う環境にも対応しやすくなることを示しました。
ロボットアームの制御や3次元の仮想環境で確かめています（ **DARLA** ）。

さらに、**物の動きや出来事の「原因と結果」の関係まで含めた「世界モデル」を、データから学び取ろうとする研究（因果表現学習）** も進められています。

- Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, Alexander Lerchner. “β-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework.” International Conference on Learning Representations (ICLR), 2017.
  https://openreview.net/forum?id=Sy2fzU9gl
- Irina Higgins, Arka Pal, Andrei A. Rusu, Loic Matthey, Christopher Burgess, Alexander Pritzel, Matthew Botvinick, Charles Blundell, Alexander Lerchner. “DARLA: Improving Zero-Shot Transfer in Reinforcement Learning.” International Conference on Machine Learning (ICML), 2017.
  https://arxiv.org/abs/1707.08475

なお、VAEが単独で生成する画像は、細部がややぼやけやすいことが知られています。

現在よく知られている **画像生成AI（Stable Diffusion など）** では、画像の生成そのものは **拡散（Diffusion）モデル** が担っています。
VAE（またはVAEに近いオートエンコーダ） は、画像を小さな潜在空間に圧縮し、また元の画像に戻す部品として使われています。

VAE は、今も画像生成AIの土台を支える部品の1つなのです。

コラム：生成AI ── VAEとGAN

VAEとは別の生成モデル（GAN）でも、潜在空間の軸を動かして、顔の特徴を連続的に変えるデモが話題になりました。

TL-GAN（Transparent Latent-space GAN）の概要

- **作者と位置づけ**：Shaobo Guan氏が、Insight Data Scienceのプロジェクトの一環として作ったものです。GitHubのリポジトリには、3週間のプロジェクト「Draw as you can tell: controlled image synthesis and edit using TL-GAN」として記されています。
- **土台のモデル**：NVIDIAのpg-GAN（高解像度でリアルな顔画像を生成するモデル）を使っています。1024×1024画素の画像のすべての特徴が、潜在空間の512次元のベクトルだけで決まる、という性質を利用しています。
- **仕組み**：学習済みのGANの潜在空間の中に、「特徴の軸」を見つけ出します。ベクトルをその軸に沿って動かすと、画像がその特徴に沿って変化します。
- **スライダーのデモ**：対話的に操作できるデモが、Kaggleのノートブックとして公開されました。デモの説明には、「ひげ（Beard）」を動かすときは「男性（Male）」を固定する、という使い方が書かれています。
- **話題になった点**：作者のブログでは、従来の方法では、ひげを少しだけ濃くするように、1つの特徴を2つの状態の間で連続的に調整することができなかったと述べ、それを解決したことを打ち出していました。

なお、TL-GANは、正式な論文ではなく、ブログ記事とGitHubで公開されたプロジェクトです。

出典：

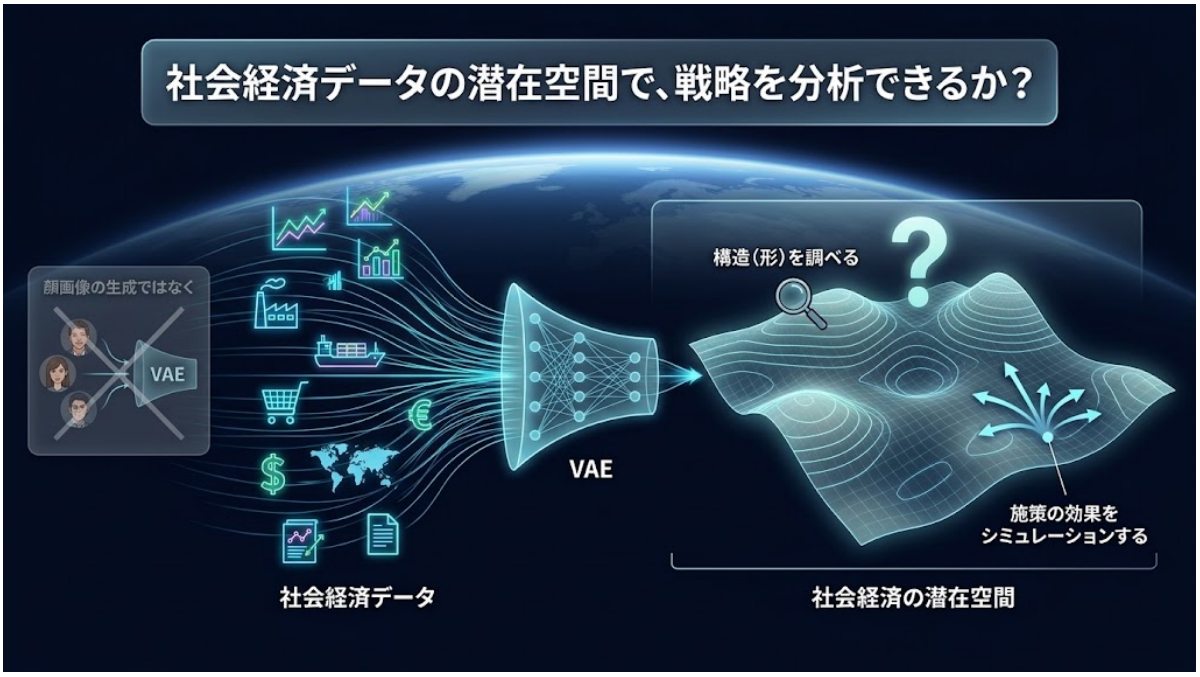
- GitHub：https://github.com/SummitKwan/transparent_latent_gan
- 作者のブログ記事：https://medium.com/p/d170b1b59255
- Kaggleのデモ：https://www.kaggle.com/summitkwan/tl-gan-demo

似た研究（正式な論文）

同じように、GANの潜在空間の中で、性別、年齢、表情、眼鏡の有無、顔の向きなどの特徴を連続的に変える研究として、InterFaceGANがあります。

- Yujun Shen, Jinjin Gu, Xiaoou Tang, Bolei Zhou. “Interpreting the Latent Space of GANs for Semantic Face Editing.” Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020. https://arxiv.org/abs/1907.10786

② 社会経済データでVAEの潜在空間を「地図」として使えるか



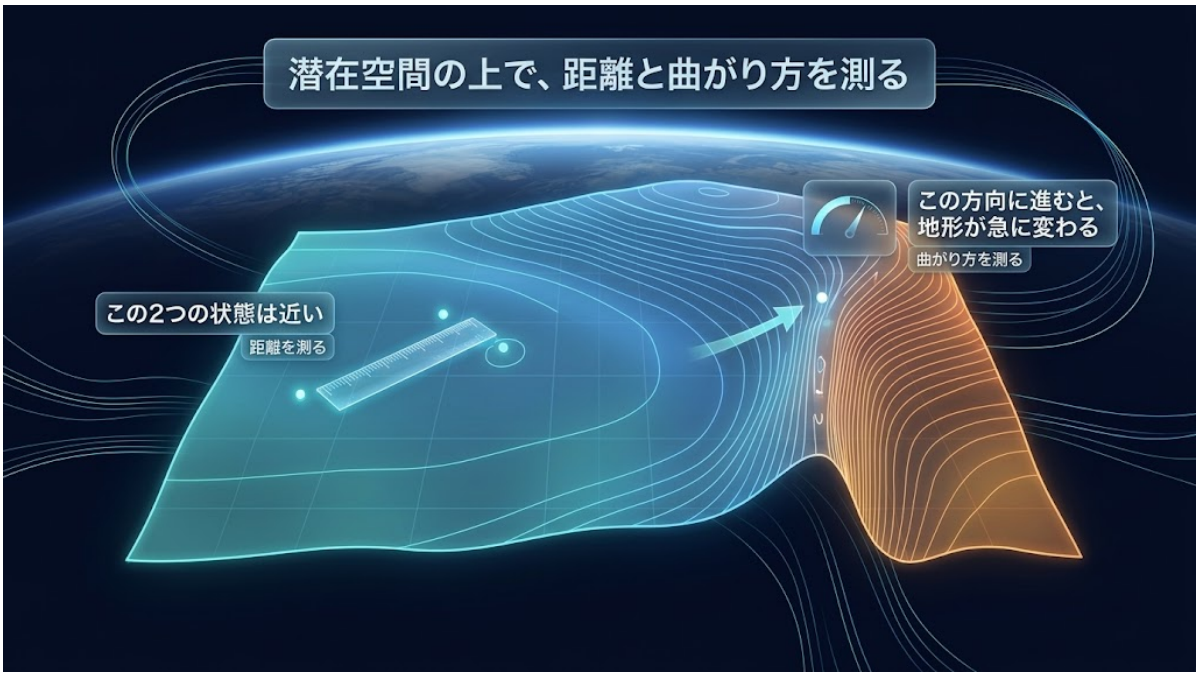
VAEの潜在空間 は、**画像などの生成AIのタスク** で、優れた精度を発揮しています。
あたかも実在するかのような、架空の画像や音声などを生成するタスクです。

では、**社会経済データをVAEに入力したら、どうでしょうか。**
得られた潜在空間の上で、企業がとるべき戦略や戦術、個々の施策（営業施策、マーケティング施策など）を分析できるでしょうか。

ここで考えたいのは、顔画像にそっくりな架空の画像を出力するタスクではありません。
現実の社会経済データを、VAEで次元圧縮します。
すると、**社会経済の潜在空間**が得られます。
重要な情報だけが、少ない次元数（＝少ない座標軸）に圧縮されたベクトル空間です。

この潜在空間を舞台に、**社会経済の構造（形）を調べる。**
あるいは、**企業の施策の効果を予測するシミュレーションを行う。**
そういうタスクです。

このタスクでは、潜在空間の上で、**距離や曲がり方を測る**ことが必要になります。
「この2つの状態は近い」「この方向に進むと、地形が急に変わる」といったことです。



ここで問題になることを表にまとめると、次のようになります。

観点	VAEの潜在空間
学習の目的	再構成の誤差と、正規分布に近づける項（KL）を小さくすること。幾何の性質は目的に入っていない
地図が現実を表しているか	保証なし。再構成が粗ければ、地図そのものが現実とずれている
近いものは近いか	保証なし。データ空間で近い点が潜在空間で離れていたり、逆に遠い点が近くに重なったりする（地図が破れたり、折りたたまれたりする）
どの方向にも潰れていないか	保証なし。使われていない次元や、データの境目では、ヤコビ行列の特異値がほぼゼロになり、地図がその方向に潰れる
滑らかさ	ReLUを使うと、デコーダは折れ線の集まり（区分的に線形）になる。2回微分が必要な曲率は、ほとんどの場所でゼロになるか、定義できない
$g = J^\top J$ の意味	計算はできるが、正定値とは限らない。潰れた方向では「距離ゼロ」の向きができ、距離として成り立たない
結果の扱い	「それらしい図」。距離や曲率の数値は解釈できない

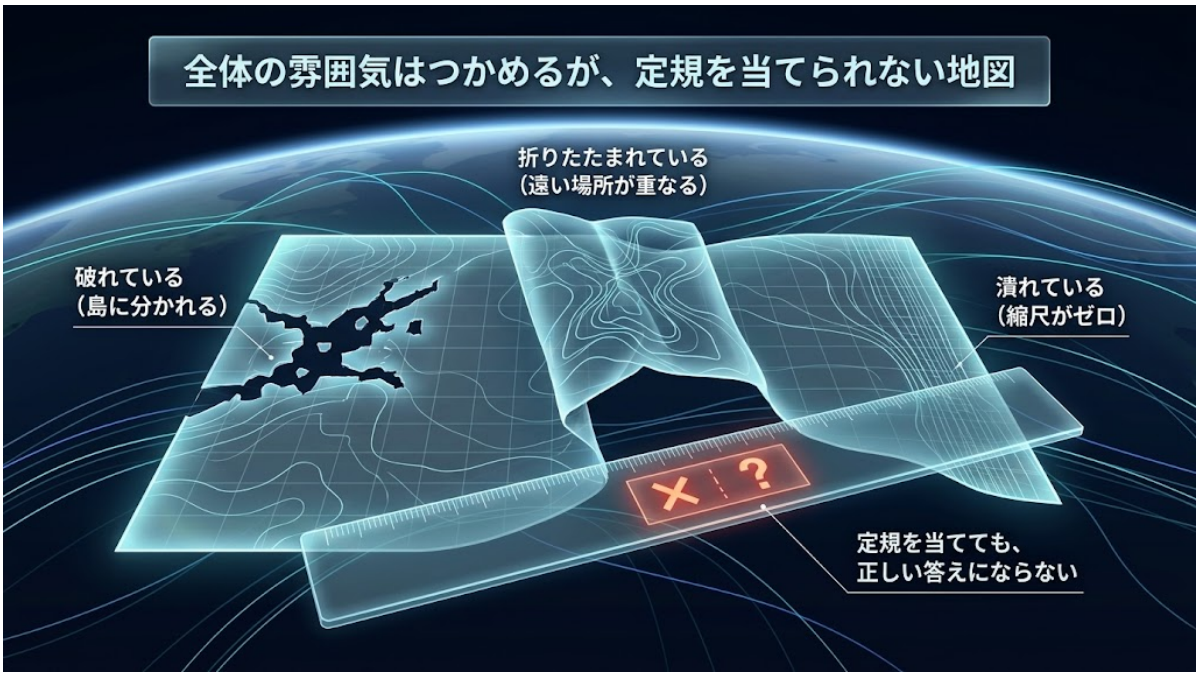
つまり、**VAEの潜在空間** は、**全体の雰囲気はつかめる地図** です。

けれど、ところどころ紙が破れています（島に分かれる）。

折りたたまれているところもあります（遠い場所が重なる）。

縮尺が、場所によってゼロになっていることもあります（潰れる）。

その上で定規を当てて距離を測っても、正しい答えにはならない のです。



③ 潜在空間を「定規を当ててよい地図」にするための条件

- **社会経済の潜在空間を舞台に、社会経済の構造（形）を調べる。**
- **企業の施策の効果を予測するシミュレーションを行う。**

そのためには、**次の条件を満たす必要がある** と、筆者は考えます。

これらの条件 を、「**地図**」 にたとえて説明します。

条件１：地図が、現実をきちんと写していること

地図の上の点から、元のデータをほぼそのまま描き戻せること。
これが1つ目の条件です。

描き戻したデータが現実とずれていれば、その地図は、そもそも現実を写していません。
どんなに精密に距離を測っても、それは、ずれた地図の上の距離です。

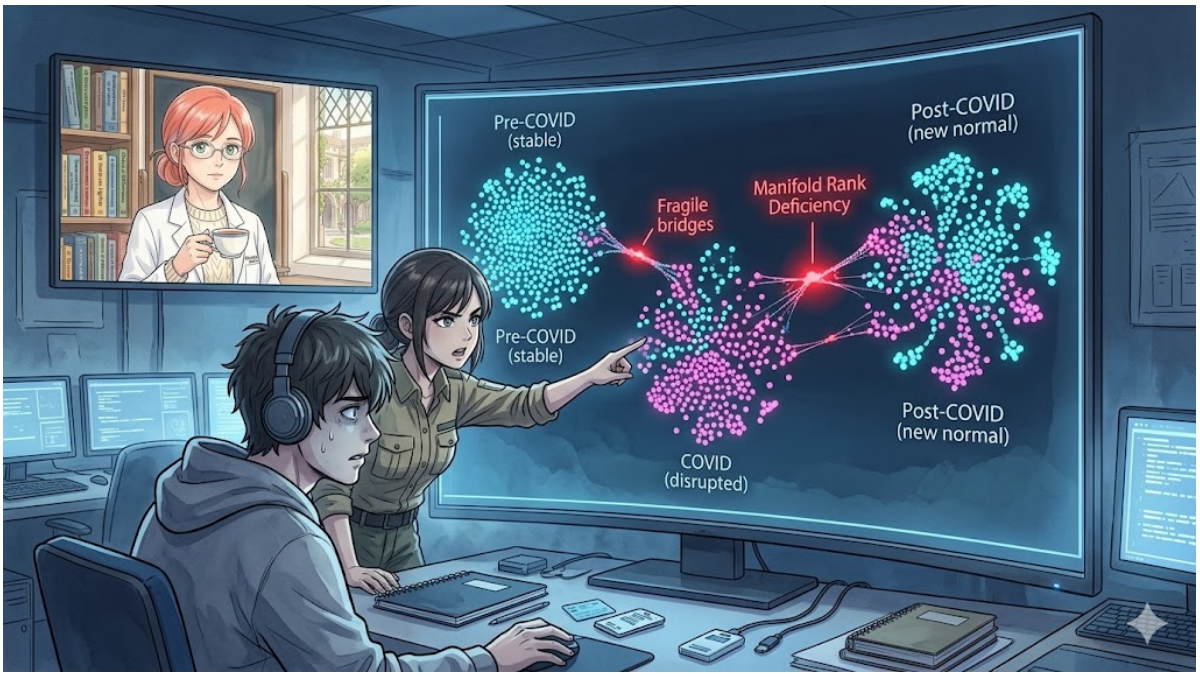
> 例：月ごとの売上や在庫を、地図の上の点に置いたとします。
> その点から、元の売上や在庫の数字が、ほぼそのまま戻ってくること。

条件２：地図に、破れや折りたたみがないこと

現実で近いものは、地図の上でも近くにあること。
そして、地図の上で近いものは、現実でも近いこと。

道路にたとえれば、「道の表面がつながっていて、途中で途切れたり、ワープしたりしない」ということです。

> 失敗の例：現実ではよく似た2つの月が、地図の上では遠く離れた「島」に分かれてしまう（地図が破れている）。
> 逆に、現実ではまったく違う2つの状況が、地図の上では重なってしまう（地図が折りたたまれている）。



図：地図が「島」に分かれてしまった例（架空のケーススタディより）。3つの時代のデータが3つの塊になり、その間が細い橋でしかつながっていない。

条件３：どこでも、どの方向にも、縮尺が決まっていること

地図のどの場所でも、どの方向に動いても、縮尺が決まっていること。
つまり、「地図の上の1歩が、現実ではどれくらいの変化にあたるか」が決まっていることです。

道路にたとえれば、「途中に、幅がほとんどゼロの細い道（ボトルネック）がない」ということです。

ある方向の縮尺がゼロに近いと、その方向では、地図がぺたんと潰れています。
潰れた方向では、距離を測ることができません。

> 失敗の例：よく似た動きをする指標を、そのまま別々の軸として地図に入れると、「同じ方向を2回数える」ことになります。
> すると、地図がその方向で歪んだり、潰れたりします。
> また、データの数が少なすぎると、縮尺を決めるための情報そのものが足りなくなります。

あわせて：地図が、なめらかであること

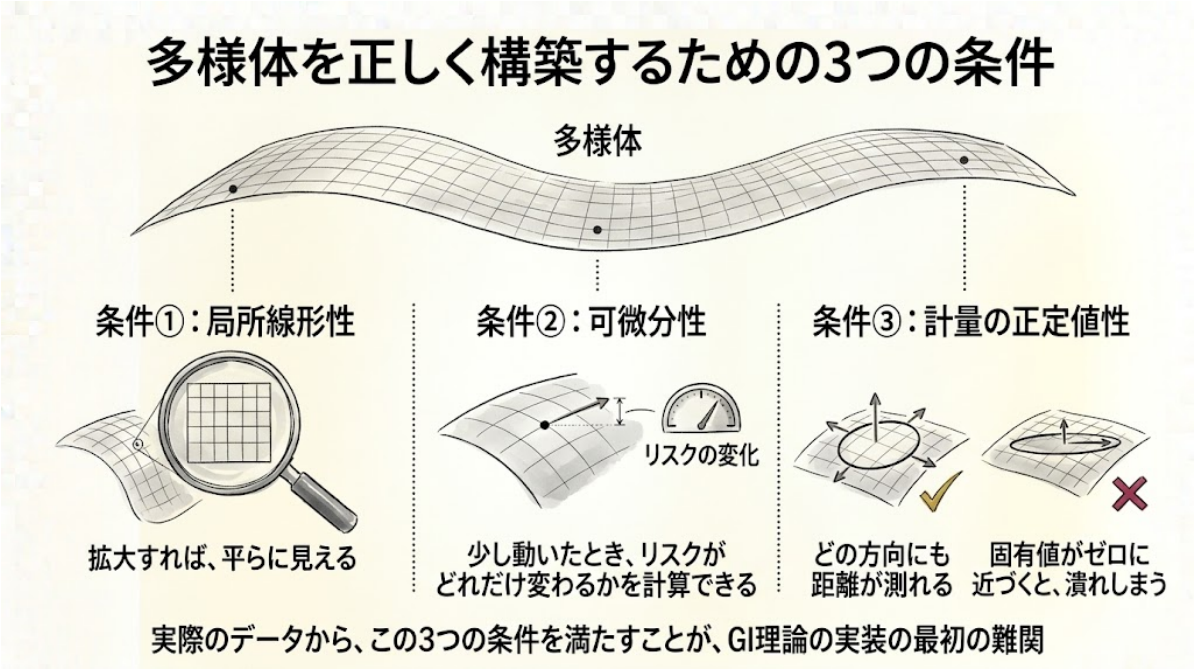
距離だけでなく、地形の起伏（曲がり方）も測りたい。

そのためには、**地図がなめらかである必要** があります。
「少し動いたとき、どれだけ変わるか」を計算できなければならないからです。
（数学の言葉では、「微分可能である」という性質が必要になる、ということです。
曲がり方まで測るには、2回以上微分できることが必要です。
「可微分多様体」という言葉の「可微分」も、このように微分の計算ができる、なめらかな空間であることを表しています）

経営判断でいえば、「この施策を少し強めたら、リスクはどれだけ変わるか」という感度を計算できることです。

そのために、AIのモデルの部品（活性化関数）には、なめらかな曲線になるもの（Tanh や Softplus）を使います。

角のある折れ線になるもの（ReLU）は使いません。



図：地図に定規を当てるための条件のまとめ

3つの条件を満たすと

地図の上に、場所ごとに正しい「定規」（リーマン計量）を当てられるようになります。
この定規を使って初めて、次のものを計算できるようになります。

- 距離
- 地形の起伏（曲率）
- 2つの状態を結ぶ、最も無理のない道筋（測地線）

エンジニア向けのメモ（判定の目安）

- 条件1：再構成誤差（MSE）が閾値未満（データを標準化した場合の目安：0.01）
- 条件2：k最近傍の保存率が0.90以上（データ空間での近傍が、潜在空間でも近傍として保たれている割合）
- 条件3：デコーダのヤコビ行列 J の最小特異値が閾値以上（データの尺度に応じて決める。目安：0.001）。このとき $g = J^\top J$ が正定値になる
- なめらかさ：デコーダの活性化関数に Tanh や Softplus を使い、2回以上微分できるようにする

3つの補足

- **「多様体」と「可微分多様体」とは**：多様体とは、どの地点も、**すぐ近くだけを見ると、まっすぐな平面（ユークリッド空間）と同じように見える空間** のことです。
  たとえば地球の表面は、**全体としては丸く曲がっていますが、自分のいる町の近くだけなら、平らな地図で表せます。**
  地球全体は、こうした小さな平らな地図を、**隣どうしが重なる部分で貼り合わせた「地図帳」** として表せます。**多様体は、この「地図帳」として表せる空間のこと** です。
  「可微分多様体」の「可微分」は、厳密には、空間そのものに「微分の計算ができる構造」が入っていることを指す言葉です。**地図の貼り合わせ方がなめらかである**、という意味です。
  そのおかげで、どのページの地図で計算しても、「少し動いたとき、どれだけ変わるか」

の答えが食い違いません。
- **数学の言葉で言えば**：潜在空間（たとえば2次元の平面）は、それだけで、数学上は多様体です。
  問題は、デコーダによって、その平面が現実のデータの形を正しく写した「地図」（はめ込み）になっているかどうか です。
  3つの条件は、それを実際のデータで確かめる手順 です。
- **確かめられる範囲**：条件は、データがある範囲（実際に使う潜在空間の領域）で確かめます。**データのない空白の領域では、デコーダは、学習していない場所を勝手に補っているだけ** です。
  ですから、合格した多様体でも、**その外側の距離や曲率は信用できません**。

④ 条件を満たすと、何ができるようになるか

上記の条件を満たすと、社会経済の潜在空間を舞台にしたタスクを行えるようになります。
社会経済の構造（形）を調べたり、企業の施策の効果を予測するシミュレーションを行ったりできるのです。

たとえば、**いまいる場所が安定した「平地」なのか、少しの変化で大きく動く「崖」なのかを、地形の起伏として測ることができる** ようになります。

いまの状態から目標の状態までの、最も無理のない道筋も計算 できます。

物理学（一般相対性理論）や工学では、曲がった空間の上で、こうした計算が当たり前のように行われています。
それを、社会経済データに対して行うイメージです。

- 具体的にどのような計算ができるのか。
- 物理学や工学では、どのように使われているのか。

これらは、**この連載の第２回目の記事** で詳しく取り上げます。

社会経済データから、経営環境分析や政策環境分析を行う。
企業や政府の施策がもたらす効果の予測シミュレーションを行う。
そのために、距離や勾配などが定義された可微分多様体をサーバ上に構築する。
この流れについて、理論面（数学面）での考察を、以下の記事と本（Zenn Book）で詳しく論じています。

- https://qiita.com/etale_cohomology/items/4ad1afafc20b98e69ae7
- https://qiita.com/etale_cohomology/items/3487a08a8dd08c7452a8
- https://zenn.dev/etalecohomology/books/3761995ca27127

https://qiita.com/etale_cohomology/items/4ad1afafc20b98e69ae7

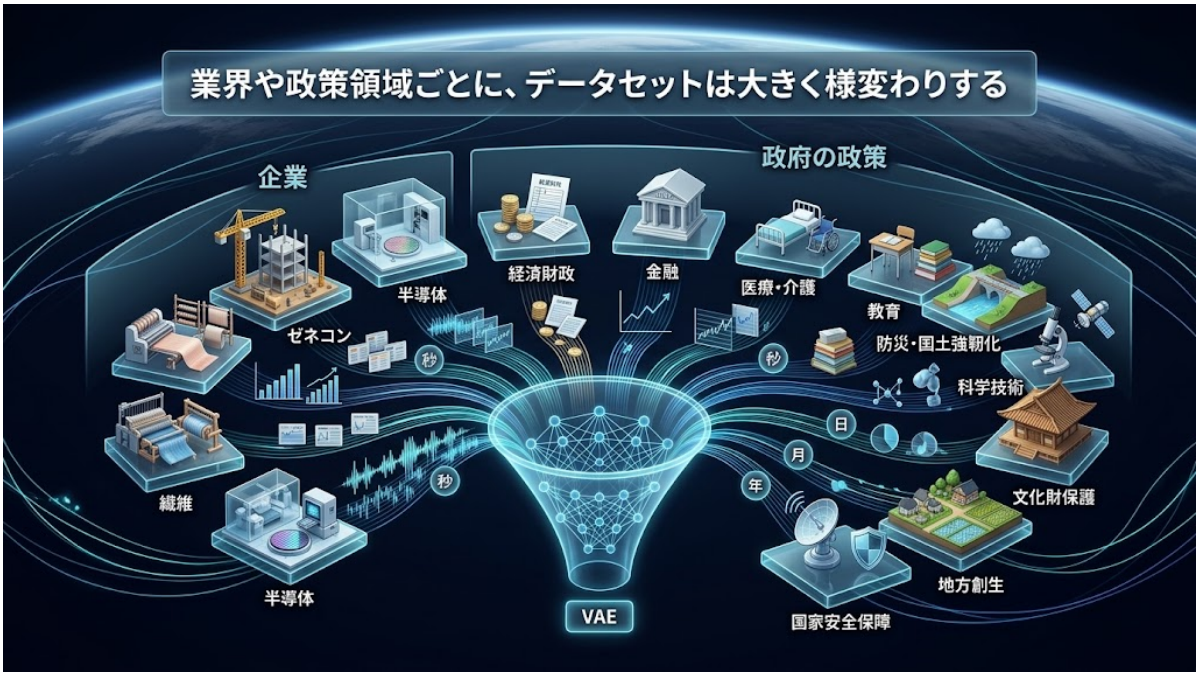
https://qiita.com/etale_cohomology/items/3487a08a8dd08c7452a8

https://zenn.dev/etalecohomology/books/3761995ca27127

ただ、上記の記事と本（Zenn Book）は、ニーズに応えきれていなかったと思います。
説明が足りなかったり、逆に、説明が学術的すぎたりしたからです。

そこで、適度に読みやすい記事を、別途、執筆・公開する予定です。

⑤ 社会経済データから「地図」を作るための試行錯誤 ―― 架空の舞台セットで考える



VAEに入力するデータセットは、業界や政策領域ごとに、大きく様変わりする と思われます。

企業の経営環境を分析し、その環境での企業戦略の効果を予測する場合と、国の政策や施策を分析する場合とでは、扱うデータがまったく違うからです。

また、民間企業であっても、例えば繊維産業とゼネコン企業と半導体企業とでは、経営環境の構造もそれを調べるために用いるデータセットの種類と時間粒度は大きく異なると思われます。

政府の政策も、経済財政政策と金融政策、医療・介護政策、教育政策、防災・自然災害対策・国土強靭化政策、科学技術政策、文化財保護政策、地方創生政策、国家安全保障政策でも、データセットは大きくことなるのではないでしょうか。

そこで筆者は、複数の業界と複数の政策領域について、架空の舞台セットを考えてみました。

フィクションの企業戦略シナリオや国家戦略シナリオを想定し、それぞれでどのようなデータセットを扱うことになりそうかを考えた のです。

そして、**その舞台セットの上で、架空のデータセットから、条件を満たす「地図」をVAEで構築するには、どのような試行錯誤が必要になりそうか** を考えました。

データの集計（名寄せ、欠損値の補完、データの取得粒度や計測基準（目盛りなど）の定義の調整）から、データの加工までです。

データ解析の中で最も時間を使う、いわゆる「どぶ板」のデータ・クレンジングの工程です。

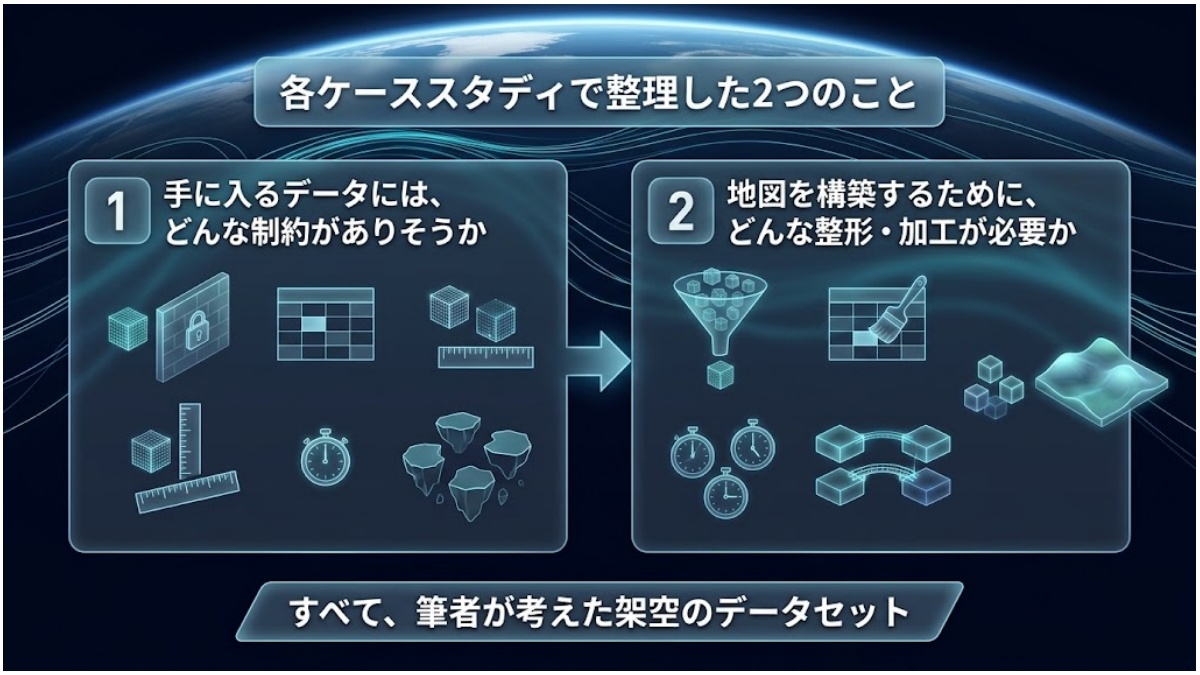
これを、フィクションのケーススタディ・ノベルの形式で言語化しています。



各ケーススタディでは、次の2つを整理してみました。

- 各業界・各政策領域で手に入るデータには、どんな制約がありそうか
- そうしたデータから地図を構築する際に、どんなデータの整形・加工の作業が求められそうか

ただし、あくまで筆者が考えた**架空のデータセット**です。



繰り返しますが、以下は、実在する企業や政府機関の実データを使って得られた知見ではありません。
登場する企業、組織、人物、数値は、すべて架空のものです。

舞台（架空）	データの制約	最初につまずいた条件	試行錯誤の中身
繊維メーカー	売却した子会社や新しい拠点の期間のデータが欠ける。現地の担当者の交代で、6か月分のコストデータが紙の請求書にしか残っていない。COVIDなどの大きな出来事の前後で、データが「別の世界」になる	条件2・3（データが3つの時代の塊に分かれ、その間が細い橋でつながるだけ）	大きな出来事の前後の期間だけ、月次ではなく日次のデータを掘り起こした（約28万件の取引記録を整えて1,247日分に）。SNSの投稿から日次の評判を抽出。売上の連続性、稼働率は0〜100%、資産の保存といった「経営の物理法則」を守る制約付きの補間で、塊の間をつないだ
ゼネコン（総合建設会社）	事業の単位がプロジェクトで、数十件が別々のシステムで管理されている。本社の基幹システムと海外の合弁会社のシステムが別で、合弁会社のデータは月次の集計値しかない。案件ごとに使うプラットフォームも違う。現場のセンサーデータは秒単位	条件2・3（プロジェクトごとに無数の小さな島ができた）	分析の単位を「プロジェクト」から「会社全体の月次の指標」に変え、プロジェクト間の連動のパターンを主成分分析で残した。秒単位のセンサーデータは月次に混ぜず、別の層として扱った。国内・中東・新興国の塊は、技術者の異動の履歴（約3,200件）を「橋」としてつないだ
半導体製造装置メーカー	好況と不況のサイクルが周期的にくり返し、構造そのものが変わる。顧客ごとの取引データは厳格に機密管理され、顧客Aのデータを顧客Bに知られてはならない。装置のデータは1枚のウェハーで1万5千のパラメータ。技術の世代が変わると装置の設定値がまったく違う	条件2・3（サイクルの局面ごとに塊が分かれた）→ 次に条件2（技術世代ごとの島）	時間ではなく「サイクルのどの位置にいるか」（位相）を、信号処理の方法（ヒルベルト変換）で推定して加えた。装置の設定値（レシピ）を、物理法則が決める量（プラズマの電子密度など）に置き換えると、世代の間が連続になった。顧客ごとのデータは、個別に復元できない形で使う
日本の経済安全保障（政策領域）	データが7つの情報関係機関と11の省庁に分かれ、それぞれに外に出せない理由がある。生のデータは入れられず、集計した指標になって初めて使える。情報源そのものは出せない。月次だけでは時点の数が足りない	条件2・3（11の分野が、省庁ごとの島に分かれた）	集計し、件数の少ない区分を伏せ、統計的なノイズを加えてから入力する仕組みを作った。情報源の中身ではなく「方向と強さ」として入力。指標の定義・単位・更新頻度を辞書で統一。分野の間の依存関係を、産業連関表から指標化して島をつないだ

舞台（架空）	データの制約	最初につまずいた条件	試行錯誤の中身
英国の国家レジリエンス（政策領域）	通信情報は、生のデータや通信内容を使えず、分析結果だけが使える。EU離脱で、EUのデータの仕組みへのアクセスを失った	条件2（EU離脱の前と後で「2つの英国」に分かれた）	「EU離脱の度合い」を0から1の連続的な指標として作り、離脱の前後をなめらかにつないだ。週次・日次の指標で時点を約4,000に増やし、補間した値には印を付けた
8か国の情報機関の協力（政策領域）	データを国の外に出せない。共有できる範囲が国によって違う。年次の統計と秒単位の通信データが混在。同じ「軍事費」でも定義が違う。情報源を守るための意図的な欠損がある	条件1（尺度の違い）→条件2（外交データの粒度の不統一）	各国の施設の中で計算し、集計とノイズを加えた結果だけを持ち寄る方法（連合学習）で学習した。定義を統一し、分野ごとに標準化した。条約・投票・制裁など粒度の違うデータを、すべて四半期にそろえた
北極海の海上保険（業界）	事故の記録が世界で7件しかない。船の古さ、氷海の等級、積荷の種類が互いに強く相関する。市場に流れ込む資料の中に、正しいデータだが、偏って選ばれたデータがまぎれ込む	条件③（距離を定める行列が退化）、条件①（相関による曲率の歪み）	氷の厚さや気象の公開データにもとづく物理シミュレーションで5,000件のシナリオを補い、本物の7件で照らし合わせ続けた。行列に小さな値を足して安定させた（正則化）。相関の強い変数は、互いに直交する軸に変換した（主成分分析）。資料の偏りは、統計学の検定で見抜いた

どの舞台でも、最初の試行で条件を満たせたことは、ほとんどありませんでした。

けれど、条件に落ちたことそのものが、手がかりになりました。

そのデータの「どこが切れているか」「何が混ざっているか」を教えてくれたのです。

そして、切れ目をつなぐ方法は、統計の操作よりも、現場を知る人の知恵から見つかることが多かったのです。

たとえば、「人がどこからどこへ動くか」。
「物理法則は、技術の世代が変わっても変わらない」。

そうした知恵です。

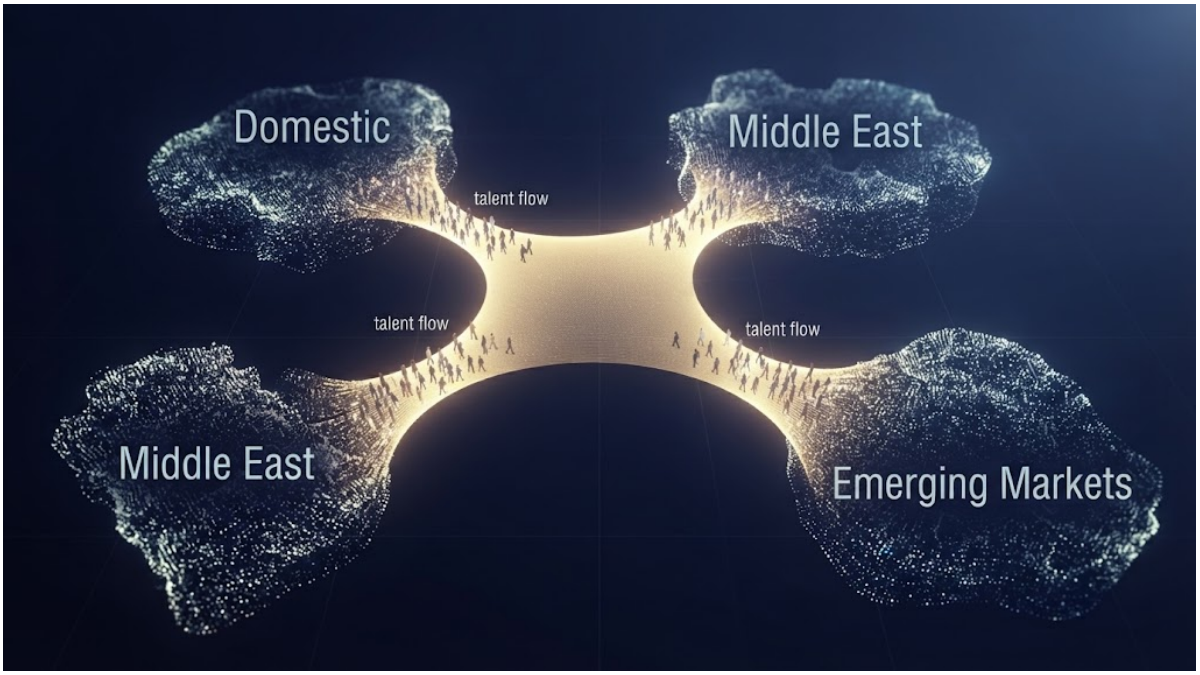
架空の舞台での試行錯誤のイメージ

以下の図は、それぞれの架空のケーススタディの中で描いたものです。
データの切れ目と、その切れ目をつないだ工夫のイメージです（いずれも、架空の舞台のイメージ図です）。

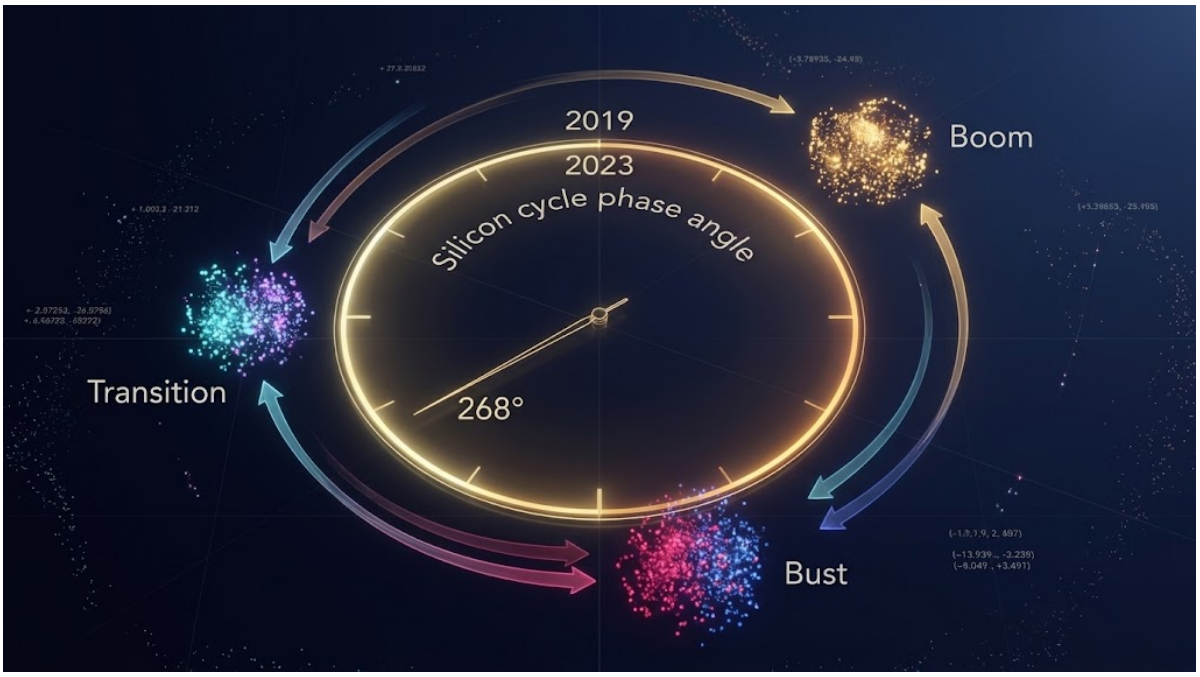
ゼネコン：プロジェクトごとに無数の島に分かれた地図



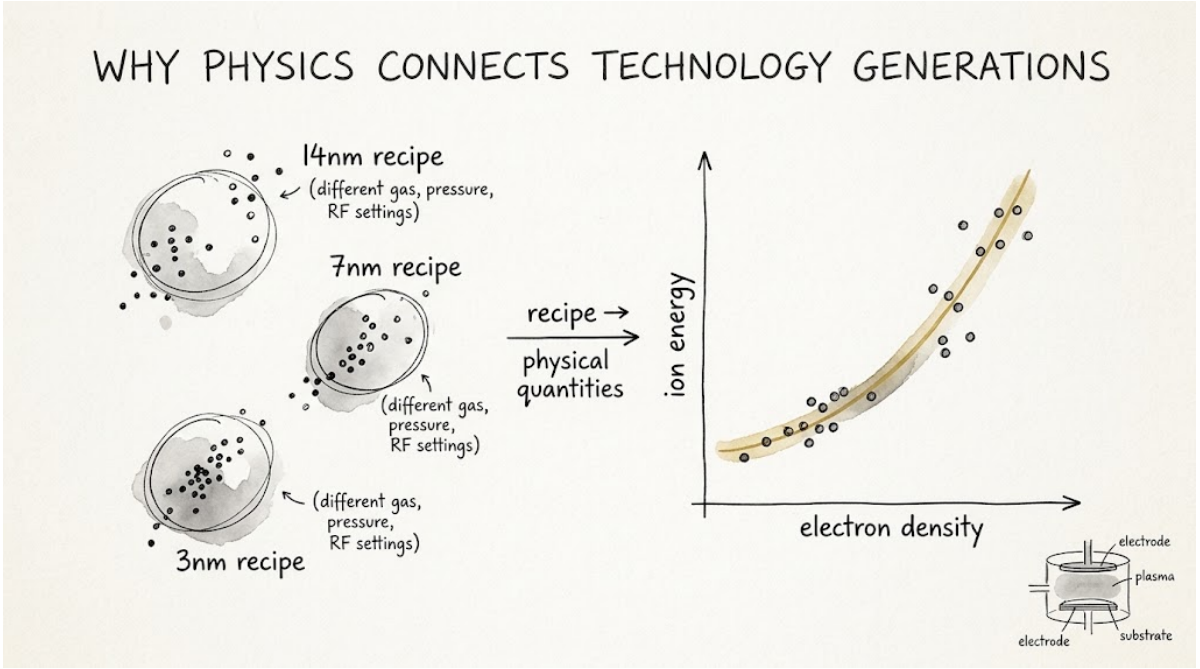
ゼネコン：技術者の異動の流れを「橋」にして、国内・中東・新興国の塊をつなぐ



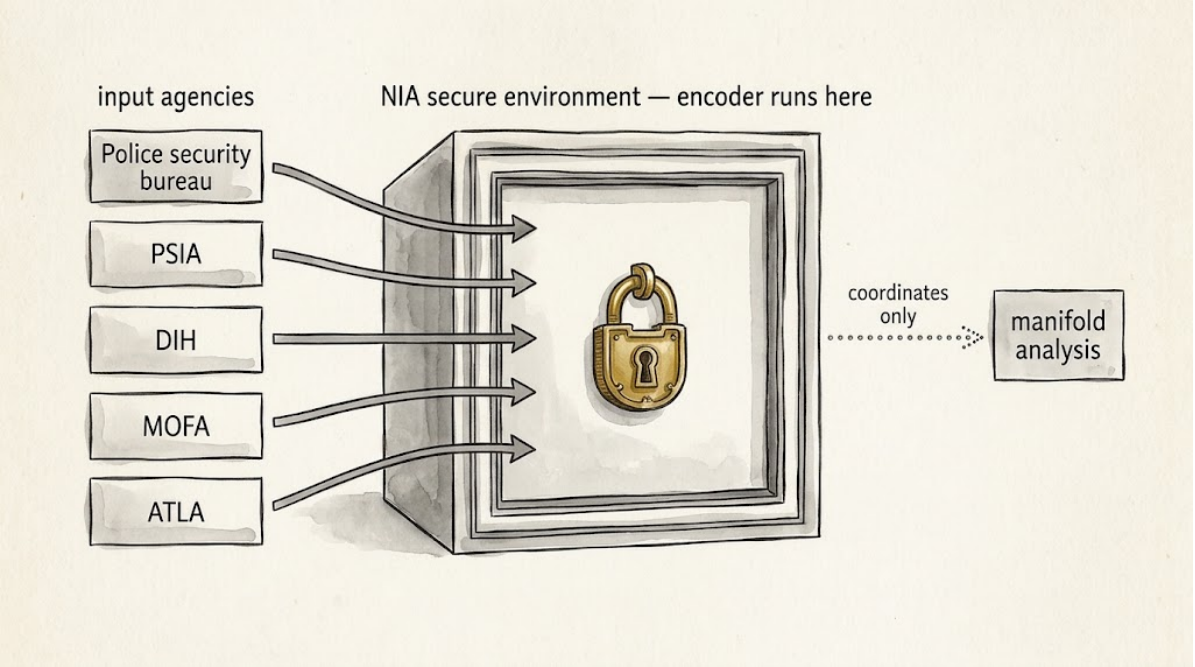
半導体製造装置メーカー：時間ではなく、サイクルの「どの位置にいるか」（位相）で表す



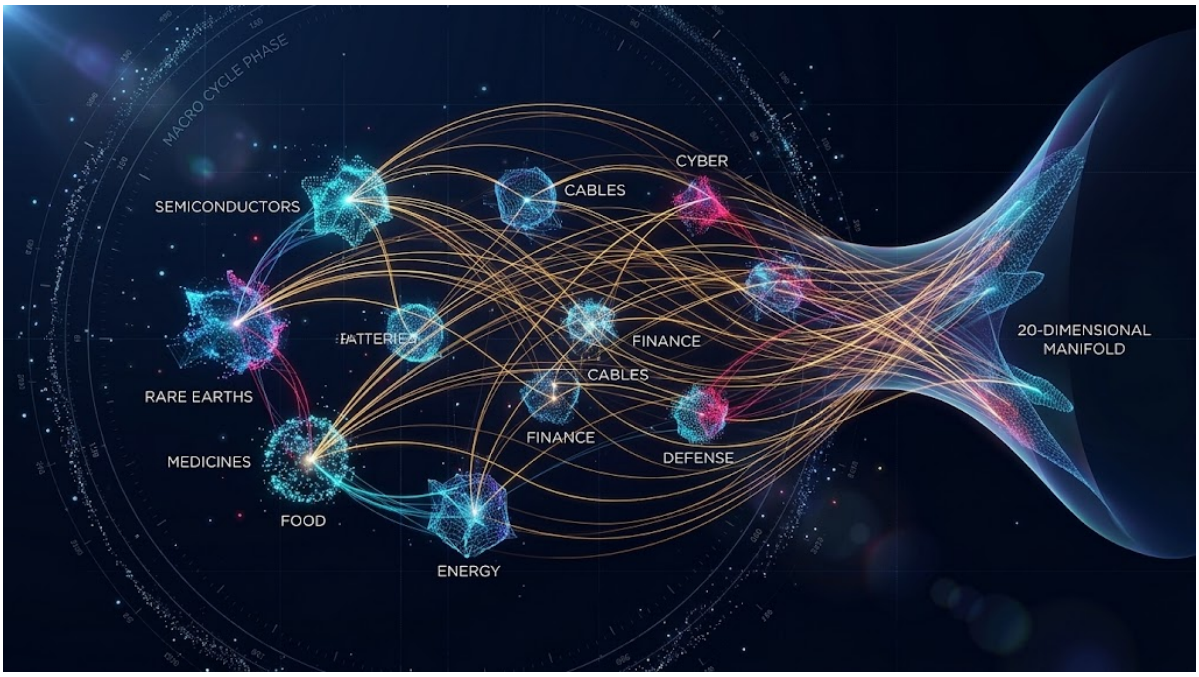
半導体製造装置メーカー：装置の設定値を、物理法則が決める量に置き換えると、技術の世代の間がつながる



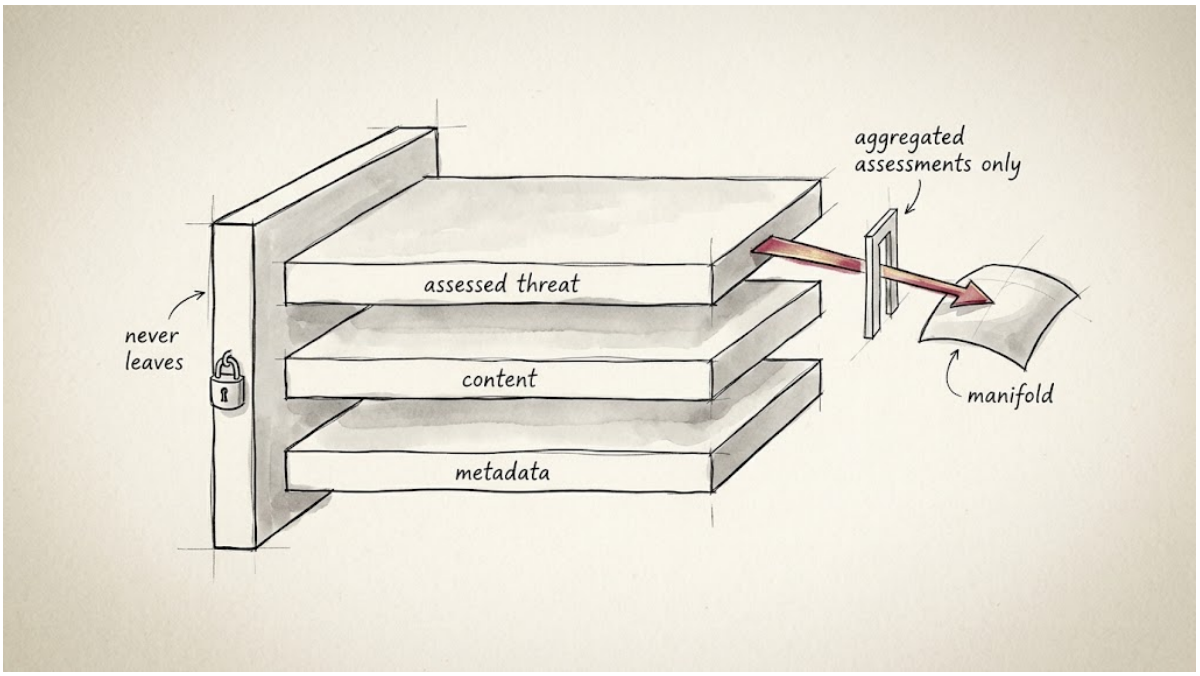
日本の経済安全保障：生のデータは外に出さず、集計した指標だけを地図づくりに使う仕組み



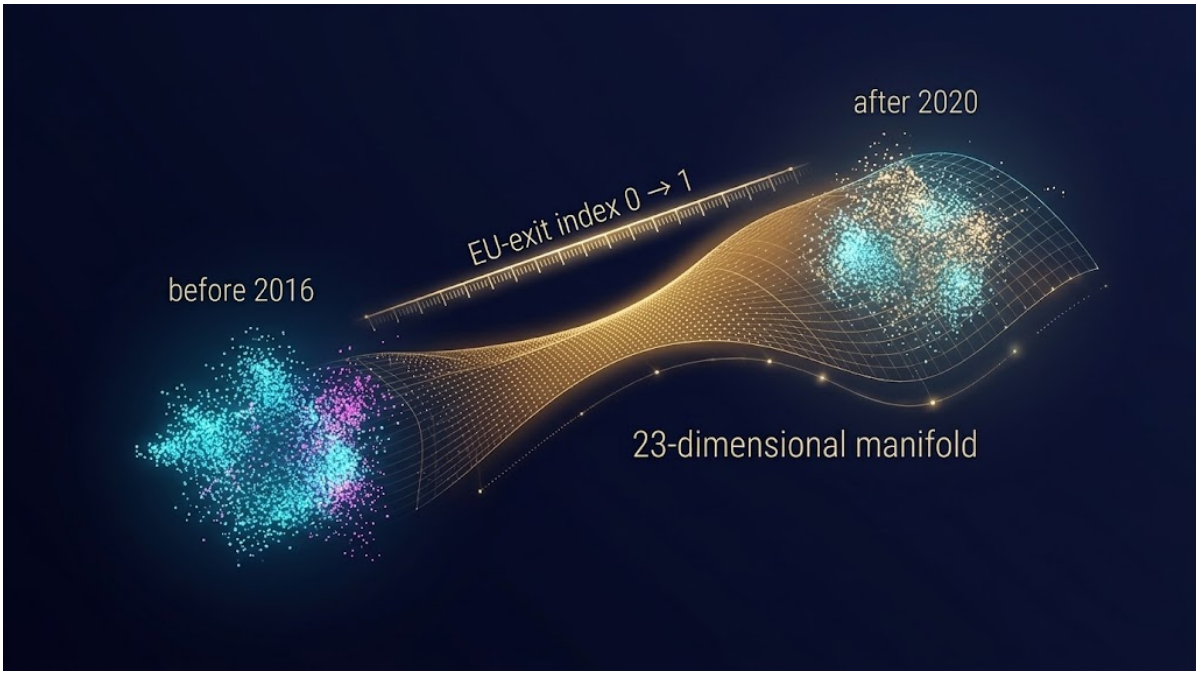
日本の経済安全保障：分野の間の依存関係を指標にして、省庁ごとの島をつなぐ



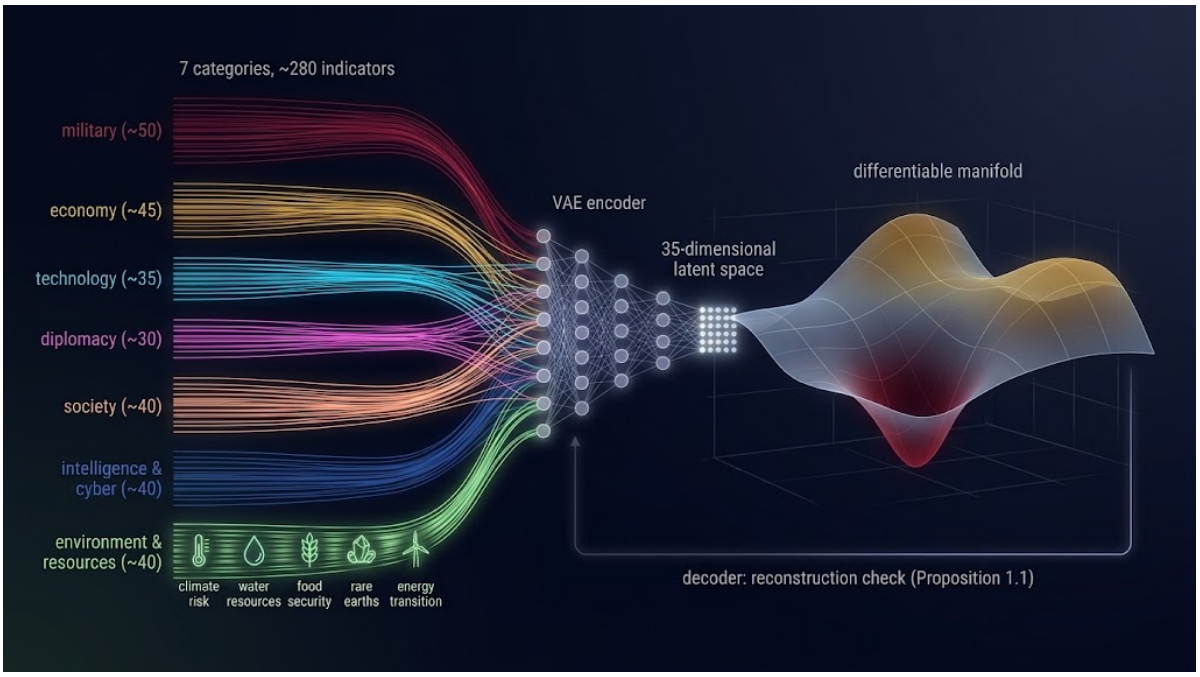
英国の国家レジリエンス：通信情報の3つの層のうち、分析結果だけを地図づくりに使う



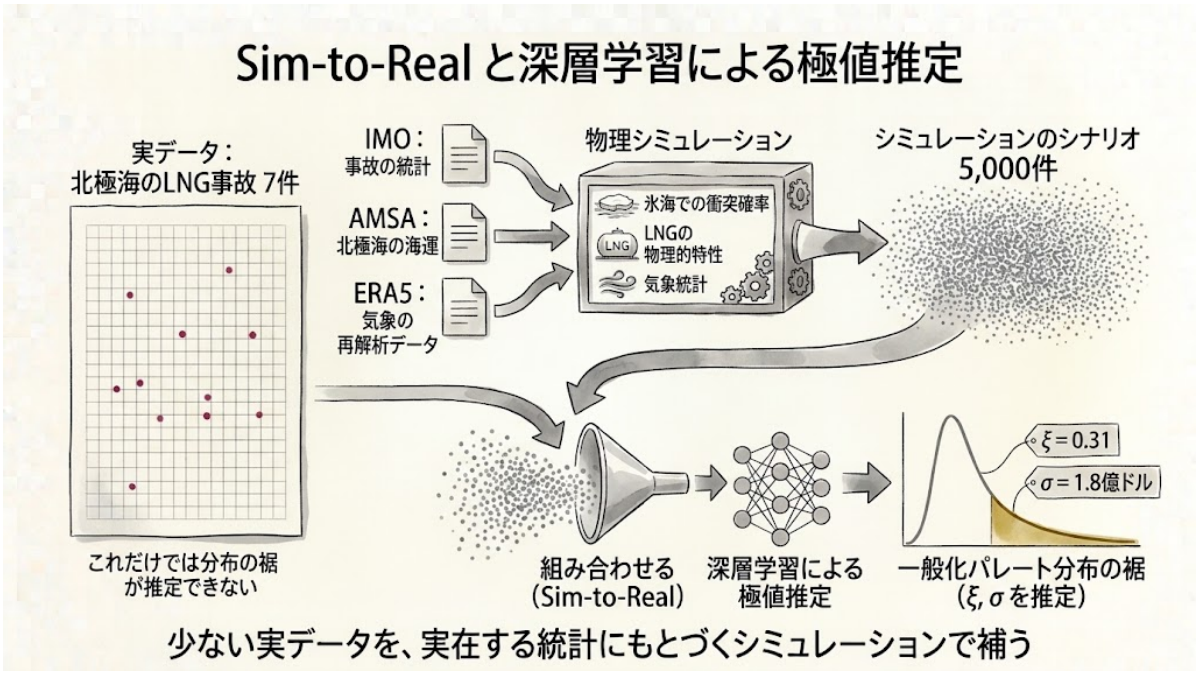
英国の国家レジリエンス：「EU離脱の度合い」を連続的な指標にして、離脱の前後をつなぐ



8か国の情報機関の協力：分野の違う多数の指標を、1つの地図にまとめる



北極海の海上保険：7件しかない実データを、物理シミュレーションで補う



（繊維メーカーの舞台の図は、③の「地図が『島』に分かれてしまった例」です。）

⑥ 結び —— 冒頭の画像の「ジオメトリック・インテリジェンス」とは

この記事の冒頭の画像には、「ジオメトリック・インテリジェンス」という連載名が描かれています。
最後に、この名前について説明させてください。

筆者は、ここまで書いてきた考え方を、**Geometric Intelligence（ジオメトリック・インテリジェンス、GI）理論**と呼んでいます。
「データから作った地図を、条件を確かめたうえで、社会経済の分析と意思決定に使う」という考え方です。

GI理論の流れを、地図のたとえで、ひと言ずつ表してみます。

1. **地図をつくる**：社会経済のデータから、VAEで潜在空間をつくる
2. **地図を確かめる**：この記事で紹介した3つの条件で、地図に定規を当ててよいかを確かめる
3. **地形を読む**：いまいる場所が、安定した「平地」か、少しの変化で大きく動く「崖」かを、地形の起伏（曲率）として測る
4. **施策の効き方を読む**：ある施策が、地形そのものをどう変えるか。2つの施策を「どちらから先に」行うかで、結果がどう変わるか
5. **道筋を選ぶ**：いまの状態から目標の状態まで、最も無理のない道筋（最短距離。曲がった平面（曲面）上の最短距離は微分幾何学で「測地線」を計算する必要がある。一般相対論でも使われる、空間自体の曲がり具合を考慮に入れた方法を数学者が整備してくれている）を計算する
6. **確からしさを添える**：どの答えにも、どれくらい確かか、なぜそう言えるのかを添え、「分かること」と「分からないこと」を分けて伝える

最後の6つ目は、数学というより、姿勢の話です。
けれど筆者は、これがいちばん大切だと考えています。

条件を満たさない地図の上の数字を、それらしい図として示す。
それは、この記事の②で見たとおり、意思決定を誤らせるからです。

GitHubで公開しているもの

GI理論の理論書と、それを使ったケーススタディを、GitHubで公開しています。

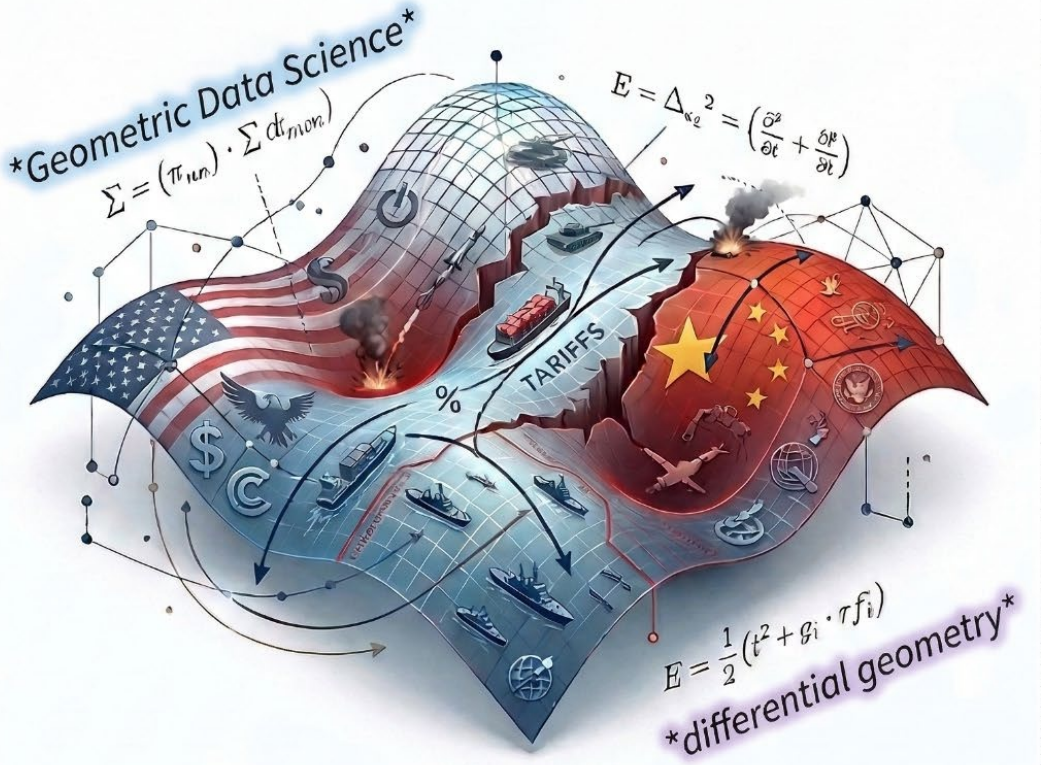
https://github.com/EtaleCohomology/geometric-intelligence-saga

- **理論書**：GI理論の論文（2本）と、実務に導入するための手引書（2巻）

Lumière de l'Intelligence de la Géométrie Différentielle

『ジオメトリック・インテリジェンス』

(GEOMETRIC INTELLIGENCE)



- ✔ 最先端の<幾何学的AI>を使って立体的な<経営環境・政策環境>地形図(可微分多様体)を構築。
- ✔ 立体地形図上で、アインシュタイン方程式で使われるる共変微分・リー微分を計算。
- ✔ 最小リスク・最大効果の経営・政策アクションを導き出す。

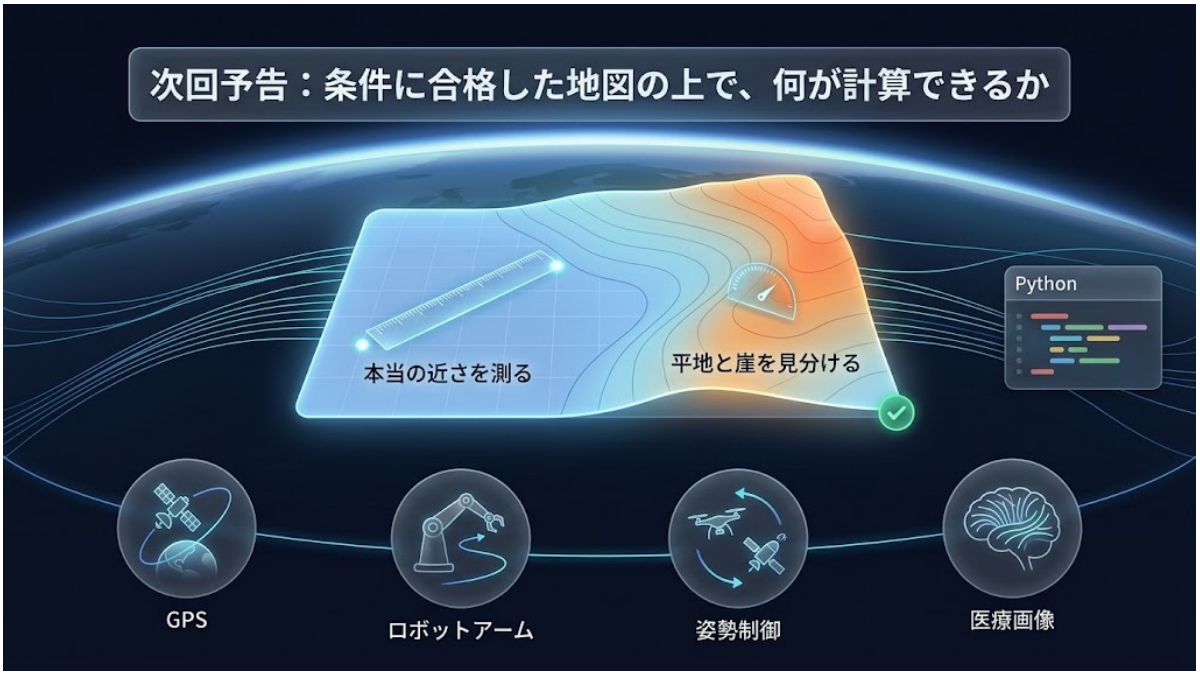


図：実務導入のための手引書（第1巻・第2巻）の表紙

- **ケーススタディ・ノベル**：業界別と政策領域別に、架空の企業や国家の舞台を設定したものです。
  データから地図をつくり、条件に合格するまでの試行錯誤と、その地図の上での分析を、物語の形で描いています（繊維業界、建設業界、半導体製造装置業界、日本の経済安全保障、英国の国家レジリエンス、8か国のインテリジェンス統合、北極海の海上保険）。

⑤の表で紹介した試行錯誤は、このケーススタディ・ノベルの中の出来事です。
くり返しになりますが、登場する企業、組織、人物、データは、すべて架空のものです。

次回予告



第2回 では、**3つの条件に合格した地図** の上で、実際にどのような計算ができるのかを取り上げます。

- 地図の上に当てる「定規」（リーマン計量）で、2つの状態の本当の近さを測る
- 地形の起伏（曲率）から、「平地」と「崖」を見分ける
- 物理学や工学 —— GPS、ロボットアーム、ドローンや人工衛星の姿勢制御、医療画像 —— で、曲がった空間の上の計算がどのように使われているか

そして、それを社会経済データに対して行うと何が見えてくるのか。
Pythonのコードとともに紹介する予定です。